Chapitre 3 – Tests d'hypothèse

La fiche simple

1. L'idée

On a estimé un coefficient, par exemple $\hat{b} = 0{,}2$. On veut savoir si le vrai coefficient pourrait être 0.

On se pose une seule question : si le vrai coefficient était 0, est-ce qu'obtenir 0,2 serait *rare* ?

— Si c'est rare (moins de 5 % de chances) : on **rejette** H_0.
— Sinon : on **ne rejette pas** H_0.

2. Les outils

Test t : tester UN coefficient

Formule : $t = \dfrac{\text{estimation} - \text{valeur testée}}{\text{écart-type}} = \dfrac{b_k - \beta_{k,0}}{\text{e.t.}(b_k)}$
Règle : on rejette H_0 si $|t| >$ valeur critique (environ **1,96** à 5 %).

p-value : la même décision, autrement

En mots : la probabilité d'obtenir un résultat aussi extrême si H_0 est vraie.
Règle : on rejette H_0 si $p < 0{,}05$.

Intervalle de confiance à 95 %

Formule : $b_k \pm 1{,}96 \times \text{e.t.}(b_k)$
Règle : si 0 n'est **pas** dans l'intervalle, on rejette $\beta_k = 0$.

Tester une SOMME de coefficients : $\beta_1 + \beta_2 = 1$

Formule : $t = \dfrac{b_1 + b_2 - 1}{\text{e.t.}(b_1 + b_2)}$, avec $\text{Var}(b_1 + b_2) = \text{Var}(b_1) + \text{Var}(b_2) + \mathbf{2\,Cov}(b_1, b_2)$
À ne pas oublier : la covariance.

Test F : tester PLUSIEURS restrictions à la fois

Formule : $F = \dfrac{\text{SCE}_r - \text{SCE}_u}{\text{SCE}_u} \times \dfrac{n - K}{J}$
SCE_r : modèle avec les restrictions ; SCE_u : modèle sans restriction ; J : nombre de restrictions.
Règle : on rejette H_0 si $F >$ valeur critique.

3. Un exemple (celui du cours)

$H_0 : \beta_3 = 0{,}5$. On a trouvé $b_3 = 0{,}77$ et e.t.$(b_3) = 0{,}12$, avec $n - K = 11$.

1. $t = \dfrac{0{,}77 - 0{,}5}{0{,}12} = 2{,}25$
2. Valeur critique à 5 % avec 11 degrés de liberté : 2,201.
3. $2{,}25 > 2{,}201$: on **rejette** H_0. (La p-value vaut 0,046, qui est bien inférieure à 0,05.)

4. Les 5 choses à retenir

1. **Erreur de type I** = rejeter H_0 alors qu'elle est vraie. Elle arrive avec une probabilité de 5 % si $\alpha = 5\,\%$.
2. **Degrés de liberté** $= n - K$ (nombre d'observations moins nombre de coefficients).
3. **Grand échantillon** : on utilise 1,96 à 5 %. **Petit échantillon** : on lit la table de Student avec $n - K$.
4. **Intervalle de confiance** : on ne dit pas « 95 % de chances que β soit dedans », mais « 95 % des intervalles construits ainsi contiennent le vrai β ».
5. **Variables très corrélées** (multicolinéarité) : les tests t peuvent être non significatifs alors que le test F l'est. Cela veut dire qu'au moins une variable compte, sans savoir laquelle.

5. Les compléments utiles à l'examen

Reparamétrisation : faire le test d'une somme avec un simple t

À quoi ça sert : tester $\beta_1 + \beta_2 = 1$ sans calculer la covariance.
Méthode : poser $\theta = \beta_1 + \beta_2 - 1$, donc $\beta_1 = \theta - \beta_2 + 1$, et remplacer dans le modèle :

$$y_i - x_{1i} = \beta_0 + \theta\, x_{1i} + \beta_2\,(x_{2i} - x_{1i}) + \epsilon_i$$

Règle : le t du coefficient de x_{1i} teste directement $\theta = 0$, c'est-à-dire $\beta_1 + \beta_2 = 1$.

Test unilatéral : quand l'alternative a un seul sens

Exemple : $H_0 : \beta_k \leq 0$ contre $H_1 : \beta_k > 0$.
Règle : on rejette si $t > 1{,}65$ (à 5 %, un seul côté). La p-value est la moitié de la p-value bilatérale.

Test F : toutes les pentes sont-elles nulles ?

Hypothèse : H_0 : tous les coefficients sauf la constante valent 0.
Formule : même F que page 1, avec $J = K - 1$; le modèle contraint est y sur une constante seulement.
Règle : rejet si $F > F^*(K - 1,\, n - K)$. Les logiciels l'affichent en haut du tableau (« F » et « Prob > F »).

Écrire plusieurs restrictions sous la forme $R\beta = q$

Exemple : $H_0 : \beta_2 = 1$ et $\beta_3 = 1$ dans $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \epsilon$:

$$\underbrace{\begin{pmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}}_{R} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \underbrace{\begin{pmatrix} 1 \\ 1 \end{pmatrix}}_{q}$$

Règle : R a une ligne par restriction, donc J = nombre de lignes. On transforme chaque restriction en « un coefficient vaut 0 » (comme la reparamétrisation), puis on fait le test F.

Multicolinéarité : pourquoi la variance augmente

Formule : $\mathrm{Var}(b_k) = \dfrac{\sigma^2}{x_k' x_k \,(1 - R_k^2)}$

R_k^2 : R^2 (non centré) de la régression de x_k sur les autres variables.

En mots : plus x_k ressemble aux autres variables (R_k^2 proche de 1), plus sa variance est grande et plus son t est petit.

Après un Monte Carlo : l'estimateur est-il sans biais ?

Formule : $\tau = \dfrac{\bar{b}^* - \beta_k}{\sqrt{\widehat{\mathrm{Var}}(b^*)/R}}$ ($\bar{b}^*$: moyenne des R estimations simulées)

Règle : si $|\tau| < 1{,}96$, on ne rejette pas l'absence de biais.