Chapitre 3 – Tests d'hypothèse

La fiche simple

1. L'idée

On a estimé un coefficient, par exemple $\hat{b} = 0{,}2$. On veut savoir si le vrai coefficient pourrait être 0.

On se pose une seule question : si le vrai coefficient était 0, est-ce qu'obtenir 0,2 serait *rare* ?

— Si c'est rare (moins de 5 % de chances) : on **rejette** H_0.
— Sinon : on **ne rejette pas** H_0.

2. Les outils

Test t : tester UN coefficient

Formule : $t = \dfrac{\text{estimation} - \text{valeur testée}}{\text{écart-type}} = \dfrac{b_k - \beta_{k,0}}{\text{e.t.}(b_k)}$
Règle : on rejette H_0 si $|t| >$ valeur critique (environ **1,96** à 5 %).

p-value : la même décision, autrement

En mots : la probabilité d'obtenir un résultat aussi extrême si H_0 est vraie.
Règle : on rejette H_0 si $p < 0{,}05$.

Intervalle de confiance à 95 %

Formule : $b_k \pm 1{,}96 \times \text{e.t.}(b_k)$
Règle : si 0 n'est **pas** dans l'intervalle, on rejette $\beta_k = 0$.

Tester une SOMME de coefficients : $\beta_1 + \beta_2 = 1$

Formule : $t = \dfrac{b_1 + b_2 - 1}{\text{e.t.}(b_1 + b_2)}$, avec $\text{Var}(b_1 + b_2) = \text{Var}(b_1) + \text{Var}(b_2) + \mathbf{2\,Cov}(b_1, b_2)$
À ne pas oublier : la covariance.

Test F : tester PLUSIEURS restrictions à la fois

Formule : $F = \dfrac{\text{SCE}_r - \text{SCE}_u}{\text{SCE}_u} \times \dfrac{n - K}{J}$
SCE_r : modèle avec les restrictions ; SCE_u : modèle sans restriction ; J : nombre de restrictions.
Règle : on rejette H_0 si $F >$ valeur critique.

3. Un exemple (celui du cours)

$H_0 : \beta_3 = 0{,}5$. On a trouvé $b_3 = 0{,}77$ et e.t.$(b_3) = 0{,}12$, avec $n - K = 11$.

1. $t = \dfrac{0{,}77 - 0{,}5}{0{,}12} = 2{,}25$
2. Valeur critique à 5 % avec 11 degrés de liberté : 2,201.
3. $2{,}25 > 2{,}201$: on **rejette** H_0. (La p-value vaut 0,046, qui est bien inférieure à 0,05.)

4. Les 5 choses à retenir

1. **Erreur de type I** = rejeter H_0 alors qu'elle est vraie. Elle arrive avec une probabilité de 5 % si $\alpha = 5\,\%$.
2. **Degrés de liberté** $= n - K$ (nombre d'observations moins nombre de coefficients).
3. **Grand échantillon** : on utilise 1,96 à 5 %. **Petit échantillon** : on lit la table de Student avec $n - K$.
4. **Intervalle de confiance** : on ne dit pas « 95 % de chances que β soit dedans », mais « 95 % des intervalles construits ainsi contiennent le vrai β ».
5. **Variables très corrélées** (multicolinéarité) : les tests t peuvent être non significatifs alors que le test F l'est. Cela veut dire qu'au moins une variable compte, sans savoir laquelle.