Chapitre 7 : corrigé des exercices

La non-sphéricité des erreurs : MCG, hétéroscédasticité et erreurs AR(1)

Ce qu'il faut avoir en tête (rappels du cours)

— Erreurs **non sphériques** : $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}] = \sigma^2\boldsymbol{\Omega} \neq \sigma^2\mathbf{I}_n$, soit à cause de l'**hétéroscédasticité** (variances différentes sur la diagonale), soit à cause de la **corrélation sérielle** (termes hors diagonale non nuls).
— Les MCO restent **sans biais** mais sont **inefficaces**, et la formule $s^2(\mathbf{X}'\mathbf{X})^{-1}$ de leur variance est fausse (éq. (3)–(4) du cours).
— **MCG** (moindres carrés généralisés) : on cherche une matrice $\mathbf{P}$ telle que $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$ (éq. (6)) ; le modèle transformé $\mathbf{Py} = \mathbf{PX}\boldsymbol{\beta} + \mathbf{P}\boldsymbol{\epsilon}$ a des erreurs sphériques, et les MCO appliqués à ce modèle donnent l'estimateur efficace

$$\tilde{\boldsymbol{\beta}} = (\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{y}, \qquad \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1} \quad \text{(éq. (10) et (12))}.$$

Les deux exercices sont les deux cas du cours, avec seulement deux observations pour que tout se calcule à la main : l'exercice 1 est l'**hétéroscédasticité** (section 4), l'exercice 2 la **corrélation sérielle AR(1)** (section 6).

Table des matières

1 Exercice 1 : estimer une moyenne avec des variances différentes 1

2 Exercice 2 : erreurs AR(1) avec deux observations 4

1 Exercice 1 : estimer une moyenne avec des variances différentes

y_1, y_2 avec $y_i \sim N(\mu, \sigma_i^2)$, $\sigma_1^2 \neq \sigma_2^2$ en général. On suppose, comme pour tout échantillon, que y_1 et y_2 sont **indépendants**.

Lien avec le cours

C'est le modèle $y_i = \mu + \epsilon_i$ (régression sur une constante, $\mathbf{X} = \boldsymbol{\iota}$) avec des erreurs **hétéroscédastiques** : $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}'] = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}$, une matrice diagonale dont les éléments ne sont pas égaux (éq. (16) du cours). On compare les MCO (poids égaux) et les MCG (poids $1/\sigma_i^2$).

(a) L'estimateur MCO

Idée de la démarche

Minimiser la fonction par rapport à μ : dériver, égaler à zéro, résoudre.

On minimise $S(\mu) = \left(\frac{y_1 - \mu}{2}\right)^2 + \left(\frac{y_2 - \mu}{2}\right)^2 = \frac{1}{4}\big[(y_1 - \mu)^2 + (y_2 - \mu)^2\big]$.

Condition du premier ordre (dérivée de $(y_i - \mu)^2$ par rapport à μ : $-2(y_i - \mu)$) :

$$\frac{dS}{d\mu} = \frac{1}{4}\big[-2(y_1 - \mu) - 2(y_2 - \mu)\big] = -\frac{1}{2}(y_1 + y_2 - 2\mu) = 0 \quad \Longrightarrow \quad \hat{\mu} = \frac{y_1 + y_2}{2}.$$

Condition du second ordre : $\dfrac{d^2S}{d\mu^2} = \dfrac{1}{4}(2+2) = 1 > 0$: c'est bien un minimum.

Réponse

$\hat{\mu} = \dfrac{y_1 + y_2}{2} = \bar{y}$: la moyenne simple. Le facteur $\frac{1}{2}$ dans chaque terme est le *même* pour les deux observations : il ne change pas le point où le minimum est atteint. Les MCO donnent donc le même poids ($\frac{1}{2}$) à chaque observation, sans tenir compte de leur précision.

(b) $\hat{\mu}$ est sans biais ; sa variance

Biais.

$$\mathbb{E}[\hat{\mu}] = \frac{\mathbb{E}[y_1] + \mathbb{E}[y_2]}{2} = \frac{\mu + \mu}{2} = \mu.$$

Variance (indépendance : pas de covariance) :

$$\mathrm{Var}(\hat{\mu}) = \frac{1}{4}\big[\,\mathrm{Var}(y_1) + \mathrm{Var}(y_2)\big] = \frac{\sigma_1^2 + \sigma_2^2}{4}.$$

Réponse

$\hat{\mu}$ est **sans biais** et $\mathrm{Var}(\hat{\mu}) = \dfrac{\sigma_1^2 + \sigma_2^2}{4}$. Comme le dit le cours (section 2.1), les MCO restent sans biais en présence d'hétéroscédasticité : l'absence de biais n'utilise que $\mathbb{E}[\epsilon_i] = 0$.

(c) L'estimateur MCG

On minimise $S(\mu) = \left(\dfrac{y_1 - \mu}{\sigma_1}\right)^2 + \left(\dfrac{y_2 - \mu}{\sigma_2}\right)^2$.

Condition du premier ordre.

$$\frac{dS}{d\mu} = -\frac{2(y_1 - \mu)}{\sigma_1^2} - \frac{2(y_2 - \mu)}{\sigma_2^2} = 0 \iff \frac{y_1}{\sigma_1^2} + \frac{y_2}{\sigma_2^2} = \mu\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right).$$

On isole μ.

$$\tilde{\mu} = \frac{\dfrac{y_1}{\sigma_1^2} + \dfrac{y_2}{\sigma_2^2}}{\dfrac{1}{\sigma_1^2} + \dfrac{1}{\sigma_2^2}} = \frac{\sigma_2^2\, y_1 + \sigma_1^2\, y_2}{\sigma_1^2 + \sigma_2^2}$$

(on a multiplié numérateur et dénominateur par $\sigma_1^2\sigma_2^2$). Condition du second ordre : $\frac{d^2S}{d\mu^2} = \frac{2}{\sigma_1^2} + \frac{2}{\sigma_2^2} > 0$.

Réponse

$$\tilde{\mu} = w_1 y_1 + w_2 y_2, \qquad w_1 = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \frac{1/\sigma_1^2}{1/\sigma_1^2 + 1/\sigma_2^2}, \qquad w_2 = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} = \frac{1/\sigma_2^2}{1/\sigma_1^2 + 1/\sigma_2^2}.$$

C'est une **moyenne pondérée**, chaque observation étant pondérée par l'inverse de sa variance, c'est-à-dire par sa **précision**.

Vérification avec la formule matricielle du cours. Avec $\mathbf{X} = \boldsymbol{\iota} = (1,1)'$ et $\boldsymbol{\Omega} = \mathrm{diag}(\sigma_1^2, \sigma_2^2)$:

$$\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}, \qquad \boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\mathbf{y} = \frac{y_1}{\sigma_1^2} + \frac{y_2}{\sigma_2^2}, \qquad \tilde{\mu} = (\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota})^{-1}\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\mathbf{y} \ \checkmark$$

Et la matrice de transformation est $\mathbf{P} = \mathrm{diag}(1/\sigma_1,\, 1/\sigma_2)$ (cours, section 4.1) : diviser chaque observation par son écart-type. Le modèle transformé $y_i/\sigma_i = \mu\,(1/\sigma_i) + \epsilon_i/\sigma_i$ a des erreurs de variance 1 : il est homoscédastique, et ses MCO minimisent exactement le critère de (c).

(d) $\tilde{\mu}$ est sans biais ; sa variance

Biais. Les poids somment à 1 ($w_1 + w_2 = \frac{\sigma_2^2+\sigma_1^2}{\sigma_1^2+\sigma_2^2} = 1$), donc

$$\mathbb{E}[\tilde{\mu}] = w_1\mu + w_2\mu = (w_1 + w_2)\mu = \mu.$$

Variance.

$$\mathrm{Var}(\tilde{\mu}) = w_1^2\sigma_1^2 + w_2^2\sigma_2^2 = \frac{\sigma_2^4\sigma_1^2 + \sigma_1^4\sigma_2^2}{(\sigma_1^2+\sigma_2^2)^2} = \frac{\sigma_1^2\sigma_2^2(\sigma_2^2+\sigma_1^2)}{(\sigma_1^2+\sigma_2^2)^2} = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}.$$

Réponse

$\tilde{\mu}$ est **sans biais** et

$$\mathrm{Var}(\tilde{\mu}) = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2} = \frac{1}{\dfrac{1}{\sigma_1^2} + \dfrac{1}{\sigma_2^2}}.$$

C'est bien la formule du cours $(\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1} = (\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota})^{-1}$ (éq. (12)). Remarque : la précision de $\tilde{\mu}$ (l'inverse de sa variance) est la *somme* des précisions des deux observations.

(e) $\tilde{\mu}$ est plus efficace que $\hat{\mu}$

Idée de la démarche

Les deux estimateurs sont sans biais : le plus efficace est celui de plus petite variance. On calcule la différence des variances et on montre qu'elle est positive.

$$\mathrm{Var}(\hat{\mu}) - \mathrm{Var}(\tilde{\mu}) = \frac{\sigma_1^2+\sigma_2^2}{4} - \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2} = \frac{(\sigma_1^2+\sigma_2^2)^2 - 4\sigma_1^2\sigma_2^2}{4(\sigma_1^2+\sigma_2^2)}.$$

Le numérateur est une identité remarquable : $(a+b)^2 - 4ab = a^2 + 2ab + b^2 - 4ab = (a-b)^2$, avec $a = \sigma_1^2$ et $b = \sigma_2^2$. Donc

$$\mathrm{Var}(\hat{\mu}) - \mathrm{Var}(\tilde{\mu}) = \frac{(\sigma_1^2-\sigma_2^2)^2}{4(\sigma_1^2+\sigma_2^2)} \ \geq\ 0.$$

Réponse

$\mathrm{Var}(\tilde{\mu}) \leq \mathrm{Var}(\hat{\mu})$, avec égalité **si et seulement si** $\sigma_1^2 = \sigma_2^2$ (pas d'hétéroscédasticité : MCO et MCG coïncident, $w_1 = w_2 = \frac{1}{2}$). Dès que les variances diffèrent, $\tilde{\mu}$ est strictement plus efficace, et le gain est d'autant plus grand que les variances sont différentes.
Exemple : $\sigma_1^2 = 1$, $\sigma_2^2 = 9$.
— MCO : poids (0,5 ; 0,5), $\mathrm{Var}(\hat{\mu}) = 10/4 = 2{,}5$;
— MCG : poids (0,9 ; 0,1), $\mathrm{Var}(\tilde{\mu}) = 9/10 = 0{,}9$.
La variance des MCO est presque 3 fois plus grande. Elle est même plus grande que celle de y_1 tout seul (1) : en donnant autant de poids à l'observation très bruitée, les MCO font *pire* qu'en l'ignorant.

Intuition

Une observation de grande variance est peu fiable : il faut lui faire moins confiance. Les MCO traitent toutes les observations de la même façon ; les MCG donnent plus de poids aux observations précises. C'est le principe de la section 4.1 du cours : « diviser chaque observation par σ_i » rend les erreurs homoscédastiques et redonne aux MCO leur efficacité (Gauss-Markov s'applique au modèle transformé). En pratique, les σ_i^2 sont inconnus : on les estime par une fonction scédastique, ce sont les MCGE (sections 4.1–4.2).

2 Exercice 2 : erreurs AR(1) avec deux observations

$y_t = \beta_0 + \epsilon_t$, avec $\epsilon_t = \rho\epsilon_{t-1} + u_t$, $|\rho| < 1$, $u_t \sim iid(0, \sigma^2)$, et $\mathbb{E}(u_t \mid \epsilon_s) = 0$ pour les dates passées. On a $T = 2$ observations.

Lien avec le cours

C'est le modèle de la section 6 du cours avec $\mathbf{X} = \boldsymbol{\iota}$ (une constante seulement) et $T = 2$. Les questions reprennent, pas à pas, la construction de la matrice $\boldsymbol{\Omega}$ (éq. (37)) et de la transformation de Prais-Winsten (éq. (42)–(44)).

(a) La matrice $\boldsymbol{\Omega} = \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}']$

Idée de la démarche

Il faut trois quantités : $\mathrm{Var}(\epsilon_1)$, $\mathrm{Var}(\epsilon_2)$ et $\mathrm{Cov}(\epsilon_1, \epsilon_2)$. On utilise la stationnarité ($|\rho| < 1$) comme dans le cours (éq. (35)–(36)).

Variance. Le processus est stationnaire : $\mathrm{Var}(\epsilon_t)$ est la même à toutes les dates. En prenant la variance de $\epsilon_t = \rho\epsilon_{t-1} + u_t$ (u_t non corrélé avec ϵ_{t-1}) :

$$\mathrm{Var}(\epsilon_t) = \rho^2 \mathrm{Var}(\epsilon_{t-1}) + \sigma^2 \implies \sigma_\epsilon^2 = \rho^2\sigma_\epsilon^2 + \sigma^2 \implies \sigma_\epsilon^2 = \frac{\sigma^2}{1-\rho^2}.$$

(Même résultat que l'éq. (35) du cours, obtenu là par la somme géométrique $1+\rho^2+\rho^4+\cdots = \frac{1}{1-\rho^2}$.)

Covariance.

$$\mathrm{Cov}(\epsilon_1, \epsilon_2) = \mathbb{E}[\epsilon_1\epsilon_2] = \mathbb{E}[\epsilon_1(\rho\epsilon_1 + u_2)] = \rho\,\mathbb{E}[\epsilon_1^2] + \underbrace{\mathbb{E}[\epsilon_1 u_2]}_{0} = \rho\,\frac{\sigma^2}{1-\rho^2}.$$

($\mathbb{E}[\epsilon_1 u_2] = 0$ car $\mathbb{E}(u_2 \mid \epsilon_1) = 0$.)

Réponse

$$\boldsymbol{\Omega} = \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}'] = \begin{pmatrix} \mathbb{E}[\epsilon_1^2] & \mathbb{E}[\epsilon_1\epsilon_2] \\ \mathbb{E}[\epsilon_2\epsilon_1] & \mathbb{E}[\epsilon_2^2] \end{pmatrix} = \frac{\sigma^2}{1-\rho^2}\begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}.$$

C'est l'éq. (37) du cours avec $T = 2$. Les variances sont égales (pas d'hétéroscédasticité) ; c'est la covariance hors diagonale ($\rho \neq 0$) qui rend les erreurs non sphériques.

(b) La matrice P telle que $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$

Étape 1 : calculer $\boldsymbol{\Omega}^{-1}$. Pour une matrice 2×2, $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$. Ici $\begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}^{-1} = \frac{1}{1-\rho^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix}$, donc

$$\boldsymbol{\Omega}^{-1} = \frac{1-\rho^2}{\sigma^2} \cdot \frac{1}{1-\rho^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix} = \frac{1}{\sigma^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix}.$$

P ne peut pas être diagonale

L'énoncé demande une matrice « diagonale ». Or si $\mathbf{P} = \mathrm{diag}(p_1, p_2)$, alors $\mathbf{P}'\mathbf{P} = \mathrm{diag}(p_1^2, p_2^2)$ est diagonale, alors que $\boldsymbol{\Omega}^{-1}$ a des termes hors diagonale égaux à $-\rho/\sigma^2 \neq 0$. Aucune matrice diagonale ne convient (sauf si $\rho = 0$). Le cours le dit : $\mathbf{P}$ est **triangulaire** (section 3, éq. (6)). La matrice diagonale $\mathrm{diag}(1/\sigma_i)$ est celle du cas de l'hétéroscédasticité (exercice 1), pas celui de l'autocorrélation.

Étape 2 : proposer P (transformation de Prais-Winsten). D'après le cours (éq. (42)–(44)), la première observation est multipliée par $\sqrt{1-\rho^2}$ et la deuxième est quasi-différenciée ($y_2 - \rho y_1$). On divise en plus par σ pour obtenir une variance égale à 1 :

$$\mathbf{P} = \frac{1}{\sigma}\begin{pmatrix} \sqrt{1-\rho^2} & 0 \\ -\rho & 1 \end{pmatrix} \qquad \text{(triangulaire inférieure).}$$

Étape 3 : vérifier $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$.

$$\mathbf{P}'\mathbf{P} = \frac{1}{\sigma^2}\begin{pmatrix} \sqrt{1-\rho^2} & -\rho \\ 0 & 1 \end{pmatrix}\begin{pmatrix} \sqrt{1-\rho^2} & 0 \\ -\rho & 1 \end{pmatrix} = \frac{1}{\sigma^2}\begin{pmatrix} (1-\rho^2)+\rho^2 & -\rho \\ -\rho & 1 \end{pmatrix} = \frac{1}{\sigma^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix} = \boldsymbol{\Omega}^{-1} \ \checkmark$$

Réponse

$\mathbf{P} = \frac{1}{\sigma}\begin{pmatrix} \sqrt{1-\rho^2} & 0 \\ -\rho & 1 \end{pmatrix}$ vérifie $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$.

Variante : avec la normalisation du cours, $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}'] = \sigma^2\boldsymbol{\Omega}$ où $\boldsymbol{\Omega} = \frac{1}{1-\rho^2}\begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$, on prend $\mathbf{P} = \begin{pmatrix} \sqrt{1-\rho^2} & 0 \\ -\rho & 1 \end{pmatrix}$ (sans le $1/\sigma$) ; les erreurs transformées ont alors la variance σ^2 au lieu de 1. Les deux versions sont équivalentes pour l'estimation.

(c) Le modèle transformé a des erreurs indépendantes et homoscédastiques

Étape 1 : écrire le modèle transformé. Avec $\mathbf{y} = \boldsymbol{\iota}\beta_0 + \boldsymbol{\epsilon}$ (l'énoncé écrit $\mathbf{P}\beta_0$; il s'agit de $\mathbf{P}\boldsymbol{\iota}\,\beta_0$, le régresseur constant transformé) :

$$\mathbf{P}\mathbf{y} = \mathbf{P}\boldsymbol{\iota}\,\beta_0 + \mathbf{P}\boldsymbol{\epsilon} \iff \begin{cases} \dfrac{\sqrt{1-\rho^2}\,y_1}{\sigma} = \dfrac{\sqrt{1-\rho^2}}{\sigma}\,\beta_0 + \dfrac{\sqrt{1-\rho^2}\,\epsilon_1}{\sigma}, \\ \dfrac{y_2 - \rho y_1}{\sigma} = \dfrac{1-\rho}{\sigma}\,\beta_0 + \dfrac{\epsilon_2 - \rho\epsilon_1}{\sigma} = \dfrac{1-\rho}{\sigma}\,\beta_0 + \dfrac{u_2}{\sigma}. \end{cases}$$

La deuxième erreur transformée est u_2/σ, car $\epsilon_2 - \rho\epsilon_1 = u_2$ (définition de l'AR(1)).

Étape 2 : espérance. $\mathbb{E}[\mathbf{P}\boldsymbol{\epsilon}] = \mathbf{P}\,\mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0}$.

Étape 3 : variances (homoscédasticité).

$$\mathrm{Var}\left(\frac{\sqrt{1-\rho^2}\,\epsilon_1}{\sigma}\right) = \frac{1-\rho^2}{\sigma^2}\cdot\frac{\sigma^2}{1-\rho^2} = 1, \qquad \mathrm{Var}\left(\frac{u_2}{\sigma}\right) = \frac{\sigma^2}{\sigma^2} = 1.$$

Les deux erreurs ont la même variance : le facteur $\sqrt{1-\rho^2}$ sert exactement à ramener la variance de la première observation, $\sigma^2/(1-\rho^2)$, au niveau de celle des u_t (éq. (42) du cours).

Étape 4 : covariance (absence de corrélation).

$$\mathrm{Cov}\left(\frac{\sqrt{1-\rho^2}\,\epsilon_1}{\sigma}, \frac{u_2}{\sigma}\right) = \frac{\sqrt{1-\rho^2}}{\sigma^2}\,\mathbb{E}[\epsilon_1 u_2] = 0,$$

car $\mathbb{E}(u_2 \mid \epsilon_1) = 0$: le choc u_2 est « nouveau », sans lien avec l'erreur passée.

Étape 5 : en matrices (comme dans le cours).

$$\mathbb{E}[\mathbf{P}\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{P}'] = \mathbf{P}\,\boldsymbol{\Omega}\,\mathbf{P}' = \mathbf{P}(\mathbf{P}'\mathbf{P})^{-1}\mathbf{P}' = \mathbf{P}\mathbf{P}^{-1}(\mathbf{P}')^{-1}\mathbf{P}' = \mathbf{I}_2.$$

Réponse

Les erreurs transformées $\mathbf{P}\boldsymbol{\epsilon} = (\sqrt{1-\rho^2}\,\epsilon_1/\sigma,\ u_2/\sigma)'$ ont une espérance nulle, une même variance (1) et une covariance nulle : $\mathbb{E}[\mathbf{P}\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{P}'] = \mathbf{I}_2$. Elles sont donc **homoscédastiques et non corrélées** ; elles sont même **indépendantes**, car ϵ_1 ne dépend que des chocs passés $u_1, u_0, u_{-1}, \ldots$ (éq. (34) du cours) et u_2 est indépendant de ces chocs (u_t i.i.d.). Le modèle transformé satisfait les hypothèses du modèle classique : les MCO appliqués à $\mathbf{P}\mathbf{y} = \mathbf{P}\boldsymbol{\iota}\beta_0 + \mathbf{P}\boldsymbol{\epsilon}$ donnent l'estimateur MCG, qui est efficace.

Intuition

La quasi-différence $y_2 - \rho y_1$ retire de y_2 la partie de son erreur qui est « héritée » de la période précédente ($\rho\epsilon_1$) : il ne reste que le choc nouveau u_2. La première observation n'a pas de passé dans l'échantillon ; on la garde, mais on la « réduit » par $\sqrt{1-\rho^2}$ pour qu'elle ait la même variance que les autres. C'est la différence entre Prais-Winsten (qui garde la première observation ainsi transformée) et Cochrane-Orcutt (qui la supprime et perd de l'information ; section 6.7 du cours).

Pour aller plus loin : l'estimateur MCG de β_0

Avec $\mathbf{X} = \boldsymbol{\iota}$ et $\boldsymbol{\Omega}^{-1} = \frac{1}{\sigma^2}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix}$:

$$\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota} = \frac{2-2\rho}{\sigma^2}, \qquad \boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\mathbf{y} = \frac{(1-\rho)(y_1+y_2)}{\sigma^2}, \qquad \tilde{\beta}_0 = (\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota})^{-1}\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\mathbf{y} = \frac{y_1+y_2}{2}.$$

Avec seulement deux observations, la situation est symétrique (y_1 et y_2 jouent le même rôle), et l'estimateur MCG coïncide avec la moyenne simple des MCO. Sa variance est

$$\mathrm{Var}(\tilde{\beta}_0) = (\boldsymbol{\iota}'\boldsymbol{\Omega}^{-1}\boldsymbol{\iota})^{-1} = \frac{\sigma^2}{2(1-\rho)}$$

(ici $\boldsymbol{\Omega} = \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}']$ contient déjà le facteur de variance, donc pas de σ^2 devant). Vérification directe : $\mathrm{Var}\left(\frac{\epsilon_1+\epsilon_2}{2}\right) = \frac{1}{4}(2\sigma_\epsilon^2 + 2\rho\sigma_\epsilon^2) = \frac{(1+\rho)\sigma^2}{2(1-\rho^2)} = \frac{\sigma^2}{2(1-\rho)}$ ✓.

Le vrai problème des MCO ici : leur écart-type. La formule usuelle des MCO, $\sigma_\epsilon^2(\boldsymbol{\iota}'\boldsymbol{\iota})^{-1} = \sigma_\epsilon^2/2$, ignore la covariance. La vraie variance est $\sigma_\epsilon^2(1+\rho)/2$: si $\rho > 0$, les MCO **sous-estiment** la variance de $\hat{\beta}_0$ (d'un facteur $1+\rho$), et les tests t rejettent trop souvent. C'est exactement le message de la section 2.2 du cours : avec des erreurs non sphériques, la variance estimée par MCO est biaisée, d'où les corrections MCG, Newey-West, etc.