Les MCG sont plus efficaces que les MCO

Démonstration pas à pas (chapitre 7, section 3.1 : « laissée comme exercice »)

Le point de départ (cours, section 3.1)

Modèle : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$, $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}] = \sigma^2\boldsymbol{\Omega}$, avec $\boldsymbol{\Omega}$ symétrique et définie positive.

$$\mathrm{Var}(\mathbf{b} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\boldsymbol{\Omega}\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1} \quad \text{(MCO)}, \qquad \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1} \quad \text{(MCG)}.$$

Il faut montrer que $\mathrm{Var}(\mathbf{b} \mid \mathbf{X}) - \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})$ est semi-définie positive. Le cours propose de passer par les inverses :

$$\mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})^{-1} - \mathrm{Var}(\mathbf{b} \mid \mathbf{X})^{-1} = \frac{1}{\sigma^2}\,\mathbf{D}, \qquad \mathbf{D} = \mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X} - (\mathbf{X}'\mathbf{X})(\mathbf{X}'\boldsymbol{\Omega}\mathbf{X})^{-1}(\mathbf{X}'\mathbf{X}).$$

L'inverse de $\mathrm{Var}(\mathbf{b})$ s'obtient avec $(\mathbf{ABC})^{-1} = \mathbf{C}^{-1}\mathbf{B}^{-1}\mathbf{A}^{-1}$:

$$\mathrm{Var}(\mathbf{b} \mid \mathbf{X})^{-1} = \frac{1}{\sigma^2}(\mathbf{X}'\mathbf{X})(\mathbf{X}'\boldsymbol{\Omega}\mathbf{X})^{-1}(\mathbf{X}'\mathbf{X}).$$

Idée de la démonstration

Réécrire $\mathbf{D}$ sous la forme $\mathbf{X}^{*\prime}\,\mathbf{M}_W\,\mathbf{X}^*$, où $\mathbf{M}_W$ est une **matrice de projection** (symétrique, idempotente) du type $\mathbf{M}$ du chapitre 2. Une telle forme est toujours semi-définie positive, car elle s'écrit comme un « carré » : $(\mathbf{M}_W\mathbf{X}^*)'(\mathbf{M}_W\mathbf{X}^*)$. C'est la même astuce que dans la preuve de Gauss-Markov.

Étape 1 : la matrice P du cours

$\boldsymbol{\Omega}$ étant symétrique et définie positive, il existe une matrice $\mathbf{P}$ $(n \times n)$ inversible telle que (cours, éq. (6)–(8)) :

$$\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1} \qquad \text{et} \qquad \boldsymbol{\Omega} = (\mathbf{P}'\mathbf{P})^{-1} = \mathbf{P}^{-1}(\mathbf{P}')^{-1}.$$

Étape 2 : deux matrices transformées

On définit

$$\mathbf{X}^* = \mathbf{PX} \qquad \text{(les régresseurs transformés « MCG »)}, \qquad \mathbf{W} = (\mathbf{P}')^{-1}\mathbf{X}.$$

Ce sont deux matrices $n \times K$.

Étape 3 : réécrire les trois blocs de D

Le premier terme.

$$\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X} = \mathbf{X}'\mathbf{P}'\mathbf{PX} = (\mathbf{PX})'(\mathbf{PX}) = \mathbf{X}^{*\prime}\mathbf{X}^*.$$

Le terme du milieu. Comme $(\mathbf{P}^{-1})' = (\mathbf{P}')^{-1}$, on a $\mathbf{X}'\mathbf{P}^{-1} = \big((\mathbf{P}')^{-1}\mathbf{X}\big)' = \mathbf{W}'$, donc

$$\mathbf{X}'\boldsymbol{\Omega}\mathbf{X} = \mathbf{X}'\mathbf{P}^{-1}(\mathbf{P}')^{-1}\mathbf{X} = \big((\mathbf{P}')^{-1}\mathbf{X}\big)'\big((\mathbf{P}')^{-1}\mathbf{X}\big) = \mathbf{W}'\mathbf{W}.$$

Le terme $\mathbf{X}'\mathbf{X}$. On insère $\mathbf{P}'(\mathbf{P}')^{-1} = \mathbf{I}_n$ au milieu :

$$\mathbf{X}'\mathbf{X} = \mathbf{X}'\,\mathbf{P}'(\mathbf{P}')^{-1}\,\mathbf{X} = (\mathbf{P}\mathbf{X})'((\mathbf{P}')^{-1}\mathbf{X}) = \mathbf{X}^{*\prime}\mathbf{W}, \qquad \text{et en transposant :} \qquad \mathbf{X}'\mathbf{X} = \mathbf{W}'\mathbf{X}^*.$$

Résultat de l'étape

$$\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X} = \mathbf{X}^{*\prime}\mathbf{X}^*, \qquad \mathbf{X}'\boldsymbol{\Omega}\mathbf{X} = \mathbf{W}'\mathbf{W}, \qquad \mathbf{X}'\mathbf{X} = \mathbf{X}^{*\prime}\mathbf{W} = \mathbf{W}'\mathbf{X}^*.$$

Étape 4 : faire apparaître une matrice de projection

On remplace dans $\mathbf{D}$:

$$\begin{aligned}\mathbf{D} &= \mathbf{X}^{*\prime}\mathbf{X}^* - \mathbf{X}^{*\prime}\mathbf{W}\,(\mathbf{W}'\mathbf{W})^{-1}\,\mathbf{W}'\mathbf{X}^* \\ &= \mathbf{X}^{*\prime}\Big[\mathbf{I}_n - \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\Big]\mathbf{X}^* \\ &= \mathbf{X}^{*\prime}\,\mathbf{M}_W\,\mathbf{X}^*,\end{aligned}$$

où $\mathbf{M}_W = \mathbf{I}_n - \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'$ est la matrice qui crée les résidus d'une régression sur $\mathbf{W}$ (la matrice $\mathbf{M}$ du chapitre 2, avec $\mathbf{W}$ à la place de $\mathbf{X}$). ($\mathbf{W}'\mathbf{W} = \mathbf{X}'\boldsymbol{\Omega}\mathbf{X}$ est bien inversible : $\boldsymbol{\Omega}$ est définie positive et $\mathbf{X}$ de plein rang.)

$\mathbf{M}_W$ est **symétrique** ($\mathbf{M}_W' = \mathbf{M}_W$) et **idempotente** ($\mathbf{M}_W\mathbf{M}_W = \mathbf{M}_W$). Donc

$$\mathbf{D} = \mathbf{X}^{*\prime}\mathbf{M}_W\mathbf{M}_W\mathbf{X}^* = \mathbf{X}^{*\prime}\mathbf{M}_W'\mathbf{M}_W\mathbf{X}^* = (\mathbf{M}_W\mathbf{X}^*)'(\mathbf{M}_W\mathbf{X}^*).$$

Pour tout vecteur $\mathbf{c} \in \mathbb{R}^K$:

$$\mathbf{c}'\mathbf{D}\mathbf{c} = (\mathbf{M}_W\mathbf{X}^*\mathbf{c})'(\mathbf{M}_W\mathbf{X}^*\mathbf{c}) = \left\|\mathbf{M}_W\mathbf{X}^*\mathbf{c}\right\|^2 \;\geq\; 0.$$

Résultat de l'étape

$\mathbf{D} = (\mathbf{M}_W\mathbf{X}^*)'(\mathbf{M}_W\mathbf{X}^*)$ est **semi-définie positive**. Donc $\mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})^{-1} - \mathrm{Var}(\mathbf{b} \mid \mathbf{X})^{-1} = \mathbf{D}/\sigma^2$ est semi-définie positive.

Étape 5 : passer des inverses aux variances

On utilise un résultat d'algèbre matricielle (Greene, annexe A) :

Si $\mathbf{A}$ et $\mathbf{B}$ sont symétriques définies positives, alors

$$\mathbf{A} - \mathbf{B} \text{ semi-définie positive} \quad\Longleftrightarrow\quad \mathbf{B}^{-1} - \mathbf{A}^{-1} \text{ semi-définie positive.}$$

C'est l'analogue matriciel de : si $a \geq b > 0$, alors $\frac{1}{b} \geq \frac{1}{a}$.

Avec $\mathbf{A} = \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})^{-1}$ et $\mathbf{B} = \mathrm{Var}(\mathbf{b} \mid \mathbf{X})^{-1}$: on vient de montrer que $\mathbf{A} - \mathbf{B}$ est semi-définie positive, donc $\mathbf{B}^{-1} - \mathbf{A}^{-1} = \mathrm{Var}(\mathbf{b} \mid \mathbf{X}) - \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})$ l'est aussi.

Conclusion

$$\mathrm{Var}(\mathbf{b} \mid \mathbf{X}) - \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) \quad \text{est semi-définie positive.}$$

Chaque coefficient, et plus généralement toute combinaison linéaire $\mathbf{c}'\boldsymbol{\beta}$, est estimé avec une variance au moins aussi petite par les MCG que par les MCO : $\mathrm{Var}(\mathbf{c}'\tilde{\boldsymbol{\beta}}) \leq \mathrm{Var}(\mathbf{c}'\mathbf{b})$. **Les MCG sont plus efficaces que les MCO.** ■

Remarques

« Définie » ou « semi-définie » positive ?

Le cours écrit « positive définie », mais en général la différence est seulement **semi-définie** positive. Elle est nulle quand $\mathbf{M}_W\mathbf{X}^* = \mathbf{0}$, et alors MCO et MCG coïncident. C'est le cas :

- si $\boldsymbol{\Omega} = \mathbf{I}_n$ (erreurs sphériques) ;
- dans l'exercice 1 du chapitre, si $\sigma_1^2 = \sigma_2^2$;
- dans l'exercice 2 avec deux observations : les MCG donnent la moyenne simple, comme les MCO.

Preuve plus courte, par Gauss-Markov. Dans le modèle transformé $\mathbf{Py} = \mathbf{PX}\boldsymbol{\beta} + \mathbf{P}\boldsymbol{\epsilon}$, les erreurs sont sphériques : $\mathbb{E}[\mathbf{P}\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{P}' \mid \mathbf{X}] = \sigma^2\mathbf{I}_n$ (cours, éq. (9)). Le théorème de Gauss-Markov s'applique donc à ce modèle, et son estimateur MCO est $\tilde{\boldsymbol{\beta}}$ (éq. (10)). Or l'estimateur des MCO du modèle d'origine s'écrit

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}^{-1}(\mathbf{Py}) :$$

il est *linéaire* en $\mathbf{Py}$ et *sans biais*. Par Gauss-Markov, $\mathrm{Var}(\mathbf{b} \mid \mathbf{X}) \geq \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X})$. La démonstration en 5 étapes ci-dessus fait ce calcul explicitement, sans invoquer le théorème.

Intuition

Les MCO donnent le même poids à toutes les observations, même aux plus bruitées (hétéroscédasticité) ou aux plus redondantes (autocorrélation : deux observations corrélées apportent moins d'information que deux observations indépendantes). Les MCG pondèrent chaque observation par l'information qu'elle apporte réellement, à travers $\boldsymbol{\Omega}^{-1}$. Exemple de l'exercice 1 avec $\sigma_1^2 = 1$ et $\sigma_2^2 = 9$: poids (0,9 ; 0,1) pour les MCG au lieu de (0,5 ; 0,5), et une variance de 0,9 au lieu de 2,5.