Chapitre 7 – Erreurs non sphériques

La fiche simple

1. L'idée

Jusqu'ici on supposait $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}] = \sigma^2\mathbf{I}$: toutes les erreurs ont la **même variance** et ne sont **pas corrélées** entre elles (erreurs « sphériques »). Deux problèmes peuvent casser cette hypothèse :

- **Hétéroscédasticité** : la variance change d'une observation à l'autre (σ_i^2).
- **Autocorrélation** : les erreurs sont corrélées entre elles (souvent dans le temps).

On écrit alors $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}] = \sigma^2\boldsymbol{\Omega}$.

Conséquences pour les MCO : toujours **sans biais**, mais **inefficaces**, et l'écart-type affiché par le logiciel est **faux**, donc les tests t et F habituels aussi.

Deux solutions : (1) les **MCG** : transformer le modèle pour retrouver des erreurs sphériques ; (2) garder les MCO mais utiliser des **écarts-types robustes** (White, Newey-West, clusters).

2. Les outils

MCO avec erreurs non sphériques

Sans biais : $\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta}$ (il suffit que $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$).
Vraie variance : $\mathrm{Var}(\mathbf{b} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \neq \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$

MCG : l'estimateur efficace (si Ω est connue)

Idée : trouver $\mathbf{P}$ telle que $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$, puis appliquer les MCO à $\mathbf{Py} = \mathbf{PX}\boldsymbol{\beta} + \mathbf{P}\boldsymbol{\epsilon}$ (erreurs redevenues sphériques).

$$\tilde{\boldsymbol{\beta}} = (\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{y}, \qquad \mathrm{Var}(\tilde{\boldsymbol{\beta}} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}$$

Sans biais et plus efficace que les MCO (démonstration en section 3).

Hétéroscédasticité : les MCGE

Transformation : $\mathbf{P} = \mathrm{diag}(1/\sigma_1, \ldots, 1/\sigma_n)$, c'est-à-dire diviser chaque observation par son écart-type.
Comme σ_i est inconnu (3 étapes) : (1) MCO, garder les résidus e_i ; (2) estimer la fonction scédastique, par ex. $\ln e_i^2 = \gamma_0 + \gamma_1 x_{1i} + \ldots$; (3) diviser chaque observation par $\hat{\sigma}_i = \sqrt{\exp(\hat{\gamma}_0 + \hat{\gamma}_1 x_{1i} + \ldots)}$ et refaire les MCO.

Hétéroscédasticité : écarts-types robustes de White

Idée : garder les MCO, corriger seulement la variance.

$$\widehat{\mathrm{Var}}(\mathbf{b}) = (\mathbf{X}'\mathbf{X})^{-1}\Big(\sum_i e_i^2\,\mathbf{x}_i\mathbf{x}_i'\Big)(\mathbf{X}'\mathbf{X})^{-1}$$

On s'en sert pour les tests t ; pour plusieurs restrictions $R\boldsymbol{\beta} = q$, on utilise le test de Wald : $W = (R\mathbf{b} - q)'\big[R\,\widehat{\mathrm{Var}}(\mathbf{b})\,R'\big]^{-1}(R\mathbf{b} - q) \sim \chi^2(J)$.

Tests d'hétéroscédasticité

Principe : régresser e_i^2 (résidus MCO au carré) sur des variables explicatives. Si elles expliquent e_i^2, la variance n'est pas constante.
White : e_i^2 sur les x, leurs carrés et leurs produits ; $nR^2 \sim \chi^2(P-1)$.
Breusch-Pagan : même idée avec $e_i^2/\hat{\sigma}^2 - 1$; $LM \sim \chi^2(P)$.
Règle : $p < 0{,}05 \Rightarrow$ on rejette l'homoscédasticité.

Autocorrélation AR(1) : $\epsilon_t = \rho\epsilon_{t-1} + u_t$, $|\rho| < 1$

$$\mathrm{Var}(\epsilon_t) = \frac{\sigma_u^2}{1-\rho^2}, \qquad \mathrm{Cov}(\epsilon_t, \epsilon_{t-s}) = \rho^s\,\frac{\sigma_u^2}{1-\rho^2}$$

En mots : la corrélation diminue quand les dates s'éloignent ($\rho^s \to 0$).

AR(1) : la transformation MCG (Prais-Winsten)

$$y_t^* = y_t - \rho y_{t-1}, \quad x_t^* = x_t - \rho x_{t-1} \;\; (t \geq 2); \qquad y_1^* = \sqrt{1-\rho^2}\,y_1, \quad x_1^* = \sqrt{1-\rho^2}\,x_1$$

L'erreur transformée est u_t (sans autocorrélation). Cochrane-Orcutt fait la même chose mais **supprime** la 1re observation. ρ inconnu : on l'estime par la régression $e_t = \rho e_{t-1} + \eta_t$, puis on transforme (et on peut répéter).

Tests d'autocorrélation

Breusch-Godfrey : régresser e_t sur x_t et e_{t-1} ; tester le coefficient de e_{t-1} (t ou $nR^2 \sim \chi^2(1)$).

Durbin-Watson : $d = \dfrac{\sum_{t=2}^{T}(e_t - e_{t-1})^2}{\sum_t e_t^2} \approx 2(1-r)$ (r : corrélation entre e_t et e_{t-1}).

$d \approx 2$: pas d'autocorrélation ; d proche de 0 : autocorrélation positive. Rejet si $d < d_L$, non-rejet si $d > d_U$, zone indéterminée entre les deux. Pas valable si y_{t-1} est un régresseur.

Écarts-types robustes : Newey-West et clusters

Newey-West : comme White, mais on ajoute les covariances des erreurs jusqu'à L périodes (en pratique $L \approx T^{1/4}$). Robuste à l'hétéroscédasticité *et* à l'autocorrélation. Stata : `newey y x, lag(L)`.
Clusters : les erreurs sont corrélées *à l'intérieur* d'un groupe (classe, entreprise, ville) mais pas entre groupes :

$$\widehat{\mathrm{Var}}(\mathbf{b}) = (\mathbf{X}'\mathbf{X})^{-1}\Big(\sum_{g=1}^{G} \hat{\mathbf{s}}_g \hat{\mathbf{s}}_g'\Big)(\mathbf{X}'\mathbf{X})^{-1}, \qquad \hat{\mathbf{s}}_g = \mathbf{X}_g'\mathbf{e}_g$$

Règle pratique : regrouper au niveau le plus large (l'établissement plutôt que la classe), ou au niveau du traitement.

3. Les formules développées (le cours ne les démontre pas)

(a) Pourquoi les MCG sont plus efficaces que les MCO

On veut montrer que $\mathrm{Var}(\tilde{\boldsymbol{\beta}})^{-1} - \mathrm{Var}(\mathbf{b})^{-1} = \frac{1}{\sigma^2}\mathbf{D}$ est positive, avec $\mathbf{D} = \mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X} - (\mathbf{X}'\mathbf{X})(\mathbf{X}'\boldsymbol{\Omega}\mathbf{X})^{-1}(\mathbf{X}'\mathbf{X})$.
Étape 1. Avec $\mathbf{P}'\mathbf{P} = \boldsymbol{\Omega}^{-1}$ (donc $\boldsymbol{\Omega} = \mathbf{P}^{-1}\mathbf{P}'^{-1}$), poser $\mathbf{X}^* = \mathbf{P}\mathbf{X}$ et $\mathbf{W} = \mathbf{P}'^{-1}\mathbf{X}$.
Étape 2. Réécrire les trois morceaux :

$$\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X} = \mathbf{X}^{*\prime}\mathbf{X}^*, \qquad \mathbf{X}'\boldsymbol{\Omega}\mathbf{X} = \mathbf{W}'\mathbf{W}, \qquad \mathbf{X}'\mathbf{X} = \mathbf{X}'\mathbf{P}'\mathbf{P}'^{-1}\mathbf{X} = \mathbf{X}^{*\prime}\mathbf{W}.$$

Étape 3. Remplacer :

$$\mathbf{D} = \mathbf{X}^{*\prime}\mathbf{X}^* - \mathbf{X}^{*\prime}\mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'\mathbf{X}^* = \mathbf{X}^{*\prime}\,\mathbf{M}_W\,\mathbf{X}^* = (\mathbf{M}_W\mathbf{X}^*)'(\mathbf{M}_W\mathbf{X}^*) \;\geq 0,$$

car $\mathbf{M}_W = \mathbf{I} - \mathbf{W}(\mathbf{W}'\mathbf{W})^{-1}\mathbf{W}'$ est symétrique et idempotente (comme la matrice $\mathbf{M}$ du chapitre 2).
Étape 4. Si $A^{-1} - B^{-1} \geq 0$ alors $B - A \geq 0$ (comme pour les nombres : si $1/a \geq 1/b > 0$, alors $b \geq a$). Donc $\mathrm{Var}(\mathbf{b}) - \mathrm{Var}(\tilde{\boldsymbol{\beta}}) \geq 0$: les MCG sont plus efficaces.

(b) Pourquoi $d \approx 2(1-r)$ (Durbin-Watson)

On développe le carré au numérateur :

$$\sum_{t=2}^{T}(e_t - e_{t-1})^2 = \sum_{t=2}^{T} e_t^2 + \sum_{t=2}^{T} e_{t-1}^2 - 2\sum_{t=2}^{T} e_t e_{t-1}.$$

Les deux premières sommes sont presque égales à $\sum_t e_t^2$ (il ne manque qu'un terme à chacune). En divisant par $\sum_t e_t^2$:

$$d \approx 1 + 1 - 2\,\underbrace{\frac{\sum e_t e_{t-1}}{\sum e_t^2}}_{r} = 2(1-r).$$

Lecture : $r = 0 \Rightarrow d = 2$; $r \to 1 \Rightarrow d \to 0$; $r \to -1 \Rightarrow d \to 4$.

(c) Pourquoi e_i^2 marche dans la formule de White

La vraie variance contient $\mathbf{X'\Sigma X} = \sum_i \sigma_i^2 \mathbf{x}_i\mathbf{x}_i'$, avec $\sigma_i^2 = \mathbb{E}[\epsilon_i^2 \mid \mathbf{x}_i]$. On ne connaît pas σ_i^2, mais e_i^2 en est une estimation (bruitée) observation par observation. Chaque e_i^2 est imprécis, mais leur **moyenne pondérée** $\frac{1}{n}\sum e_i^2\mathbf{x}_i\mathbf{x}_i'$ converge vers $\frac{1}{n}\sum \sigma_i^2\mathbf{x}_i\mathbf{x}_i'$ (loi des grands nombres). C'est pourquoi la correction de White est valable en **grand échantillon**.

(d) y_{t-1} régresseur + erreurs AR(1) : MCO non convergents

Modèle : $y_t = \alpha y_{t-1} + \epsilon_t,\ \ \epsilon_t = \rho\epsilon_{t-1} + u_t$. Notons $c = \mathrm{Cov}(y_t, \epsilon_t)$ (stationnaire).
Étape 1. $\mathrm{Cov}(y_{t-1}, \epsilon_t) = \mathrm{Cov}(y_{t-1}, \rho\epsilon_{t-1} + u_t) = \rho\,\mathrm{Cov}(y_{t-1}, \epsilon_{t-1}) = \rho c$ (u_t est un choc nouveau).

Étape 2. $c = \mathrm{Cov}(\alpha y_{t-1} + \epsilon_t,\ \epsilon_t) = \alpha\rho c + \sigma_\epsilon^2$, donc $c = \dfrac{\sigma_\epsilon^2}{1-\alpha\rho}$.

Conclusion. $\mathrm{Cov}(y_{t-1}, \epsilon_t) = \dfrac{\rho\,\sigma_\epsilon^2}{1-\alpha\rho} \neq 0$ dès que $\rho \neq 0$: le régresseur est corrélé avec l'erreur, donc les MCO sont biaisés **et non convergents**. Solution : variables instrumentales (par ex. z_{t-1} comme instrument de y_{t-1}).

4. Les 5 choses à retenir

1. Erreurs non sphériques : MCO **sans biais** mais **inefficaces**, et leurs écarts-types sont **faux**.
2. MCG : transformer le modèle avec $\mathbf{P}$ ($\mathbf{P'P} = \mathbf{\Omega}^{-1}$) puis faire les MCO. Hétéroscédasticité : diviser par σ_i. AR(1) : quasi-différences $y_t - \rho y_{t-1}$.
3. $\mathbf{\Omega}$ inconnue : soit on l'estime (MCGE), soit on garde les MCO avec des écarts-types robustes (White, Newey-West, clusters).
4. Détecter : tests de White ou de Breusch-Pagan pour l'hétéroscédasticité ; tests de Breusch-Godfrey ou Durbin-Watson ($d \approx 2$ = pas d'autocorrélation) pour l'AR(1).
5. Attention : y_{t-1} comme régresseur + erreurs autocorrélées $\Rightarrow$ MCO biaisés et non convergents.