

ECN-7025 Économétrie I – Devoir 1

Solutions détaillées, démarche pas à pas et explications

Chapitre 2 (MCO) – Greene, ch. 3 et 4

Comment lire ce document

Pour chaque question : **l'idée de la démarche** (quoi faire et pourquoi), puis la **démonstration ou le calcul complet**, puis la **réponse** encadrée et, quand c'est utile, une **intuition**. Les numéros « $[n]$ » renvoient aux équations des notes du chapitre 2.

Codes fournis : `stata/devoir1.do` (questions 3 et 4). Les résultats numériques présentés ici ont été calculés en Python (voir la note en début des questions 3 et 4) ; à reproduire avec le do-file sur vos propres fichiers avant de remettre le devoir.

Table des matières

1	Question 1 (25 points)	2
1.1	(a)(i) Changement de base des régresseurs : $\tilde{\mathbf{b}} = \mathbf{A}^{-1}\mathbf{b}$	2
1.2	(a)(ii) Salaire mesuré en cents au lieu de dollars	2
1.3	(b) Même somme des carrés des résidus pour (3) et (4)	3
1.4	(c) Erreur de moyenne conditionnelle non nulle	4
2	Question 2 (25 points)	5
2.1	(a) Les deux estimateurs sont sans biais	6
2.2	(b) b_{MCO} est efficace par rapport à b_{MOM}	6
2.3	(c) Intuition	7
3	Question 3 (20 points) – Étude de Monte Carlo	8
3.1	(a) Modèle correct : les MCO sont-ils sans biais ?	8
3.2	(b) Inclusion d'une variable non pertinente x_2	8
3.3	(c) Test de $H_0 : \beta_2 = 0$ à chaque répétition	9
4	Question 4 (30 points) – Rendement de l'éducation	10
4.1	(a) Régression de base et interprétation	10
4.2	(b) Moyenne des résidus	11
4.3	(c) Test $H_0 : \beta_{educ} = 0,07$ par un test t	11
4.4	(d) Reparamétrisation	12
4.5	(e) Différence de salaire constante entre le Sud et ailleurs	12
4.6	(f) Marchés du travail identiques ? Test de Chow	13
	Annexe – Code Stata	14

1 Question 1 (25 points)

1.1 (a)(i) Changement de base des régresseurs : $\tilde{\mathbf{b}} = \mathbf{A}^{-1}\mathbf{b}$

Idée de la démarche

On écrit la formule des MCO pour le modèle transformé, $\tilde{\mathbf{b}} = (\tilde{\mathbf{X}}'\tilde{\mathbf{X}})^{-1}\tilde{\mathbf{X}}'\mathbf{y}$, on remplace $\tilde{\mathbf{X}}$ par $\mathbf{XA}$, puis on utilise deux règles d'algèbre : $(\mathbf{XA})' = \mathbf{A}'\mathbf{X}'$ et l'inverse d'un produit de matrices carrées inversibles, $(\mathbf{BCD})^{-1} = \mathbf{D}^{-1}\mathbf{C}^{-1}\mathbf{B}^{-1}$.

Hypothèses utilisées. $\mathbf{X}$ ($n \times k$) est de plein rang colonne, donc $\mathbf{X}'\mathbf{X}$ ($k \times k$) est inversible et $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ existe. $\mathbf{A}$ ($k \times k$) est non singulière, donc $\mathbf{A}^{-1}$ et $(\mathbf{A}')^{-1} = (\mathbf{A}^{-1})'$ existent.

Étape 1 : $\tilde{\mathbf{X}}$ est aussi de plein rang, donc $\tilde{\mathbf{b}}$ existe. Si $\tilde{\mathbf{X}}\mathbf{v} = \mathbf{X}(\mathbf{A}\mathbf{v}) = \mathbf{0}$, le plein rang de $\mathbf{X}$ donne $\mathbf{A}\mathbf{v} = \mathbf{0}$, et comme $\mathbf{A}$ est inversible, $\mathbf{v} = \mathbf{0}$.

Étape 2 : calcul.

$$\begin{aligned}
 \tilde{\mathbf{b}} &= (\tilde{\mathbf{X}}'\tilde{\mathbf{X}})^{-1}\tilde{\mathbf{X}}'\mathbf{y} \\
 &= ((\mathbf{XA})'(\mathbf{XA}))^{-1}(\mathbf{XA})'\mathbf{y} && \text{définition de } \tilde{\mathbf{X}} \\
 &= (\mathbf{A}'(\mathbf{X}'\mathbf{X})\mathbf{A})^{-1}\mathbf{A}'\mathbf{X}'\mathbf{y} && (\mathbf{XA})' = \mathbf{A}'\mathbf{X}' \\
 &= \mathbf{A}^{-1}(\mathbf{X}'\mathbf{X})^{-1}(\mathbf{A}')^{-1}\mathbf{A}'\mathbf{X}'\mathbf{y} && \text{inverse d'un produit de 3 matrices } k \times k \text{ inversibles} \\
 &= \mathbf{A}^{-1}(\mathbf{X}'\mathbf{X})^{-1}\underbrace{(\mathbf{A}')^{-1}\mathbf{A}'}_{=\mathbf{I}_k}\mathbf{X}'\mathbf{y} \\
 &= \mathbf{A}^{-1}\underbrace{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}}_{=\mathbf{b}} = \mathbf{A}^{-1}\mathbf{b}.
 \end{aligned}$$

Réponse

$$\tilde{\mathbf{b}} = \mathbf{A}^{-1}\mathbf{b}. \quad \blacksquare$$

Conséquences utiles (à mentionner pour la partie (ii)).

- Valeurs prédites et résidus inchangés : $\tilde{\mathbf{X}}\tilde{\mathbf{b}} = \mathbf{XAA}^{-1}\mathbf{b} = \mathbf{Xb} = \hat{\mathbf{y}}$, donc $\tilde{\mathbf{e}} = \mathbf{e}$, même SCE, même s^2 , même R^2 .
- Variance : $\widehat{\text{Var}}(\tilde{\mathbf{b}}) = s^2(\tilde{\mathbf{X}}'\tilde{\mathbf{X}})^{-1} = s^2\mathbf{A}^{-1}(\mathbf{X}'\mathbf{X})^{-1}(\mathbf{A}^{-1})' = \mathbf{A}^{-1}\widehat{\text{Var}}(\mathbf{b})(\mathbf{A}^{-1})'$.

Intuition

$\tilde{\mathbf{X}} = \mathbf{XA}$ a exactement les mêmes colonnes « en combinaisons linéaires » que $\mathbf{X}$: l'espace engendré par les colonnes est le même. Or les MCO projettent $\mathbf{y}$ sur cet espace ($\hat{\mathbf{y}} = \mathbf{Py}$) ; la projection ne change donc pas, seule la façon d'écrire $\hat{\mathbf{y}}$ comme combinaison des colonnes change. Les coefficients s'ajustent pour compenser : c'est $\mathbf{A}^{-1}$.

1.2 (a)(ii) Salaire mesuré en cents au lieu de dollars

Idée de la démarche

Passer de dollars à cents revient à multiplier la colonne x par 100 sans toucher à la constante. C'est un cas particulier de $\tilde{\mathbf{X}} = \mathbf{XA}$ avec une matrice $\mathbf{A}$ diagonale. On applique (i).

Ici $\mathbf{X} = [\mathbf{1} \quad \mathbf{x}]$ ($n \times 2$) et la nouvelle variable est $x_i^c = 100 x_i$. Donc

$$\tilde{\mathbf{X}} = [\mathbf{1} \quad 100\mathbf{x}] = [\mathbf{1} \quad \mathbf{x}] \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 100 \end{pmatrix}}_{\mathbf{A}}, \quad \mathbf{A}^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 1/100 \end{pmatrix}.$$

Par (i) :

$$\begin{pmatrix} \tilde{b}_0 \\ \tilde{b}_1 \end{pmatrix} = \mathbf{A}^{-1} \begin{pmatrix} b_0 \\ b_1 \end{pmatrix} = \begin{pmatrix} b_0 \\ b_1/100 \end{pmatrix}.$$

Réponse

- **Pente** : $\tilde{b}_1 = b_1/100$. Si b_1 = variation des heures hebdomadaires pour une hausse du salaire horaire de 1 \$, alors $\tilde{b}_1$ = variation pour une hausse de 1 cent, qui est 100 fois plus petite. Exemple : $b_1 = 0,5$ heure par dollar devient $\tilde{b}_1 = 0,005$ heure par cent. **L'effet économique est identique** ; seule l'unité change.
- **Constante** : inchangée ($\tilde{b}_0 = b_0$), car la colonne de 1 n'est pas modifiée ; un salaire nul vaut 0 en dollars comme en cents.
- **Écart-type** : $\widehat{\text{Var}}(\tilde{\mathbf{b}}) = \mathbf{A}^{-1} \widehat{\text{Var}}(\mathbf{b}) \mathbf{A}^{-1}$ donne e.t. ($\tilde{b}_1$) = e.t. (b_1)/100. Donc **la statistique** t ($\tilde{b}_1/\text{e.t.}(\tilde{b}_1) = b_1/\text{e.t.}(b_1)$), la p -value, les résidus et le R^2 sont **inchangés**.

Moralité : les unités de mesure n'affectent ni l'ajustement ni l'inférence ; elles changent seulement l'échelle (la lecture) des coefficients.

Attention

Si l'on changeait plutôt l'unité de y (heures $\rightarrow$ minutes, facteur 60), *tous* les coefficients seraient multipliés par 60. Et si x entraînait en logarithme, $\ln(100x) = \ln 100 + \ln x$: la pente ne changerait pas mais la constante oui. On le reverra à la question 4 : `lwage` est en log, donc l'unité du salaire (dollars ou cents) n'affecte que la constante.

1.3 (b) Même somme des carrés des résidus pour (3) et (4)

Modèles : (3) $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\gamma} + \boldsymbol{\epsilon}$, (4) $\mathbf{M}_Z\mathbf{y} = \mathbf{M}_Z\mathbf{X}\boldsymbol{\beta} + \tilde{\boldsymbol{\epsilon}}$, avec $\mathbf{M}_Z = \mathbf{I}_n - \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$.

Idée de la démarche

On montre plus fort que demandé : **les vecteurs de résidus sont identiques**. L'égalité de la somme (et de la somme des carrés) des résidus en découle immédiatement. Trois ingrédients :

1. les équations normales de (3) ;
2. le théorème de Frisch-Waugh-Lovell (FWL), qu'on redémontre : le $\mathbf{b}$ de (3) est égal au $\mathbf{b}$ de (4) ;
3. les résidus de (3) sont orthogonaux à $\mathbf{Z}$, donc $\mathbf{M}_Z$ ne les modifie pas.

Notation et hypothèse. On suppose $\mathbf{W} = [\mathbf{X} \quad \mathbf{Z}]$ de plein rang colonne. Soient $(\mathbf{b}, \mathbf{c})$ les estimateurs MCO de (3) et $\mathbf{e} = \mathbf{y} - \mathbf{X}\mathbf{b} - \mathbf{Z}\mathbf{c}$ ses résidus. Soient $\tilde{\mathbf{b}}$ l'estimateur MCO de (4) et $\tilde{\mathbf{e}} = \mathbf{M}_Z\mathbf{y} - \mathbf{M}_Z\mathbf{X}\tilde{\mathbf{b}}$ ses résidus.

Rappel : propriétés de $\mathbf{M}_Z$. Symétrique ($\mathbf{M}_Z' = \mathbf{M}_Z$), idempotente ($\mathbf{M}_Z\mathbf{M}_Z = \mathbf{M}_Z$), et $\mathbf{M}_Z\mathbf{Z} = \mathbf{0}$ (démontré dans les notes, §2.2).

Étape 1 : l'estimateur MCO de (4). Par la formule générale appliquée aux données transformées,

$$\tilde{\mathbf{b}} = ((\mathbf{M}_Z\mathbf{X})'(\mathbf{M}_Z\mathbf{X}))^{-1}(\mathbf{M}_Z\mathbf{X})'(\mathbf{M}_Z\mathbf{y}) = (\mathbf{X}'\mathbf{M}_Z'\mathbf{M}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{M}_Z'\mathbf{M}_Z\mathbf{y} = (\mathbf{X}'\mathbf{M}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{M}_Z\mathbf{y}.$$

Il existe car $\mathbf{X}'\mathbf{M}_Z\mathbf{X}$ est inversible. En effet, si $\mathbf{M}_Z\mathbf{X}\mathbf{v} = \mathbf{0}$, alors $\mathbf{X}\mathbf{v} = \mathbf{P}_Z\mathbf{X}\mathbf{v} = \mathbf{Z}\mathbf{d}$ avec $\mathbf{d} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X}\mathbf{v}$. Donc $\mathbf{X}\mathbf{v} - \mathbf{Z}\mathbf{d} = \mathbf{0}$, et le plein rang de $\mathbf{W}$ impose $\mathbf{v} = \mathbf{0}$.

Étape 2 : les équations normales de (3). Elles s'écrivent $\mathbf{W}'\mathbf{e} = \mathbf{0}$, c'est-à-dire

$$\mathbf{X}'\mathbf{e} = \mathbf{0} \iff \mathbf{X}'\mathbf{X}\mathbf{b} + \mathbf{X}'\mathbf{Z}\mathbf{c} = \mathbf{X}'\mathbf{y}, \quad (\text{N1})$$

$$\mathbf{Z}'\mathbf{e} = \mathbf{0} \iff \mathbf{Z}'\mathbf{X}\mathbf{b} + \mathbf{Z}'\mathbf{Z}\mathbf{c} = \mathbf{Z}'\mathbf{y}. \quad (\text{N2})$$

Étape 3 : FWL, $\mathbf{b} = \tilde{\mathbf{b}}$. De (N2) : $\mathbf{c} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'(\mathbf{y} - \mathbf{X}\mathbf{b})$. On substitue dans (N1) :

$$\mathbf{X}'\mathbf{X}\mathbf{b} + \underbrace{\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'}_{\mathbf{P}_Z}(\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{X}'\mathbf{y}$$

$$\iff \mathbf{X}'(\mathbf{I} - \mathbf{P}_Z)\mathbf{X}\mathbf{b} = \mathbf{X}'(\mathbf{I} - \mathbf{P}_Z)\mathbf{y} \iff \mathbf{X}'\mathbf{M}_Z\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{M}_Z\mathbf{y}.$$

Donc $\mathbf{b} = (\mathbf{X}'\mathbf{M}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{M}_Z\mathbf{y} = \tilde{\mathbf{b}}$.

Étape 4 : $\mathbf{M}_Z\mathbf{e} = \mathbf{e}$. Par (N2), $\mathbf{Z}'\mathbf{e} = \mathbf{0}$, donc $\mathbf{P}_Z\mathbf{e} = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{e} = \mathbf{0}$ et $\mathbf{M}_Z\mathbf{e} = \mathbf{e} - \mathbf{P}_Z\mathbf{e} = \mathbf{e}$.

Étape 5 : conclusion. On prémultiplie la décomposition $\mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{Z}\mathbf{c} + \mathbf{e}$ par $\mathbf{M}_Z$:

$$\mathbf{M}_Z\mathbf{y} = \mathbf{M}_Z\mathbf{X}\mathbf{b} + \underbrace{\mathbf{M}_Z\mathbf{Z}\mathbf{c}}_{\mathbf{0}} + \underbrace{\mathbf{M}_Z\mathbf{e}}_{\mathbf{e}} \implies \mathbf{e} = \mathbf{M}_Z\mathbf{y} - \mathbf{M}_Z\mathbf{X}\mathbf{b} = \mathbf{M}_Z\mathbf{y} - \mathbf{M}_Z\mathbf{X}\tilde{\mathbf{b}} = \tilde{\mathbf{e}} \quad (\text{étape 3}).$$

Réponse

Les résidus des deux régressions sont **le même vecteur** : $\mathbf{e} = \tilde{\mathbf{e}}$. Par conséquent

$$\mathbf{e}'\mathbf{e} = \tilde{\mathbf{e}}'\tilde{\mathbf{e}} \quad \text{et aussi} \quad \sum_i e_i = \sum_i \tilde{e}_i.$$

Les sommes des carrés des résidus MCO de (3) et de (4) sont égales. ■

Intuition

$\mathbf{M}_Z$ « nettoie » $\mathbf{y}$ et $\mathbf{X}$ de tout ce que $\mathbf{Z}$ explique. Une fois $\mathbf{Z}$ retiré des deux côtés, il ne reste plus rien que $\mathbf{Z}$ puisse expliquer : l'inclure explicitement (modèle 3) ou l'avoir retiré au préalable (modèle 4) laisse exactement la même partie inexpliquée de $\mathbf{y}$.

Attention

Les SCE sont égales, mais pas les *degrés de liberté*. Le logiciel divise la SCE par $n - k$ pour (4) alors qu'il faut diviser par $n - k - m$ (où m est le nombre de colonnes de $\mathbf{Z}$), comme pour (3). Les écarts-types affichés pour la régression (4) sont donc un peu trop petits ; il faut les multiplier par $\sqrt{(n - k)/(n - k - m)}$.

1.4 (c) Erreur de moyenne conditionnelle non nulle

Modèle $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ avec $\mathbb{E}[\epsilon_i | x_i] = \alpha_0 + \alpha_1 x_i$.

Idée de la démarche

Deux méthodes équivalentes : (1) réécrire le modèle avec une nouvelle erreur de moyenne conditionnelle nulle ; (2) calculer directement $\mathbb{E}[\mathbf{b} | \mathbf{X}]$ avec la décomposition $\mathbf{b} = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}$ du cours [79].

Méthode 1 : réécriture. Posons $u_i = \epsilon_i - \mathbb{E}[\epsilon_i \mid x_i] = \epsilon_i - \alpha_0 - \alpha_1 x_i$. Par construction, $\mathbb{E}[u_i \mid x_i] = 0$. Alors

$$y_i = \beta_0 + \beta_1 x_i + \alpha_0 + \alpha_1 x_i + u_i = \underbrace{(\beta_0 + \alpha_0)}_{\gamma_0} + \underbrace{(\beta_1 + \alpha_1)}_{\gamma_1} x_i + u_i.$$

Ce modèle satisfait l'hypothèse d'exogénéité, donc les MCO estiment sans biais γ_0 et γ_1 .

Méthode 2 : calcul direct (avec un échantillon aléatoire, $\mathbb{E}[\epsilon_i \mid x_1, \dots, x_n] = \mathbb{E}[\epsilon_i \mid x_i]$). Le vecteur $\mathbb{E}[\epsilon \mid \mathbf{X}]$ a pour i -ème composante $\alpha_0 + \alpha_1 x_i = \mathbf{x}_i' \boldsymbol{\alpha}$, avec $\boldsymbol{\alpha} = (\alpha_0, \alpha_1)'$: donc $\mathbb{E}[\epsilon \mid \mathbf{X}] = \mathbf{X}\boldsymbol{\alpha}$. Alors

$$\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\epsilon \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\alpha} = \boldsymbol{\beta} + \boldsymbol{\alpha}.$$

Réponse

$$\gamma_0 = \beta_0 + \alpha_0, \quad \gamma_1 = \beta_1 + \alpha_1.$$

Les MCO sont biaisés pour β_0 (biais α_0) et pour β_1 (biais α_1), mais sans biais pour γ_0 et γ_1 .

Intuition

- α_0 **est inoffensif** : une erreur de moyenne constante non nulle est simplement absorbée par la constante. C'est pourquoi l'hypothèse $\mathbb{E}[\epsilon] = 0$ n'est qu'une *normalisation* quand le modèle contient une constante (voir question 4(b)).
- α_1 **est le vrai problème** : si l'erreur varie systématiquement avec x , les MCO attribuent à x l'effet de ce qui est caché dans l'erreur. Exemple : dans une équation de salaire, si l'habileté (dans ϵ) augmente avec l'éducation, alors $\alpha_1 > 0$ et les MCO surestiment le rendement de l'éducation. C'est le biais de variable omise (exercice 7 du document d'explications du chapitre 2).

2 Question 2 (25 points)

Modèle **sans constante** : $y_i = \beta x_i + \epsilon_i$, avec $\mathbb{E}[\epsilon_i \mid x_i] = 0$, $\mathbb{E}[\epsilon_i \epsilon_j \mid x_i] = 0$ ($i \neq j$) et $\text{Var}(\epsilon_i \mid x_i) = \sigma^2$.

$$b_{MCO} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}, \quad b_{MOM} = \frac{\widehat{\text{Cov}}(Y, X)}{\widehat{\text{Var}}(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

(Les facteurs $1/n$ ou $1/(n-1)$ de la covariance et de la variance empiriques s'annulent dans le rapport.)

Conventions. Comme dans le cours, on raisonne conditionnellement à toutes les x (notées $\mathbf{X}$), avec un échantillon aléatoire, de sorte que $\mathbb{E}[\epsilon_i \mid \mathbf{X}] = 0$, $\text{Var}(\epsilon_i \mid \mathbf{X}) = \sigma^2$ et $\text{Cov}(\epsilon_i, \epsilon_j \mid \mathbf{X}) = 0$. On suppose que x varie dans l'échantillon : $\sum (x_i - \bar{x})^2 > 0$.

Deux identités utiles (car $\sum (x_i - \bar{x}) = 0$) :

$$(I1) \quad \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i, \quad (I2) \quad \sum_{i=1}^n (x_i - \bar{x})x_i = \sum_{i=1}^n (x_i - \bar{x})^2.$$

Preuve de (I1) : $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum (x_i - \bar{x})y_i - \bar{y} \sum (x_i - \bar{x}) = \sum (x_i - \bar{x})y_i$. (I2) : même argument avec x à la place de y .

2.1 (a) Les deux estimateurs sont sans biais

Idée de la démarche

Comme en [79] : on remplace y_i par $\beta x_i + \epsilon_i$ pour écrire chaque estimateur sous la forme « β + combinaison linéaire des erreurs », puis on prend l'espérance conditionnelle.

b_{MCO} .

$$b_{MCO} = \frac{\sum x_i(\beta x_i + \epsilon_i)}{\sum x_i^2} = \beta \frac{\sum x_i^2}{\sum x_i^2} + \frac{\sum x_i \epsilon_i}{\sum x_i^2} = \beta + \sum_{i=1}^n w_i \epsilon_i, \quad w_i = \frac{x_i}{\sum_j x_j^2}.$$

Les poids w_i ne dépendent que des x , donc $\mathbb{E}[b_{MCO} | \mathbf{X}] = \beta + \sum w_i \mathbb{E}[\epsilon_i | \mathbf{X}] = \beta + 0 = \beta$.

b_{MOM} . Par (I1), puis (I2) :

$$b_{MOM} = \frac{\sum (x_i - \bar{x})y_i}{\sum (x_i - \bar{x})^2} = \frac{\beta \sum (x_i - \bar{x})x_i + \sum (x_i - \bar{x})\epsilon_i}{\sum (x_i - \bar{x})^2} = \beta + \sum_{i=1}^n k_i \epsilon_i, \quad k_i = \frac{x_i - \bar{x}}{\sum_j (x_j - \bar{x})^2}.$$

D'où $\mathbb{E}[b_{MOM} | \mathbf{X}] = \beta + \sum k_i \mathbb{E}[\epsilon_i | \mathbf{X}] = \beta$.

Réponse

$\mathbb{E}[b_{MCO} | \mathbf{X}] = \mathbb{E}[b_{MOM} | \mathbf{X}] = \beta$. Par la loi des espérances itérées, $\mathbb{E}[b_{MCO}] = \mathbb{E}[b_{MOM}] = \beta$: les deux estimateurs sont sans biais.

Attention

Le point subtil de b_{MOM} est le terme en $\bar{y}$: il disparaît grâce à (I1). Sans cette identité, on pourrait croire que $\bar{y}$ (qui contient $\bar{\epsilon}$) pose problème. Autre remarque : b_{MOM} est sans biais ici *même si* le vrai modèle avait une constante, ce qui n'est pas le cas de b_{MCO} (voir (c)).

2.2 (b) b_{MCO} est efficace par rapport à b_{MOM}

Idée de la démarche

« Efficace relativement » signifie : tous deux sont sans biais et $\text{Var}(b_{MCO} | \mathbf{X}) \leq \text{Var}(b_{MOM} | \mathbf{X})$. On calcule les deux variances à partir des écritures « $\beta + \sum(\text{poids})\epsilon_i$ », puis on les compare grâce à la décomposition $\sum x_i^2 = \sum (x_i - \bar{x})^2 + n\bar{x}^2$.

Variance d'une combinaison linéaire des erreurs. Pour des poids a_i fonctions des x :

$$\text{Var}\left(\sum a_i \epsilon_i \mid \mathbf{X}\right) = \sum_i a_i^2 \underbrace{\text{Var}(\epsilon_i \mid \mathbf{X})}_{\sigma^2} + \sum_{i \neq j} a_i a_j \underbrace{\text{Cov}(\epsilon_i, \epsilon_j \mid \mathbf{X})}_0 = \sigma^2 \sum_i a_i^2.$$

(On utilise l'homoscédasticité et l'absence de corrélation entre les erreurs.)

Application.

$$\begin{aligned} \text{Var}(b_{MCO} | \mathbf{X}) &= \sigma^2 \sum_i \frac{x_i^2}{(\sum_j x_j^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}, \\ \text{Var}(b_{MOM} | \mathbf{X}) &= \sigma^2 \sum_i \frac{(x_i - \bar{x})^2}{(\sum_j (x_j - \bar{x})^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

Comparaison. Développons :

$$\sum_{i=1}^n x_i^2 = \sum_{i=1}^n ((x_i - \bar{x}) + \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2\bar{x} \underbrace{\sum_{i=1}^n (x_i - \bar{x})}_0 + n\bar{x}^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n\bar{x}^2.$$

Donc $\sum x_i^2 \geq \sum (x_i - \bar{x})^2$, et en passant à l'inverse :

$$\text{Var}(b_{MCO} | \mathbf{X}) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2 + n\bar{x}^2} \leq \frac{\sigma^2}{\sum (x_i - \bar{x})^2} = \text{Var}(b_{MOM} | \mathbf{X}),$$

avec inégalité **stricte** dès que $\bar{x} \neq 0$.

Réponse

Les deux estimateurs sont sans biais et $\text{Var}(b_{MCO} | \mathbf{X}) \leq \text{Var}(b_{MOM} | \mathbf{X})$: b_{MCO} est efficace par rapport à b_{MOM} . Le rapport des variances vaut

$$\frac{\text{Var}(b_{MOM} | \mathbf{X})}{\text{Var}(b_{MCO} | \mathbf{X})} = \frac{\sum x_i^2}{\sum (x_i - \bar{x})^2} = 1 + \frac{\bar{x}^2}{\hat{\sigma}_x^2}, \quad \hat{\sigma}_x^2 = \frac{1}{n} \sum (x_i - \bar{x})^2.$$

Exemple : si $\bar{x} = 2$ et $\hat{\sigma}_x = 1$, la variance de b_{MOM} est **5 fois** plus grande. Il faudrait 5 fois plus d'observations pour atteindre la même précision.

Autre démonstration (via Gauss-Markov). $b_{MOM} = \sum k_i y_i$ est *linéaire* en y , et on a montré en (a) qu'il est sans biais. Les hypothèses de Gauss-Markov sont vérifiées (le modèle est $\mathbf{y} = \mathbf{X}\beta + \epsilon$ avec $\mathbf{X} = \mathbf{x}$, sans constante), et $b_{MCO} = (\mathbf{x}'\mathbf{x})^{-1}\mathbf{x}'\mathbf{y}$ est l'estimateur MCO de ce modèle. Le théorème garantit donc $\text{Var}(b_{MCO} | \mathbf{X}) \leq \text{Var}(b_{MOM} | \mathbf{X})$. En reprenant la notation du cours, $D = k - w$ et $\text{Var}(b_{MOM}) = \text{Var}(b_{MCO}) + \sigma^2 \sum (k_i - w_i)^2$.

2.3 (c) Intuition

Intuition

- b_{MOM} **n'utilise pas une information que l'on possède.** b_{MOM} est exactement la pente MCO d'une régression de y sur une constante *et* x (formule [16]). Il estime donc une constante alors que le modèle dit qu'elle vaut zéro : la droite doit passer par l'origine. Estimer un paramètre inutile coûte de la précision (même phénomène que la variable non pertinente de la question 3(b)).
- **Il n'utilise qu'une partie de la variation de x .** b_{MOM} n'exploite que la variation de x *autour de sa moyenne*, $\sum (x_i - \bar{x})^2$. b_{MCO} exploite la variation *autour de zéro*, $\sum x_i^2 = \sum (x_i - \bar{x})^2 + n\bar{x}^2$. Le terme $n\bar{x}^2$ est l'information supplémentaire : quand x est loin de 0, le point $(0, 0)$, connu grâce au modèle, joue le rôle d'une observation très informative qui « ancre » la droite. La précision croît avec la variation de la variable explicative ($\text{Var}(b) = \sigma^2 / \text{variation de } x$).
- **Cas limite.** Si $\bar{x} = 0$, les deux estimateurs sont identiques (même numérateur et même dénominateur), donc également efficaces.
- **Mais il y a un compromis.** L'efficacité de b_{MCO} repose sur l'hypothèse « pas de constante ». Si en réalité $y_i = \beta_0 + \beta x_i + \epsilon_i$ avec $\beta_0 \neq 0$, alors b_{MCO} est biaisé ($\mathbb{E}[b_{MCO}] = \beta + \beta_0 \sum x_i / \sum x_i^2$), tandis que b_{MOM} reste sans biais. C'est pourquoi, en pratique, on inclut presque toujours une constante.

3 Question 3 (20 points) – Étude de Monte Carlo

Note sur les chiffres

Les résultats ci-dessous proviennent d'une réplique exacte du protocole en Python (script `q3_simulation.py`, graine 1234). **Stata utilise un autre générateur de nombres aléatoires** : avec `set seed 1234`, le do-file `stata/devoir1.do` donnera des chiffres légèrement différents (aux décimales près), mais **les conclusions sont les mêmes**. Dans votre copie, reportez les chiffres produits par *votre* programme.

Protocole commun. Paramètres $(\beta_0, \beta_1, \sigma^2) = (2, 1, 1)$; graine 1234 ; $n = 250$; $R = 1000$ répétitions.

1. Générer une seule fois $x_{1i} \sim N(0, 1)$ puis, pour (b), $x_{2i} = 0,5x_{1i} + \eta_i$ avec $\eta_i \sim N(0, 1)$. Ces x restent **fixes** d'une répétition à l'autre : on étudie les propriétés conditionnelles à $\mathbf{X}$, comme dans le cours.
2. À chaque répétition : tirer $\epsilon_i \sim N(0, 1)$, construire $y_i = 2 + x_{1i} + \epsilon_i$, puis estimer **sur le même échantillon** le modèle correct (y sur x_1) et le modèle surspécifié (y sur x_1, x_2). Sauvegarder les coefficients, les écarts-types et le résultat du test de $\beta_2 = 0$.

Estimer les deux modèles sur le même y permet une comparaison « toutes choses égales par ailleurs » : les écarts ne viennent que de l'inclusion de x_2 .

3.1 (a) Modèle correct : les MCO sont-ils sans biais ?

	Vraie val.	Moyenne (1000 rép.)	É.-t. empir.	É.-t. théor.	Test : moy. = vraie val.
b_0	2	2,0005	0,0656	0,0634	$t = 0,26, p = 0,79$
b_1	1	1,0007	0,0620	0,0603	$t = 0,34, p = 0,74$

L'écart-type théorique est $\sigma \sqrt{[(\mathbf{X}'\mathbf{X})^{-1}]_{kk}}$, calculé avec les x fixés. La moyenne des écarts-types estimés par la régression (0,0634 et 0,0603) coïncide avec la valeur théorique.

Comment juger l'absence de biais ? La moyenne des R estimations est elle-même une estimation de $\mathbb{E}[b_1]$. Son erreur-type (l'« erreur de simulation ») vaut $0,0620/\sqrt{1000} \approx 0,002$. L'écart observé, $1,0007 - 1 = 0,0007$, est bien plus petit : il s'explique entièrement par le hasard de la simulation. Formellement, le test t de $H_0 : \mathbb{E}[b_1] = 1$ sur les 1000 valeurs donne $p = 0,74$: on ne rejette pas.

Réponse

Oui. Les moyennes de b_0 et b_1 sont statistiquement indiscernables de 2 et de 1. C'est ce que prédit la théorie : sous $\mathbb{E}[\epsilon | \mathbf{X}] = \mathbf{0}$, $\mathbb{E}[\mathbf{b} | \mathbf{X}] = \boldsymbol{\beta}$ [80]. Chaque estimation individuelle varie pourtant (de 0,75 à 1,21 pour b_1) : « sans biais » décrit la moyenne sur des échantillons répétés, pas un échantillon particulier.

3.2 (b) Inclusion d'une variable non pertinente x_2

Modèle estimé : $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \epsilon_i$, alors que y est généré avec $\beta_2 = 0$. Dans notre tirage, $\widehat{\text{corr}}(x_1, x_2) = 0,54$ (valeur théorique $0,5/\sqrt{1,25} \approx 0,45$).

	Vraie valeur	Moyenne	É.-t. empirique	É.-t. empirique du modèle correct
b_0	2	2,0006	0,0657	0,0656
b_1	1	1,0016	0,0745	0,0620
b_2	0	-0,0016	0,0661	—

Tests d'absence de biais : $b_0 : p = 0,77$; $b_1 : p = 0,49$.

Pourquoi l'absence de biais est conservée (théorie). Le modèle avec x_2 est *correctement spécifié* : c'est le vrai modèle, avec $\beta_2 = 0$. L'hypothèse $\mathbb{E}[\epsilon | x_1, x_2] = 0$ est vérifiée, car ϵ est tiré indépendamment de x_1 et x_2 . Donc $\mathbb{E}[\mathbf{b} | \mathbf{X}] = \beta = (2, 1, 0)'$: b_0 , b_1 et b_2 sont sans biais.

Le coût : une variance plus grande. Par FWL, $\text{Var}(b_1 | \mathbf{X}) = \sigma^2 / [\sum (x_{1i} - \bar{x}_1)^2 (1 - R_{12}^2)]$, où R_{12}^2 est le R^2 de la régression de x_1 sur x_2 . Comme x_1 et x_2 sont corrélés, b_1 ne peut utiliser que la partie de x_1 non expliquée par x_2 : on « jette » de la variation utile. Ici $1/(1 - 0,54^2) = 1,41$. La simulation donne un rapport des variances de $(0,0745/0,0620)^2 = 1,44$, très proche. L'écart-type de b_1 augmente d'environ 20 %. En revanche, b_0 est à peine affecté, car x_2 est de moyenne proche de 0.

Réponse

Oui, b_0 et b_1 restent sans biais : inclure une variable non pertinente ne crée pas de biais, puisque le modèle reste correctement spécifié ($\beta_2 = 0$ et $\mathbb{E}[\epsilon | x_1, x_2] = 0$). La conséquence est une **perte d'efficacité** : la variance de b_1 est environ 1,4 fois plus grande, parce que x_2 est corrélée avec x_1 . Les MCO du modèle surspécifié ne sont plus « les meilleurs » : le modèle correct fournit un estimateur linéaire sans biais de variance plus petite.

À contraster avec l'*omission* d'une variable pertinente, qui crée un biais (question 1(c)). Inclure une variable inutile coûte de la précision ; omettre une variable utile coûte du biais.

3.3 (c) Test de $H_0 : \beta_2 = 0$ à chaque répétition

À chaque répétition : $t = b_2/\text{e.t.}(b_2)$. On rejette H_0 si $|t| > t_{0,975;247} = 1,970$, ou de manière équivalente si $p < 0,05$.




FIGURE 1 – Gauche : b_1 reste centré sur 1 mais est plus dispersé avec x_2 . Centre : les 1000 statistiques t de $H_0 : \beta_2 = 0$ suivent la loi de Student à 247 degrés de liberté ; les zones de rejet sont au-delà des lignes rouges. Droite : les p -values sont uniformes sur $[0, 1]$, donc environ 5 % tombent sous 0,05.

Résultat. On rejette H_0 dans **54 répétitions sur 1000, soit 5,4 %**.

Réponse

Non, on n'« accepte » pas H_0 à chaque répétition, bien que H_0 soit *vraie* par construction. On la rejette dans 5,4 % des cas, soit environ $\alpha = 5\%$.

Explication. Le niveau de signification α est, par définition, la probabilité de rejeter H_0 lorsqu'elle est vraie : c'est la probabilité d'une **erreur de type I**. Sous H_0 (et avec des erreurs normales), $t = b_2/\text{e.t.}(b_2)$ suit exactement une loi de Student à $n - 3$ degrés de liberté. Il tombe donc dans la zone de rejet $|t| > 1,970$ avec une probabilité d'exactement 5 %. Sur 1000 répétitions, on s'attend à environ 50 rejets « à tort ».

Le 5,4 % est-il compatible avec 5 % ? Le nombre de rejets suit une loi binomiale (1000; 0,05), dont l'écart-type de la proportion vaut $\sqrt{0,05 \times 0,95/1000} = 0,0069$. L'intervalle $0,05 \pm 1,96 \times 0,0069 = [3,6\%; 6,4\%]$ contient 5,4 %. Le test a donc bien la « taille » annoncée.

Terminologie. On dit « on ne rejette pas H_0 » plutôt que « on accepte H_0 » : ne pas rejeter ne prouve pas que H_0 est vraie.

4 Question 4 (30 points) – Rendement de l'éducation

Note sur les données

Le fichier `assign2School.raw` n'était pas joint ; seul le dictionnaire l'était. Ses 34 variables (`id nearc2 nearc4 educ age ... lwage expersq`) sont, dans le même ordre, celles du fichier **CARD** de Wooldridge (données de D. Card, 1995, sur 3010 hommes de la *National Longitudinal Survey of Young Men*, salaires de 1976). Les résultats ci-dessous ont été calculés sur ce fichier ($n = 3010$). **Relancez le do-file sur votre fichier** : si c'est bien le même, vous obtiendrez exactement ces chiffres.

Lecture des données dans Stata : `infile using dictionary.raw, using(assign2School.raw) clear`

4.1 (a) Régression de base et interprétation

lwage	Coefficient	É.-t.	t	p
educ	0,09317	0,00361	25,80	0,000
exper	0,04066	0,00233	17,42	0,000
constante	4,66604	0,06379	73,15	0,000
$n = 3010, R^2 = 0,181, SCE = 485,18, s = 0,4017$				

Comment interpréter un coefficient quand y est en logarithme. Dans $\ln w = \beta_0 + \beta_1 educ + \beta_2 exper + \epsilon$, on a $\partial \ln w / \partial educ = \beta_1$. Une variation de Δ du log correspond à une variation relative d'environ $100\Delta\%$ (car $\ln(1 + g) \approx g$ pour g petit). La variation exacte est $100(e^\Delta - 1)\%$.

Réponse

- **Éducation** : à *expérience égale*, une année de scolarité supplémentaire est associée à un salaire plus élevé d'environ **9,3 %** (exactement $e^{0,0932} - 1 = 9,8\%$). C'est le « rendement de l'éducation » au sens de Mincer.
- **Expérience** : à *éducation égale*, une année d'expérience supplémentaire est associée à un salaire plus élevé d'environ **4,1 %** (exactement 4,15 %).
- « À ... égale » est essentiel : par FWL, b_{educ} ne mesure que la relation entre le salaire et la partie de l'éducation non expliquée par l'expérience.
- Les deux coefficients sont très significatifs ($t = 25,8$ et $17,4$).
- **Prudence causale** : il s'agit d'une association. Si l'habileté (dans ϵ) est corrélée à l'éducation, $\mathbb{E}[\epsilon \mid educ] \neq 0$ et b_{educ} est biaisé, probablement vers le haut (question 1(c)). C'est pour traiter ce problème que Card utilise la proximité d'un collègue (`nearc4`) comme instrument.
- L'unité du salaire (dollars ou cents) n'affecte que la constante, car $\ln(100w) = \ln 100 + \ln w$; voir la question 1(a).

4.2 (b) Moyenne des résidus

Résultat : $\bar{e} = -1,5 \times 10^{-15}$, c'est-à-dire **zéro** à la précision de l'ordinateur près.

Réponse

La moyenne des résidus est nulle, mais **ce n'est pas informatif** sur la moyenne des erreurs dans la population.

- C'est une **propriété numérique** des MCO. La régression contient une constante, et la première équation normale ($\mathbf{1}'\mathbf{e} = 0$) impose $\sum e_i = 0$ *par construction*, quelles que soient les données et que le modèle soit bon ou mauvais (propriété 2 des notes, [26]).
- Les résidus sont des *estimations* des erreurs, calculées *de façon* à sommer à zéro. Ils ne peuvent donc pas nous renseigner sur $\mathbb{E}[\epsilon]$ ni sur $\mathbb{E}[\epsilon \mid educ, exper]$.
- De plus, comme montré en 1(c), une moyenne non nulle des erreurs (α_0) serait absorbée par la constante : $\mathbb{E}[\epsilon] = 0$ est une *normalisation*, non testable. Ce qui compte pour l'absence de biais, c'est $\mathbb{E}[\epsilon \mid \mathbf{X}]$ ne dépendant pas de $\mathbf{X}$, et cela ne se vérifie pas avec les résidus (ils sont aussi orthogonaux à *educ* et *exper* par construction : $\mathbf{X}'\mathbf{e} = \mathbf{0}$).

4.3 (c) Test $H_0 : \beta_{educ} = 0,07$ par un test t

Démarche.

1. Hypothèses : $H_0 : \beta_{educ} = 0,07$ contre $H_a : \beta_{educ} \neq 0,07$ (test bilatéral), au seuil $\alpha = 5\%$.
2. Statistique : $t = \frac{b_{educ} - 0,07}{\text{e.t.}(b_{educ})}$, qui suit sous H_0 une loi de Student à $n - k = 3010 - 3 = 3007$ degrés de liberté.
3. Calcul : $t = \frac{0,093168 - 0,07}{0,003612} = \frac{0,023168}{0,003612} = \mathbf{6,41}$.
4. Valeur critique : $t_{0,975; 3007} = 1,961$. Comme $|6,41| > 1,961$, on rejette H_0 .
5. p -value : $p = 2P(T_{3007} > 6,41) = \mathbf{1,6 \times 10^{-10}}$.

En Stata : `display 2*ttail(e(df_r), abs((_b[educ]-0.07)/_se[educ]))`. Vérification possible avec `test educ = 0.07` (qui affiche $F = t^2 = 41,15$ et la même p -value) ou avec `lincom educ - 0.07`.

Réponse

$t = 6,41$ et $p \approx 1,6 \times 10^{-10}$: on **rejette** H_0 à tous les niveaux usuels (1 %, 5 %, 10 %). Le rendement estimé (9,3 %) est significativement supérieur aux 7 % du collègue.

Interprétation de la p -value : si le vrai rendement était de 0,07, la probabilité d'obtenir, dans un échantillon comme le nôtre, une estimation au moins aussi éloignée de 0,07 que celle observée ($|t| \geq 6,41$) serait d'environ 1,6 sur 10 milliards. Une telle observation est pratiquement incompatible avec H_0 . C'est aussi le plus petit seuil α auquel on rejeterait H_0 .

Cohérence : l'intervalle de confiance à 95 %, $[0,086; 0,100]$, ne contient pas 0,07.

Nuance : la p -value n'est *pas* la probabilité que H_0 soit vraie.

4.4 (d) Reparamétrisation**Idée de la démarche**

Le tableau de régression donne automatiquement le test de « coefficient = 0 ». On réécrit donc le modèle pour qu'un coefficient soit égal à $\theta = \beta_{educ} - 0,07$: tester $\theta = 0$ revient alors à tester $\beta_{educ} = 0,07$.

On pose $\theta = \beta_1 - 0,07$, soit $\beta_1 = \theta + 0,07$. On remplace dans le modèle :

$$lwage = \beta_0 + (\theta + 0,07) educ + \beta_2 exper + \epsilon \iff \underbrace{lwage - 0,07 educ}_{\text{nouvelle variable dépendante}} = \beta_0 + \theta educ + \beta_2 exper + \epsilon.$$

```
generate lwage_r = lwage - 0.07*educ
regress lwage_r educ exper
```

lwage_r	Coefficient	É.-t.	t	p
educ (= $\hat{\theta}$)	0,02317	0,00361	6,41	0,000
exper	0,04066	0,00233	17,42	0,000
constante	4,66604	0,06379	73,15	0,000

Réponse

Le coefficient de **educ** vaut maintenant $\hat{\theta} = 0,0932 - 0,07 = 0,0232$, avec le *même* écart-type (0,00361). La ligne **educ** du tableau affiche directement $t = 6,41$ et $p = 0,000$ ($1,6 \times 10^{-10}$), les mêmes valeurs qu'en (c). Les autres coefficients sont inchangés.

Pourquoi l'écart-type ne change pas : soustraire $0,07 educ$ à y ne modifie ni $\mathbf{X}$ ni les résidus ($y - 0,07 educ - \hat{\beta}_0 - \hat{\theta} educ - \hat{\beta}_2 exper = e$), donc ni s^2 ni $s^2(\mathbf{X}'\mathbf{X})^{-1}$.

4.5 (e) Différence de salaire constante entre le Sud et ailleurs**Idée de la démarche**

« Différence constante et indépendante de l'éducation et de l'expérience » : on ajoute une variable indicatrice **south**, qui ne déplace que la constante (deux droites parallèles). On teste ensuite la nullité de son coefficient.

Modèle : $lwage = \beta_0 + \beta_1 educ + \beta_2 exper + \delta south + \epsilon$. Hors du Sud, la constante est β_0 ; dans le Sud, elle est $\beta_0 + \delta$. Les pentes sont les mêmes. $H_0 : \delta = 0$ (salaires identiques à éducation et expérience égales) contre $H_a : \delta \neq 0$.

lwage	Coefficient	É.-t.	t	p
educ	0,08492	0,00356	23,86	0,000
exper	0,03983	0,00227	17,57	0,000
south	-0,20074	0,01480	-13,57	0,000
constante	4,86370	0,06362	76,45	0,000
$n = 3010, R^2 = 0,229, SCE = 457,19$				

Réponse

$t = -0,2007/0,0148 = -13,57, p < 0,0001$ (valeur critique 1,961) : on **rejette** H_0 . À éducation et expérience égales, les salaires dans le Sud sont inférieurs d'environ **20 %** (exactement $e^{-0,2007} - 1 = -18,2\%$) à ceux des autres régions.

On peut aussi faire le test par un F (**test south**) : $F = t^2 = 184,1$, même conclusion. Le résultat est robuste à l'hétéroscédasticité (**vce(robust)**) : $t = -13,4$.

Remarque : l'ajout de **south** fait baisser le rendement estimé de l'éducation (de 0,093 à 0,085). Le Sud a en moyenne moins d'éducation *et* des salaires plus bas ; en (a), une partie de l'effet régional était attribuée à l'éducation (biais de variable omise).

4.6 (f) Marchés du travail identiques ? Test de Chow

Idée de la démarche

On permet à *tous* les coefficients (constante, rendement de l'éducation, rendement de l'expérience) de différer entre le Sud et ailleurs, en interagissant chaque variable avec **south**. « Marchés identiques » signifie que les trois différences sont nulles : c'est une hypothèse jointe (3 restrictions), qu'on teste avec un F . C'est le **test de Chow**.

Modèle non contraint.

$$lwage = \beta_0 + \beta_1 educ + \beta_2 exper + \delta_0 south + \delta_1 (south \times educ) + \delta_2 (south \times exper) + \epsilon.$$

Hors du Sud : constante β_0 , pentes β_1, β_2 . Dans le Sud : $\beta_0 + \delta_0, \beta_1 + \delta_1, \beta_2 + \delta_2$.

$$H_0 : \delta_0 = \delta_1 = \delta_2 = 0 \quad \text{contre} \quad H_a : \text{au moins un } \delta_j \neq 0.$$

lwage	Coefficient	É.-t.	t	p
educ	0,07312	0,00462	15,84	0,000
exper	0,04471	0,00289	15,49	0,000
south	-0,42419	0,12677	-3,35	0,001
south×educ	0,02404	0,00722	3,33	0,001
south×exper	-0,01032	0,00462	-2,23	0,026
constante	4,98414	0,08079	61,69	0,000
$n = 3010, R^2 = 0,240, SCE_{NC} = 450,24, n - k = 3004$				

Statistique F à la main. Le modèle contraint (sous H_0) est celui de (a) : $SCE_C = 485,18$. Avec $q = 3$ restrictions et $n - k = 3010 - 6 = 3004$:

$$F = \frac{(SCE_C - SCE_{NC})/q}{SCE_{NC}/(n - k)} = \frac{(485,18 - 450,24)/3}{450,24/3004} = \frac{11,647}{0,14988} = \mathbf{77,7}.$$

Valeur critique $F_{0,95;3;3004} = 2,61$; p -value $\approx 2 \times 10^{-48}$.

Vérification par régressions séparées. La régression interagie équivaut à estimer le modèle séparément dans chaque région :

- Sud ($n = 1215$) : $\widehat{lwage} = 4,560 + 0,0972 educ + 0,0344 exper$, $SCE = 185,90$;
- ailleurs ($n = 1795$) : $\widehat{lwage} = 4,984 + 0,0731 educ + 0,0447 exper$, $SCE = 264,34$.

On vérifie $185,90 + 264,34 = 450,24 = SCE_{NC}$. C'est la forme classique du test de Chow.

Réponse

$F = 77,7 > 2,61$ ($p \approx 0$) : on **rejette** fortement l'hypothèse que les marchés du travail du Sud et du reste du pays sont identiques. Les différences ne se limitent pas à la constante :

- **rendement de l'éducation plus élevé dans le Sud** : 9,7 % contre 7,3 % par année d'étude (différence de 2,4 points, $t = 3,33$, significative) ;
- **rendement de l'expérience plus faible dans le Sud** : 3,4 % contre 4,5 % par année (différence de $-1,0$ point, $t = -2,23$, significative à 5 %) ;
- **l'écart salarial dépend donc du profil** : il vaut $-0,424 + 0,024 educ - 0,010 exper$. Pour $educ = 12$ et $exper = 8$: $-0,218$ (environ -20%). Pour $educ = 16$ et $exper = 8$: $-0,122$ (environ -11%). L'écart se réduit pour les plus éduqués.

Un test des seules pentes ($\delta_1 = \delta_2 = 0$) rejette aussi l'égalité ($F = 23,2$, $p \approx 10^{-10}$). L'hypothèse de (e) d'une différence constante est donc elle-même rejetée : le modèle (e) est trop restrictif.

Mise en garde : le test de Chow classique suppose la même variance des erreurs dans les deux régions. Une version robuste à l'hétéroscédasticité (`vce(robust)` puis `test`) donne $F = 77,3$: la conclusion est inchangée.

Annexe – Code Stata

Le fichier complet et commenté est `stata/devoir1.do`. Structure :

```
* Q3 : set seed 1234 ; x1, x2 fixes ; boucle de 1000 répétitions ;
*       post des b, se, et du rejet de H0: beta2=0 ; puis summarize / ttest
* Q4 : infile using dictionary.raw, using(assign2School.raw) clear
* (a) regress lwage educ exper
* (b) predict uhat, residuals ; summarize uhat
* (c) display (_b[educ]-0.07)/_se[educ] ; 2*ttail(e(df_r),abs(t)) ; test educ=0.07
* (d) generate lwage_r = lwage - 0.07*educ ; regress lwage_r educ exper
* (e) regress lwage educ exper south
* (f) regress lwage c.educ##i.south c.exper##i.south
*       test 1.south 1.south#c.educ 1.south#c.exper    (+ Chow à la main)
```