

Question 1(c) : une autre méthode

Calcul direct des espérances de b_0 et b_1 à partir de leurs formules explicites

Table des matières

1	Le point de départ	1
2	Le calcul, étape par étape	2
3	Vérification numérique	3
4	Interprétation	4
5	Comparaison avec la méthode matricielle	4
6	Pour rédiger la réponse	4

1 Le point de départ

Modèle : $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, avec $\mathbb{E}[\epsilon_i | x_i] = \alpha_0 + \alpha_1 x_i$.

Les MCO appliqués à ce modèle donnent les formules du cours (équation [16]) :

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{S_{xx}}, \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad b_0 = \bar{y} - b_1 \bar{x}.$$

À comprendre

On cherche ce que ces estimateurs estiment « en moyenne », c'est-à-dire $\mathbb{E}[b_1]$ et $\mathbb{E}[b_0]$. Ces espérances sont, par définition, les γ_1 et γ_0 de l'énoncé : « les MCO estiment sans biais γ_0 et γ_1 » veut dire $\mathbb{E}[b_0] = \gamma_0$ et $\mathbb{E}[b_1] = \gamma_1$.

Hypothèse (échantillon aléatoire) : on raisonne conditionnellement à toutes les x (notées x ci-dessous), et

$$\mathbb{E}[\epsilon_i | x_1, \dots, x_n] = \alpha_0 + \alpha_1 x_i.$$

Deux identités utiles, qui viennent toutes deux de $\sum (x_i - \bar{x}) = 0$ (la somme des écarts à la moyenne est nulle) :

$$(I1) \quad \sum_{i=1}^n (x_i - \bar{x}) \cdot c = c \sum_{i=1}^n (x_i - \bar{x}) = 0 \quad \text{pour toute constante } c,$$

$$(I2) \quad \sum_{i=1}^n (x_i - \bar{x}) x_i = \sum_{i=1}^n (x_i - \bar{x})^2 = S_{xx}.$$

Preuve de (I2) : $\sum (x_i - \bar{x})^2 = \sum (x_i - \bar{x}) x_i - \bar{x} \sum (x_i - \bar{x}) = \sum (x_i - \bar{x}) x_i - 0$.

2 Le calcul, étape par étape

Étape 1 : réécrire b_1 en fonction des erreurs

On remplace y_i par $\beta_0 + \beta_1 x_i + \epsilon_i$ dans le numérateur :

$$\begin{aligned} \sum_{i=1}^n (x_i - \bar{x}) y_i &= \beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x}) x_i + \sum_{i=1}^n (x_i - \bar{x}) \epsilon_i \\ &= 0 + \beta_1 S_{xx} + \sum_{i=1}^n (x_i - \bar{x}) \epsilon_i \end{aligned} \quad \text{(I1) et (I2).}$$

On divise par S_{xx} :

$$b_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \epsilon_i}{S_{xx}}.$$

Résultat de l'étape

$b_1 = \beta_1 + \frac{\sum (x_i - \bar{x}) \epsilon_i}{S_{xx}}$: c'est l'écriture habituelle « vraie valeur + erreur d'échantillonnage » (comme l'équation [79] du cours).

Étape 2 : l'espérance de b_1 , donc γ_1

Les poids $(x_i - \bar{x})/S_{xx}$ ne dépendent que des x ; sachant les x , ce sont des constantes, qu'on peut sortir de l'espérance :

$$\mathbb{E}[b_1 | x] = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \mathbb{E}[\epsilon_i | x]}{S_{xx}} = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) (\alpha_0 + \alpha_1 x_i)}{S_{xx}}.$$

Pourquoi cette manipulation ?

C'est ici que la question diffère du cours. Dans le cours, $\mathbb{E}[\epsilon_i | x] = 0$ et ce terme disparaît : b_1 est sans biais pour β_1 . Ici, $\mathbb{E}[\epsilon_i | x] = \alpha_0 + \alpha_1 x_i \neq 0$: le terme reste, et il faut le calculer.

On calcule la somme au numérateur :

$$\sum_{i=1}^n (x_i - \bar{x}) (\alpha_0 + \alpha_1 x_i) = \alpha_0 \sum_{i=1}^n (x_i - \bar{x}) + \alpha_1 \sum_{i=1}^n (x_i - \bar{x}) x_i = 0 + \alpha_1 S_{xx} \quad \text{(I1) et (I2).}$$

Donc

$$\mathbb{E}[b_1 | x] = \beta_1 + \frac{\alpha_1 S_{xx}}{S_{xx}} = \beta_1 + \alpha_1.$$

Résultat de l'étape

$$\boxed{\gamma_1 = \beta_1 + \alpha_1}$$

Remarque : α_0 **disparaît de la pente**, grâce à (I1). Une erreur de moyenne constante ne déforme pas la pente.

Étape 3 : réécrire $\bar{y}$ et calculer son espérance

On fait la moyenne du modèle sur les n observations :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i + \epsilon_i) = \beta_0 + \beta_1 \bar{x} + \bar{\epsilon}, \quad \bar{\epsilon} = \frac{1}{n} \sum_{i=1}^n \epsilon_i.$$

Espérance de la moyenne des erreurs :

$$\mathbb{E}[\bar{\epsilon} \mid x] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\epsilon_i \mid x] = \frac{1}{n} \sum_{i=1}^n (\alpha_0 + \alpha_1 x_i) = \alpha_0 + \alpha_1 \bar{x}.$$

Donc

$$\mathbb{E}[\bar{y} \mid x] = \beta_0 + \beta_1 \bar{x} + \alpha_0 + \alpha_1 \bar{x}.$$

Étape 4 : l'espérance de b_0 , donc γ_0

On part de $b_0 = \bar{y} - b_1 \bar{x}$ et on utilise les étapes 2 et 3 ($\bar{x}$ est une constante sachant les x) :

$$\begin{aligned} \mathbb{E}[b_0 \mid x] &= \mathbb{E}[\bar{y} \mid x] - \mathbb{E}[b_1 \mid x] \bar{x} \\ &= (\beta_0 + \beta_1 \bar{x} + \alpha_0 + \alpha_1 \bar{x}) - (\beta_1 + \alpha_1) \bar{x} \\ &= \beta_0 + \alpha_0 + \underbrace{(\beta_1 \bar{x} - \beta_1 \bar{x})}_0 + \underbrace{(\alpha_1 \bar{x} - \alpha_1 \bar{x})}_0 \\ &= \beta_0 + \alpha_0. \end{aligned}$$

Résultat de l'étape

$$\gamma_0 = \beta_0 + \alpha_0$$

Étape 5 : conclusion

Ces résultats ne dépendent pas des x . Par la loi des espérances itérées, $\mathbb{E}[b_1] = \mathbb{E}[\mathbb{E}[b_1 \mid x]] = \beta_1 + \alpha_1$ et $\mathbb{E}[b_0] = \beta_0 + \alpha_0$.

Réponse finale

$$\gamma_0 = \beta_0 + \alpha_0, \quad \gamma_1 = \beta_1 + \alpha_1.$$

Les MCO estiment sans biais γ_0 et γ_1 , mais ils sont **biaisés pour** β_0 (biais α_0) et **pour** β_1 (biais α_1).

3 Vérification numérique

Prenons $\beta_0 = 1$, $\beta_1 = 0,5$, $\alpha_0 = 2$, $\alpha_1 = 0,3$ et trois observations $x = (1, 2, 3)$. Alors $\bar{x} = 2$ et $S_{xx} = 1 + 0 + 1 = 2$.

Pente.

$$\begin{aligned} \mathbb{E}[b_1] &= 0,5 + \frac{\sum (x_i - 2)(2 + 0,3x_i)}{2} = 0,5 + \frac{(-1)(2,3) + 0 \cdot (2,6) + (1)(2,9)}{2} \\ &= 0,5 + \frac{0,6}{2} = 0,8 = \beta_1 + \alpha_1 \quad \checkmark \end{aligned}$$

Constante.

$$\mathbb{E}[\bar{y}] = 1 + 0,5 \cdot 2 + 2 + 0,3 \cdot 2 = 4,6, \quad \mathbb{E}[b_0] = 4,6 - 0,8 \cdot 2 = 3 = \beta_0 + \alpha_0 \checkmark$$

4 Interprétation

Intuition

- α_0 **est inoffensif** : une erreur de moyenne constante est simplement absorbée par la constante. C'est pourquoi l'hypothèse $\mathbb{E}[\epsilon] = 0$ n'est qu'une *normalisation* quand le modèle contient une constante (voir aussi la question 4(b)).
- α_1 **est un vrai biais de pente** : si l'erreur varie systématiquement avec x , les MCO attribuent à x un effet qui vient en réalité de l'erreur. Exemple : dans une équation de salaire, si l'habileté (contenue dans ϵ) augmente avec l'éducation, alors $\alpha_1 > 0$ et les MCO surestiment le rendement de l'éducation (biais de variable omise).

5 Comparaison avec la méthode matricielle

	Méthode matricielle (corrigé)	Méthode des formules explicites (ce document)
Outil	$\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}]$	formules scalaires de b_0 et b_1
Clé	$\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{X}\boldsymbol{\alpha}$, donc $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\alpha} = \boldsymbol{\alpha}$	$\sum(x_i - \bar{x}) = 0$ fait disparaître α_0 de la pente
Avantage	plus courte, valable pour k variables	plus concrète : on voit d'où vient chaque terme

Les deux méthodes donnent le même résultat ; l'une ou l'autre peut être présentée dans la copie.

6 Pour rédiger la réponse

1. Écrire les formules $b_1 = \sum(x_i - \bar{x})y_i/S_{xx}$ et $b_0 = \bar{y} - b_1\bar{x}$.
2. Remplacer y_i et obtenir $b_1 = \beta_1 + \sum(x_i - \bar{x})\epsilon_i/S_{xx}$ (étape 1)
3. Prendre l'espérance conditionnelle et calculer $\sum(x_i - \bar{x})(\alpha_0 + \alpha_1 x_i) = \alpha_1 S_{xx}$: $\gamma_1 = \beta_1 + \alpha_1$ (étape 2)
4. Calculer $\mathbb{E}[\bar{y} \mid x] = \beta_0 + \beta_1 \bar{x} + \alpha_0 + \alpha_1 \bar{x}$ (étape 3)
5. En déduire $\mathbb{E}[b_0 \mid x] = \beta_0 + \alpha_0$, donc $\gamma_0 = \beta_0 + \alpha_0$ (étape 4)
6. Conclure par la loi des espérances itérées et interpréter α_0 et α_1 (étape 5)