

Chapitre 2 : Les moindres carrés ordinaires

Explications détaillées, intuitions, démonstrations pas à pas
et compléments de recherche

Guide d'étude accompagnant les notes de cours
(réf. : W. H. Greene, *Econometric Analysis*, ch. 3, 4 et 15.5)

Ce que contient ce document

- Chaque équation du cours reprise et **expliquée ligne par ligne** (y compris les étapes « après manipulation » que les notes sautent).
- Des **intuitions** géométriques et économiques, des **exemples numériques** calculés à la main.
- Des **figures** et une **réplication de l'étude de Monte Carlo** du cours.
- Des éléments **historiques** (Legendre, Gauss, Markov, Yule, Frisch, Waugh, Lovell. . .).
- Une liste des **coquilles** relevées dans les notes, une **fiche de révision** et des **exercices corrigés**.

Table des matières

1	Boîte à outils : l'algèbre matricielle dont on a besoin	3
1.1	Dimensions et notation	3
1.2	Transposée	3
1.3	Un scalaire est égal à sa transposée	3
1.4	Rang et inverse	3
1.5	Matrice définie positive	4
1.6	Trace	4
1.7	Dérivées matricielles (règles [10] et [11])	4
2	Le modèle de régression linéaire (Greene 3.1–3.2)	4
2.1	Le modèle [1]	4
2.2	Population contre échantillon : la distinction la plus importante du chapitre	5
2.3	Pourquoi la notation $\mathbf{b}_0$?	5
3	Le vecteur des coefficients MCO (Greene 3.2.1)	5
3.1	Le critère [5]–[6]	5
3.2	Développement de la fonction objectif [7]–[8]	6
3.3	Condition du premier ordre [9]–[12]	6
3.4	Condition du second ordre [14] : pourquoi c'est bien un minimum unique	6
4	Le cas de la régression bivariée	7
4.1	Obtention des formules [16] à partir de [15]	7
4.2	Le lien avec la forme matricielle [20]–[21]	7
5	Propriétés numériques des MCO (Greene 3.2.3)	9
5.1	Numérique contre statistique	9
5.2	Les équations normales [24] et l'orthogonalité [25]	9
5.3	Les conséquences quand le modèle contient une constante	9
6	Les matrices de projection $\mathbf{P}$ et $\mathbf{M}$ (Greene 3.2.4)	10
6.1	Définitions	10
6.2	Démonstration des propriétés	10
6.3	Interprétation géométrique	10
7	Le théorème de Frisch-Waugh-Lovell (Greene 3.3)	11
7.1	Énoncé	11
7.2	La démonstration complète (l'étape « après manipulation »)	12
7.3	Pourquoi ce théorème est si important	12
8	Le coefficient de détermination R^2 (Greene 3.5)	13

8.1	La matrice $\mathbf{M}^0$ qui centre	13
8.2	La décomposition $\text{SCT} = \text{SCR} + \text{SCE}$ [58]–[66]	14
8.3	Définition et interprétation du R^2	14
8.4	Pourquoi le R^2 augmente quand on ajoute une variable [68]–(fin 2.4.1)	15
8.5	Complément : le R^2 ajusté et les critères d’information	15
9	Propriétés statistiques des MCO (Greene 4.1–4.3)	16
9.1	Les hypothèses du modèle classique, une par une	16
9.2	Absence de biais [79]–[80]	17
9.3	Variance [81]–[82]	17
10	Le théorème de Gauss-Markov (Greene 4.3.5)	18
10.1	Décortiquer l’énoncé	18
10.2	La preuve, étape par étape	18
10.3	Ce que le théorème ne dit pas	19
11	L’estimation de σ^2 (Greene 4.3.4)	19
11.1	Le problème	19
11.2	Calcul de $\mathbb{E}[\mathbf{e}'\mathbf{e} \mid \mathbf{X}]$ [94]–[106]	20
12	Les études de Monte Carlo (Greene 15.5)	21
12.1	Principe	21
12.2	Générer des nombres (pseudo-)aléatoires [110]	21
12.3	Obtenir n’importe quelle loi : la transformation inverse	21
12.4	Les étapes de l’étude (cours p. 24)	22
12.5	Le code Stata commenté	22
12.6	Lecture des résultats	23
12.7	Pourquoi l’histogramme est normal	24
13	Coquilles et imprécisions relevées dans les notes	24
14	Fiche de révision	25
15	Exercices corrigés	26
	Références et sources consultées	27

1 Boîte à outils : l’algèbre matricielle dont on a besoin

Tout le chapitre est écrit en notation matricielle. Avant de commencer, voici le strict nécessaire, avec la raison pour laquelle chaque outil sert.

1.1 Dimensions et notation

Objet	Dimension	Signification
$\mathbf{y}$	$n \times 1$	les n observations de la variable dépendante
$\mathbf{X}$	$n \times K$	les K variables explicatives (une colonne par variable, une ligne par individu)
$\mathbf{x}_i$	$K \times 1$	la i -ème ligne de $\mathbf{X}$, écrite en colonne ; donc $\mathbf{x}'_i$ est la ligne i
$\boldsymbol{\beta}$	$K \times 1$	les vrais coefficients (inconnus, « population »)
$\boldsymbol{\epsilon}$	$n \times 1$	les vraies erreurs (inconnues, non observées)
$\mathbf{b}$	$K \times 1$	l’estimateur MCO de $\boldsymbol{\beta}$ (calculé à partir des données)
$\mathbf{e}$	$n \times 1$	les résidus MCO (calculés à partir des données)

Astuce de vérification : dans un produit $\mathbf{AB}$, le nombre de colonnes de $\mathbf{A}$ doit égaler le nombre de lignes de $\mathbf{B}$. Vérifier les dimensions permet de détecter la moitié des erreurs. Par exemple $\mathbf{X}'\mathbf{X}$ est $(K \times n)(n \times K) = K \times K$ et $\mathbf{X}'\mathbf{y}$ est $(K \times n)(n \times 1) = K \times 1$.

1.2 Transposée

$(\mathbf{A}')' = \mathbf{A}$, $(\mathbf{A} + \mathbf{B})' = \mathbf{A}' + \mathbf{B}'$, $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$ (l’ordre s’inverse!). Une matrice est *symétrique* si $\mathbf{A}' = \mathbf{A}$. Exemple clé : $\mathbf{X}'\mathbf{X}$ est toujours symétrique car $(\mathbf{X}'\mathbf{X})' = \mathbf{X}'(\mathbf{X}')' = \mathbf{X}'\mathbf{X}$.

1.3 Un scalaire est égal à sa transposée

Si a est un nombre (1×1), alors $a' = a$. C’est l’astuce qui permet de passer de [7] à [8] : $\mathbf{b}'_0\mathbf{X}'\mathbf{y}$ est 1×1 et sa transposée est $\mathbf{y}'\mathbf{X}\mathbf{b}_0$, donc les deux sont égaux.

1.4 Rang et inverse

Le *rang* de $\mathbf{X}$ est le nombre de colonnes linéairement indépendantes. $\mathbf{X}$ est de *plein rang (colonne)* si $\text{rang}(\mathbf{X}) = K$: aucune variable n’est une combinaison linéaire exacte des autres. Dans ce cas, et seulement dans ce cas, $\mathbf{X}'\mathbf{X}$ est inversible.

Attention / piège fréquent

Exemples où le plein rang échoue (*multicolinéarité parfaite*) :

- inclure une constante *et* une indicatrice pour chaque catégorie (homme *et* femme) : « piège des variables indicatrices », car homme + femme = 1 = constante ;
- inclure l’âge, l’année de naissance et l’année d’observation (âge = année – naissance) ;
- avoir moins d’observations que de variables ($n < K$).

Le logiciel (Stata, R) retire alors automatiquement une variable (« omitted because of collinearity » ou coefficient NA).

1.5 Matrice définie positive

Une matrice symétrique $\mathbf{A}$ ($K \times K$) est *définie positive* si $\mathbf{c}'\mathbf{A}\mathbf{c} > 0$ pour tout vecteur $\mathbf{c} \neq \mathbf{0}$, et *semi-définie positive* si $\mathbf{c}'\mathbf{A}\mathbf{c} \geq 0$. C'est la généralisation matricielle de « nombre positif ».

Pourquoi $\mathbf{X}'\mathbf{X}$ est définie positive quand $\mathbf{X}$ est de plein rang :

$$\mathbf{c}'\mathbf{X}'\mathbf{X}\mathbf{c} = (\mathbf{X}\mathbf{c})'(\mathbf{X}\mathbf{c}) = \|\mathbf{X}\mathbf{c}\|^2 = \sum_{i=1}^n (\mathbf{x}_i'\mathbf{c})^2 \geq 0,$$

et c'est nul seulement si $\mathbf{X}\mathbf{c} = \mathbf{0}$, ce qui (plein rang) n'arrive que si $\mathbf{c} = \mathbf{0}$.

De même, pour n'importe quelle matrice $\mathbf{D}$, $\mathbf{D}\mathbf{D}'$ est semi-définie positive car $\mathbf{c}'\mathbf{D}\mathbf{D}'\mathbf{c} = \|\mathbf{D}'\mathbf{c}\|^2 \geq 0$ (sert pour Gauss-Markov).

1.6 Trace

La trace d'une matrice carrée est la somme de ses éléments diagonaux. Propriétés : $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr} \mathbf{A} + \text{tr} \mathbf{B}$, $\text{tr}(c\mathbf{A}) = c \text{tr} \mathbf{A}$, $\text{tr}(\mathbf{A}\mathbf{B}\mathbf{C}) = \text{tr}(\mathbf{B}\mathbf{C}\mathbf{A}) = \text{tr}(\mathbf{C}\mathbf{A}\mathbf{B})$ (permutation circulaire), et pour un scalaire a , $\text{tr}(a) = a$. Elle sert pour estimer σ^2 (section 11).

1.7 Dérivées matricielles (règles [10] et [11])

Le cours dit qu'il n'est pas nécessaire de connaître ces règles. Voici quand même pourquoi elles sont vraies, sur un exemple à $K = 2$: c'est rassurant.

Soit $\mathbf{a} = (a_1, a_2)'$ et $\mathbf{b} = (b_1, b_2)'$. Alors $\mathbf{a}'\mathbf{b} = a_1b_1 + a_2b_2$ et $\frac{\partial \mathbf{a}'\mathbf{b}}{\partial \mathbf{b}} = \begin{pmatrix} \partial/\partial b_1 \\ \partial/\partial b_2 \end{pmatrix} (a_1b_1 + a_2b_2) = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = \mathbf{a}$.

Pour une forme quadratique avec $\mathbf{A}$ symétrique, $\mathbf{b}'\mathbf{A}\mathbf{b} = a_{11}b_1^2 + 2a_{12}b_1b_2 + a_{22}b_2^2$, donc

$$\frac{\partial \mathbf{b}'\mathbf{A}\mathbf{b}}{\partial \mathbf{b}} = \begin{pmatrix} 2a_{11}b_1 + 2a_{12}b_2 \\ 2a_{12}b_1 + 2a_{22}b_2 \end{pmatrix} = 2\mathbf{A}\mathbf{b}.$$

À retenir

Ce sont exactement les analogues de $\frac{d}{db}(ab) = a$ et $\frac{d}{db}(ab^2) = 2ab$ en dimension 1. Retenir l'analogie suffit.

2 Le modèle de régression linéaire (Greene 3.1–3.2)

2.1 Le modèle [1]

$$y_i = \beta_1 + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \epsilon_i = \mathbf{x}_i'\boldsymbol{\beta} + \epsilon_i, \quad i = 1, \dots, n.$$

- $\mathbf{x}_i = (1, x_{i2}, \dots, x_{iK})'$: le « 1 » en première position correspond à la constante β_1 .
- $\mathbf{x}_i'\boldsymbol{\beta}$ est la *partie systématique* : sous l'hypothèse $\mathbb{E}[\epsilon_i | \mathbf{x}_i] = 0$, c'est l'espérance conditionnelle $\mathbb{E}[y_i | \mathbf{x}_i]$, c'est-à-dire la valeur moyenne de y chez les individus ayant les caractéristiques $\mathbf{x}_i$.
- ϵ_i regroupe tout ce qui influence y_i mais n'est pas dans $\mathbf{x}_i$ (facteurs omis, erreurs de mesure, hasard).

En empilant les n équations : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$.

Exemple économique

Équation de salaire (Mincer) : $\ln(\text{salaire}_i) = \beta_1 + \beta_2 \text{scolarité}_i + \beta_3 \text{expérience}_i + \epsilon_i$. Ici β_2 est l'effet (en log, donc $\approx$ en %) d'une année d'étude supplémentaire, à *expérience donnée*. ϵ_i contient par exemple l'habileté, la motivation, la chance.

2.2 Population contre échantillon : la distinction la plus importante du chapitre

	Population (inconnu)	Échantillon (calculé)
Coefficients	β	$\mathbf{b}$ (ou un candidat quelconque $\mathbf{b}_0$)
Termes aléatoires	erreurs $\epsilon_i = y_i - \mathbf{x}'_i \beta$	résidus $e_i = y_i - \mathbf{x}'_i \mathbf{b}$
Partie systématique	$\mathbb{E}[y_i \mathbf{x}_i] = \mathbf{x}'_i \beta$	valeur prédite $\hat{y}_i = \mathbf{x}'_i \mathbf{b}$

L'équation [4], $y_i = \mathbf{x}'_i \beta + \epsilon_i = \mathbf{x}'_i \mathbf{b}_0 + e_i(\mathbf{b}_0)$, dit simplement qu'on peut découper y_i de deux façons : « vraie partie systématique + vraie erreur » (inobservable) ou « partie prédite + résidu » (observable). **Les résidus ne sont pas les erreurs** : ce sont leurs estimations.

2.3 Pourquoi la notation $\mathbf{b}_0$?

$\mathbf{b}_0$ désigne *n'importe quel* vecteur candidat. À chaque candidat correspondent des résidus $e_i(\mathbf{b}_0)$. Les MCO choisissent, parmi tous les candidats, celui qui rend les résidus « les plus petits » au sens de la somme des carrés ; ce gagnant est noté $\mathbf{b}$ (sans indice).

3 Le vecteur des coefficients MCO (Greene 3.2.1)**3.1 Le critère [5]–[6]**

$$S(\mathbf{b}_0) = \sum_{i=1}^n e_i(\mathbf{b}_0)^2 = \sum_{i=1}^n (y_i - \mathbf{x}'_i \mathbf{b}_0)^2 = (\mathbf{y} - \mathbf{X}\mathbf{b}_0)'(\mathbf{y} - \mathbf{X}\mathbf{b}_0).$$

Le passage de la somme au produit matriciel utilise le fait que pour un vecteur colonne $\mathbf{v}$, $\mathbf{v}'\mathbf{v} = \sum v_i^2$ (somme des carrés des composantes).

Intuition

Pourquoi *les carrés* ?

1. Les résidus positifs et négatifs ne se compensent pas (contrairement à $\sum e_i$ qui peut valoir 0 pour une très mauvaise droite).
2. Les grands écarts sont fortement pénalisés.
3. La fonction est dérivable et quadratique, donc la solution est une formule explicite (ce n'est pas le cas avec $\sum |e_i|$, la « régression médiane »).
4. Sous normalité des erreurs, les MCO coïncident avec le maximum de vraisemblance (argument de Gauss, 1809).

3.2 Développement de la fonction objectif [7]–[8]

Calcul détaillé

On développe comme $(a - b)^2$, en respectant l'ordre des produits :

$$\begin{aligned} (\mathbf{y} - \mathbf{X}\mathbf{b}_0)'(\mathbf{y} - \mathbf{X}\mathbf{b}_0) &= (\mathbf{y}' - \mathbf{b}_0'\mathbf{X}')(\mathbf{y} - \mathbf{X}\mathbf{b}_0) && \text{car } (\mathbf{X}\mathbf{b}_0)' = \mathbf{b}_0'\mathbf{X}' \\ &= \mathbf{y}'\mathbf{y} - \mathbf{y}'\mathbf{X}\mathbf{b}_0 - \mathbf{b}_0'\mathbf{X}'\mathbf{y} + \mathbf{b}_0'\mathbf{X}'\mathbf{X}\mathbf{b}_0. \end{aligned}$$

Les deux termes du milieu sont des scalaires (1×1), transposés l'un de l'autre : $(\mathbf{y}'\mathbf{X}\mathbf{b}_0)' = \mathbf{b}_0'\mathbf{X}'\mathbf{y}$. Ils sont donc égaux, d'où

$$S(\mathbf{b}_0) = \mathbf{y}'\mathbf{y} - 2\mathbf{y}'\mathbf{X}\mathbf{b}_0 + \mathbf{b}_0'\mathbf{X}'\mathbf{X}\mathbf{b}_0.$$

C'est l'analogie matricielle de $y^2 - 2xyb + x^2b^2$: une parabole (en dimension K , un « bol »).

3.3 Condition du premier ordre [9]–[12]

On dérive terme à terme par rapport à $\mathbf{b}_0$:

- $\mathbf{y}'\mathbf{y}$ ne dépend pas de $\mathbf{b}_0$: dérivée $\mathbf{0}$;
- $-2\mathbf{y}'\mathbf{X}\mathbf{b}_0 = -2(\mathbf{X}'\mathbf{y})'\mathbf{b}_0$: forme $\mathbf{a}'\mathbf{b}_0$ avec $\mathbf{a} = \mathbf{X}'\mathbf{y}$, dérivée $-2\mathbf{X}'\mathbf{y}$ (règle [10]) ;
- $\mathbf{b}_0'\mathbf{X}'\mathbf{X}\mathbf{b}_0$: forme quadratique avec $\mathbf{A} = \mathbf{X}'\mathbf{X}$ symétrique, dérivée $2\mathbf{X}'\mathbf{X}\mathbf{b}_0$ (règle [11]).

$$\frac{\partial S}{\partial \mathbf{b}_0} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\mathbf{b}_0 = \mathbf{0} \implies \mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y}.$$

(Le cours écrit [12] sans le facteur 2, ce qui ne change rien puisqu'on égalise à zéro.)

À retenir

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \quad [13]$$

C'est la formule la plus importante du cours. Les K équations $\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y}$ s'appellent les **équations normales**.

Attention / piège fréquent

On ne peut pas « simplifier » $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ en $\mathbf{X}^{-1}\mathbf{y}$: $\mathbf{X}$ est $n \times K$, pas carrée, elle n'a pas d'inverse. $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ joue le rôle d'un « inverse à gauche » de $\mathbf{X}$: $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_K$.

3.4 Condition du second ordre [14] : pourquoi c'est bien un minimum unique

La matrice des dérivées secondes (hessienne) vaut $2\mathbf{X}'\mathbf{X}$. Si elle est définie positive (i.e. $\mathbf{X}$ de plein rang, voir §1.5), la fonction S est strictement convexe : un « bol » avec un unique fond. Le point où la pente est nulle est alors le minimum global, et il est unique.

Preuve directe (sans dérivée) que $\mathbf{b}$ est le minimum

Pour tout candidat $\mathbf{b}_0$, écrivons $\mathbf{y} - \mathbf{X}\mathbf{b}_0 = (\mathbf{y} - \mathbf{X}\mathbf{b}) + \mathbf{X}(\mathbf{b} - \mathbf{b}_0) = \mathbf{e} + \mathbf{X}(\mathbf{b} - \mathbf{b}_0)$. Alors

$$S(\mathbf{b}_0) = \mathbf{e}'\mathbf{e} + 2(\mathbf{b} - \mathbf{b}_0)' \underbrace{\mathbf{X}'\mathbf{e}}_{=0} + (\mathbf{b} - \mathbf{b}_0)' \underbrace{\mathbf{X}'\mathbf{X}(\mathbf{b} - \mathbf{b}_0)}_{\geq 0} = S(\mathbf{b}) + \underbrace{(\mathbf{b} - \mathbf{b}_0)' \mathbf{X}'\mathbf{X}(\mathbf{b} - \mathbf{b}_0)}_{\geq 0}.$$

Donc $S(\mathbf{b}_0) \geq S(\mathbf{b})$, avec égalité seulement si $\mathbf{b}_0 = \mathbf{b}$ (plein rang). Aucun calcul différentiel nécessaire !

4 Le cas de la régression bivariée

4.1 Obtention des formules [16] à partir de [15]

Modèle $y_i = \beta_1 + \beta_2 x_i + \epsilon_i$ (attention : les notes écrivent β_0, β_1 dans le modèle mais b_1, b_2 pour les estimateurs ; on utilise ici $b_1 =$ constante, $b_2 =$ pente).

Calcul détaillé

On minimise $S = \sum_{i=1}^n (y_i - b_1 - b_2 x_i)^2$. Dérivées partielles (règle de la chaîne : dérivée de $u^2 = 2u \cdot u'$) :

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^n (y_i - b_1 - b_2 x_i) = 0 \iff nb_1 + b_2 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \quad [18]$$

$$\frac{\partial S}{\partial b_2} = -2 \sum_{i=1}^n x_i (y_i - b_1 - b_2 x_i) = 0 \iff b_1 \sum_{i=1}^n x_i + b_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \quad [19]$$

Constante. Divisons [18] par n : $b_1 + b_2 \bar{x} = \bar{y}$, donc $b_1 = \bar{y} - b_2 \bar{x}$.

Pente. Remplaçons b_1 dans [19] : $(\bar{y} - b_2 \bar{x})n\bar{x} + b_2 \sum x_i^2 = \sum x_i y_i$, soit

$$b_2 \left(\sum x_i^2 - n\bar{x}^2 \right) = \sum x_i y_i - n\bar{x}\bar{y}.$$

Or $\sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2$ et $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}$. D'où

$$b_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}.$$

La seconde écriture de [16], $\sum (x_i - \bar{x})y_i / \sum (x_i - \bar{x})^2$, vient de $\sum (x_i - \bar{x})\bar{y} = \bar{y} \sum (x_i - \bar{x}) = 0$ (la somme des écarts à la moyenne est nulle).

Intuition

La pente est la covariance entre x et y divisée par la variance de x : « de combien y varie avec x , rapporté à combien x varie ». Si x ne varie pas du tout ($\sum (x_i - \bar{x})^2 = 0$), la pente est indéfinie : c'est exactement la violation du plein rang (la colonne x serait proportionnelle à la constante).

4.2 Le lien avec la forme matricielle [20]–[21]

Les équations [18]–[19] forment un système linéaire 2×2 ; le cours montre que la matrice du système est $\mathbf{X}'\mathbf{X}$ et le membre de droite $\mathbf{X}'\mathbf{y}$ avec $\mathbf{X} = [\mathbf{1} \ x]$. La formule générale $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ contient donc la formule bivariée comme cas particulier.

Exemple numérique

Données : $x = (1, 2, 3, 4, 5)$, $y = (2, 4, 5, 4, 5)$. On a $n = 5$, $\sum x_i = 15$, $\sum x_i^2 = 55$, $\sum y_i = 20$, $\sum x_i y_i = 66$.

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}, \quad \mathbf{X}'\mathbf{y} = \begin{pmatrix} 20 \\ 66 \end{pmatrix},$$

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{5 \cdot 55 - 15^2} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}.$$

(Inverse d'une 2×2 : $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$.)

$$\mathbf{b} = \frac{1}{50} \begin{pmatrix} 55 \cdot 20 - 15 \cdot 66 \\ -15 \cdot 20 + 5 \cdot 66 \end{pmatrix} = \frac{1}{50} \begin{pmatrix} 110 \\ 30 \end{pmatrix} = \begin{pmatrix} 2,2 \\ 0,6 \end{pmatrix}.$$

Vérification avec les formules bivariées : $\bar{x} = 3$, $\bar{y} = 4$, $\sum (x_i - \bar{x})(y_i - \bar{y}) = 4 + 0 + 0 + 0 + 2 = 6$, $\sum (x_i - \bar{x})^2 = 10$, donc $b_2 = 0,6$ et $b_1 = 4 - 0,6 \times 3 = 2,2$. ✓

Valeurs prédites $\hat{y} = (2,8; 3,4; 4,0; 4,6; 5,2)$, résidus $e = (-0,8; 0,6; 1,0; -0,6; -0,2)$. Cet exemple sera réutilisé tout au long du document.




FIGURE 1 – L'exemple numérique : la droite MCO passe par le point moyen et minimise la somme des carrés des segments verticaux.

Pour aller plus loin / histoire

La méthode des moindres carrés a été publiée pour la première fois par **Adrien-Marie Legendre** en 1805, en annexe de ses *Nouvelles méthodes pour la détermination des orbites des comètes*; son exposé était purement algébrique. **Carl Friedrich Gauss** la publie en 1809 dans *Theoria motus corporum coelestium* en affirmant l'utiliser depuis 1795 (il s'en serait servi en 1801 pour retrouver l'astéroïde Cérés), ce qui provoqua une célèbre querelle de priorité. L'apport de Gauss fut de donner à la méthode un fondement probabiliste : il montra qu'elle est optimale lorsque les erreurs suivent la loi qu'on appelle aujourd'hui « normale » ou « gaussienne ».

5 Propriétés numériques des MCO (Greene 3.2.3)

5.1 Numérique contre statistique

- **Propriétés numériques** : vraies *pour n'importe quel jeu de données*, par construction de l'algorithme. Elles ne demandent aucune hypothèse sur les erreurs. Exemple : « la somme des résidus est nulle ».
- **Propriétés statistiques** : décrivent le comportement de $\mathbf{b}$ *en échantillons répétés* (espérance, variance, loi). Elles reposent sur des hypothèses sur la façon dont les données sont générées. Exemple : « $\mathbf{b}$ est sans biais ».

Intuition

Une propriété numérique se vérifie sur votre fichier de données avec une calculatrice. Une propriété statistique ne peut pas se vérifier sur un seul échantillon : elle parle de ce qui se passerait si l'on recommençait l'expérience un grand nombre de fois (d'où l'intérêt de Monte Carlo, section 12).

5.2 Les équations normales [24] et l'orthogonalité [25]

Les équations normales $\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y}$ se réécrivent $\mathbf{X}'(\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{0}$, c'est-à-dire

$$\boxed{\mathbf{X}'\mathbf{e} = \mathbf{0}} \quad \Longleftrightarrow \quad \sum_{i=1}^n x_{ik} e_i = 0 \quad \text{pour chaque variable } k = 1, \dots, K.$$

(Les notes écrivent $\mathbf{e} = \mathbf{X}\mathbf{b} - \mathbf{y}$ en [24] ; la bonne définition est $\mathbf{e} = \mathbf{y} - \mathbf{X}\mathbf{b}$, mais le signe n'a pas d'importance puisque le résultat vaut zéro.)

Intuition

Chaque variable explicative est « non corrélée » (orthogonale) avec les résidus *dans l'échantillon*. S'il restait une corrélation entre x_k et $\mathbf{e}$, on pourrait encore ajuster le coefficient de x_k pour mieux prédire y : on ne serait pas au minimum. Les résidus sont ce qui reste une fois que les $\mathbf{X}$ ont « tout expliqué » de ce qu'elles pouvaient expliquer linéairement.

Attention / piège fréquent

$\mathbf{X}'\mathbf{e} = \mathbf{0}$ est une propriété *numérique* toujours vraie. Elle ne dit **rien** sur l'hypothèse $\mathbb{E}[\epsilon | \mathbf{X}] = \mathbf{0}$ (erreurs non corrélées avec $\mathbf{X}$ dans la population). On ne peut donc pas « tester l'exogénéité » en calculant la corrélation entre $\mathbf{X}$ et les résidus : elle vaut zéro par construction !

5.3 Les conséquences quand le modèle contient une constante

Si la première colonne de $\mathbf{X}$ est $\mathbf{1} = (1, \dots, 1)'$, la première ligne de $\mathbf{X}'\mathbf{e} = \mathbf{0}$ est $\mathbf{1}'\mathbf{e} = \sum_{i=1}^n e_i = 0$. On en déduit :

1. **Somme (et moyenne) des résidus nulle** : $\sum e_i = 0$, $\bar{e} = 0$.
2. **La régression passe par le point moyen** [27]–[29] : $\sum e_i = \sum (y_i - \mathbf{x}_i'\mathbf{b}) = 0$, divisé par n : $\bar{y} = \bar{\mathbf{x}}'\mathbf{b}$, où $\bar{\mathbf{x}}$ est le vecteur des moyennes des variables. En bivarié : $\bar{y} = b_1 + b_2\bar{x}$.
3. **Moyenne des prédictions = moyenne observée** [30]–[31] : puisque $\mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}$, on a $\sum y_i = \sum \hat{y}_i + \sum e_i = \sum \hat{y}_i$, donc $\bar{\hat{y}} = \bar{y}$.
4. (Complément) **Les prédictions sont orthogonales aux résidus** : $\hat{\mathbf{y}}'\mathbf{e} = \mathbf{b}'\mathbf{X}'\mathbf{e} = 0$.

Exemple numérique

Avec l'exemple : $\sum e_i = -0,8 + 0,6 + 1,0 - 0,6 - 0,2 = 0 \checkmark$; $\sum x_i e_i = -0,8 + 1,2 + 3,0 - 2,4 - 1,0 = 0 \checkmark$; $\hat{y} = (2,8 + 3,4 + 4 + 4,6 + 5,2)/5 = 4 = \bar{y} \checkmark$.

Attention / piège fréquent

Sans constante, ces propriétés 1–3 **ne tiennent plus** en général : les résidus ne somment pas à zéro et, comme on le verra, le R^2 usuel peut même devenir négatif. C'est une raison de toujours inclure une constante sauf justification théorique forte.

6 Les matrices de projection P et M (Greene 3.2.4)

6.1 Définitions

En remplaçant $\mathbf{b}$ par sa formule :

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{b} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{\mathbf{P}} \mathbf{y}, \quad \mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \underbrace{(\mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')}_{\mathbf{M}} \mathbf{y}.$$

$\mathbf{P}$ (« matrice chapeau », *hat matrix*, car elle met un chapeau sur $\mathbf{y}$) et $\mathbf{M}$ (« matrice créatrice de résidus », *residual maker*) sont $n \times n$ et ne dépendent que de $\mathbf{X}$.

6.2 Démonstration des propriétés

Calcul détaillé

Symétrie. $\mathbf{P}' = (\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')' = \mathbf{X}[(\mathbf{X}'\mathbf{X})^{-1}]' \mathbf{X}' = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{P}$, car l'inverse d'une matrice symétrique est symétrique. Alors $\mathbf{M}' = \mathbf{I}' - \mathbf{P}' = \mathbf{I} - \mathbf{P} = \mathbf{M}$.

Idempotence. $\mathbf{PP} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \underbrace{\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}}_{=\mathbf{I}_K} \mathbf{X}' = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{P}$.

$\mathbf{MM} = (\mathbf{I} - \mathbf{P})(\mathbf{I} - \mathbf{P}) = \mathbf{I} - 2\mathbf{P} + \mathbf{PP} = \mathbf{I} - 2\mathbf{P} + \mathbf{P} = \mathbf{I} - \mathbf{P} = \mathbf{M}$.

Action sur X. $\mathbf{PX} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{X}$ et $\mathbf{MX} = \mathbf{X} - \mathbf{PX} = \mathbf{0}$.

Orthogonalité mutuelle. $\mathbf{PM} = \mathbf{P} - \mathbf{PP} = \mathbf{0}$.

Intuition

- *Idempotente* : projeter deux fois = projeter une fois. Si on régresse $\hat{\mathbf{y}}$ sur $\mathbf{X}$, on retrouve $\hat{\mathbf{y}}$ (il est déjà « dans » l'espace de $\mathbf{X}$). Si on régresse les résidus $\mathbf{e}$ sur $\mathbf{X}$, on obtient des coefficients nuls et les mêmes résidus.
- $\mathbf{PX} = \mathbf{X}$: régresser une variable explicative sur toutes les variables explicatives l'explique parfaitement.
- $\mathbf{MX} = \mathbf{0}$: les résidus de cette régression sont nuls.

6.3 Interprétation géométrique

Voyons $\mathbf{y}$ comme un point de $\mathbb{R}^n$. Les colonnes de $\mathbf{X}$ engendrent un sous-espace de dimension K (un « plan » si $K = 2$). Les MCO cherchent le point $\mathbf{X}\mathbf{b}$ de ce plan le plus proche de $\mathbf{y}$ au sens de la distance euclidienne ($S(\mathbf{b}_0) = \|\mathbf{y} - \mathbf{X}\mathbf{b}_0\|^2$). Le point le plus proche est le **pied de la perpendiculaire** : $\hat{\mathbf{y}} = \mathbf{P}\mathbf{y}$. Le résidu $\mathbf{e} = \mathbf{M}\mathbf{y}$ est le segment perpendiculaire au plan. C'est exactement le théorème de Pythagore qui donnera la décomposition de la variance.

$$y = Py + My : \text{projection orthogonale de } y \text{ sur } \text{Col}(X)$$




FIGURE 2 – Géométrie des MCO avec $n = 3$ et $K = 2$: $\hat{y}$ est l'ombre de y sur le plan engendré par les colonnes de X ; le résidu est perpendiculaire à ce plan.

À retenir

- $y = Py + My = \hat{y} + e$, avec $\hat{y} \perp e$.
- Pythagore : $y'y = \hat{y}'\hat{y} + e'e$.
- $\text{tr}(\mathbf{P}) = K$ et $\text{tr}(\mathbf{M}) = n - K$ (dimensions des deux sous-espaces ; voir §11).
- Les éléments diagonaux p_{ii} de $\mathbf{P}$ s'appellent les *leviers* (*leverage*) : ils mesurent l'influence potentielle de l'observation i sur sa propre prédiction.

7 Le théorème de Frisch-Waugh-Lovell (Greene 3.3)

7.1 Énoncé

On partitionne $X = [X_1 \ X_2]$ et $\beta = (\beta'_1, \beta'_2)'$: $y = X_1\beta_1 + X_2\beta_2 + \epsilon$. On note $M_1 = I - X_1(X_1'X_1)^{-1}X_1'$ la matrice qui crée les résidus d'une régression sur X_1 .

Théorème (FWL). *Le coefficient b_2 de la régression complète de y sur $[X_1 \ X_2]$ est identique au coefficient obtenu en :*

1. *régressant y sur X_1 et gardant les résidus $\tilde{y} = M_1y$;*
2. *régressant chaque colonne de X_2 sur X_1 et gardant les résidus $\tilde{X}_2 = M_1X_2$;*
3. *régressant $\tilde{y}$ sur $\tilde{X}_2$: $b_2 = (\tilde{X}_2'\tilde{X}_2)^{-1}\tilde{X}_2'\tilde{y} = (X_2'M_1X_2)^{-1}X_2'M_1y$.*

De plus, les résidus de l'étape 3 sont identiques aux résidus de la régression complète.

7.2 La démonstration complète (l'étape « après manipulation »)

Calcul détaillé

Les équations normales partitionnées [41] donnent

$$\mathbf{X}'_1 \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}'_1 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_1 \mathbf{y} \quad [42]$$

$$\mathbf{X}'_2 \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}'_2 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 \mathbf{y} \quad [43]$$

De [42] : $\mathbf{b}_1 = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 (\mathbf{y} - \mathbf{X}_2 \mathbf{b}_2)$ [45].

On remplace dans [43] :

$$\mathbf{X}'_2 \mathbf{X}_1 (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 (\mathbf{y} - \mathbf{X}_2 \mathbf{b}_2) + \mathbf{X}'_2 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 \mathbf{y}.$$

Reconnaissons $\mathbf{P}_1 = \mathbf{X}_1 (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1$:

$$\mathbf{X}'_2 \mathbf{P}_1 \mathbf{y} - \mathbf{X}'_2 \mathbf{P}_1 \mathbf{X}_2 \mathbf{b}_2 + \mathbf{X}'_2 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 \mathbf{y} \implies \mathbf{X}'_2 (\mathbf{I} - \mathbf{P}_1) \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 (\mathbf{I} - \mathbf{P}_1) \mathbf{y}.$$

Comme $\mathbf{I} - \mathbf{P}_1 = \mathbf{M}_1$: $\mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2 \mathbf{b}_2 = \mathbf{X}'_2 \mathbf{M}_1 \mathbf{y}$, d'où [46] :

$$\mathbf{b}_2 = (\mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{M}_1 \mathbf{y}.$$

Enfin, comme $\mathbf{M}_1$ est symétrique et idempotente, $\mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2 = \mathbf{X}'_2 \mathbf{M}'_1 \mathbf{M}_1 \mathbf{X}_2 = (\mathbf{M}_1 \mathbf{X}_2)' (\mathbf{M}_1 \mathbf{X}_2)$ et $\mathbf{X}'_2 \mathbf{M}_1 \mathbf{y} = (\mathbf{M}_1 \mathbf{X}_2)' (\mathbf{M}_1 \mathbf{y})$: c'est bien la formule MCO de la régression de $\mathbf{M}_1 \mathbf{y}$ sur $\mathbf{M}_1 \mathbf{X}_2$.

Remarque sur la seconde preuve du cours [47]–[49]

Le cours prémultiplie le modèle par $\mathbf{M}_1$: $\mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 \mathbf{X}_2 \beta_2 + \mathbf{M}_1 \epsilon$ (car $\mathbf{M}_1 \mathbf{X}_1 = \mathbf{0}$). C'est un argument sur le *modèle* (la population). La preuve rigoureuse, au niveau de l'*estimateur*, fait la même chose sur la décomposition $\mathbf{y} = \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}_2 \mathbf{b}_2 + \mathbf{e}$:

$$\mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 \mathbf{X}_2 \mathbf{b}_2 + \mathbf{M}_1 \mathbf{e} = \mathbf{M}_1 \mathbf{X}_2 \mathbf{b}_2 + \mathbf{e},$$

car $\mathbf{e}$ est orthogonal à $\mathbf{X}_1$ (donc $\mathbf{M}_1 \mathbf{e} = \mathbf{e}$). En multipliant par $(\mathbf{M}_1 \mathbf{X}_2)'$ et en utilisant $\mathbf{X}'_2 \mathbf{M}_1 \mathbf{e} = \mathbf{X}'_2 \mathbf{e} = \mathbf{0}$, on retrouve [46]. Au passage, on voit que les résidus de l'étape 3 sont exactement $\mathbf{e}$.

7.3 Pourquoi ce théorème est si important

Intuition

$\mathbf{M}_1 \mathbf{X}_2$ est la partie de $\mathbf{X}_2$ que $\mathbf{X}_1$ ne peut pas expliquer. Le coefficient $\mathbf{b}_2$ n'utilise donc que la variation de $\mathbf{X}_2$ « nettoyée » de $\mathbf{X}_1$: c'est la traduction mathématique précise de l'expression « **toutes choses égales par ailleurs** » (*ceteris paribus*). Dans l'équation de salaire, le coefficient de la scolarité mesure l'association entre salaire et la partie de la scolarité non prédite par l'expérience.

Applications classiques :

- **Tendance temporelle** (le cas étudié par Frisch et Waugh en 1933) : régresser y sur x et une tendance t donne le même coefficient de x que régresser y « détendancié » sur x « détendancié ».
- **Constante** : si $\mathbf{X}_1 = \iota$, $\mathbf{M}_1 = \mathbf{M}^0$ centre les variables. Donc la pente d'une régression avec

constante = pente de la régression *sans constante* des variables centrées. C'est pourquoi la formule bivariée [16] fait intervenir $x_i - \bar{x}$ et $y_i - \bar{y}$.

- **Effets fixes** (données de panel) : inclure une indicatrice par individu revient à retirer à chaque variable sa moyenne individuelle (estimateur « within »).
- **Graphiques de régression partielle** (*added-variable plots*) : on représente $\mathbf{M}_1\mathbf{y}$ contre $\mathbf{M}_1\mathbf{x}_2$; la pente de ce nuage est exactement b_2 .
- **Biais de variable omise** : si on omet $\mathbf{X}_2$, on estime $\mathbf{b}_1^{\text{court}} = (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{y}$. Par [45], $\mathbf{b}_1^{\text{court}} = \mathbf{b}_1 + (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{X}_2\mathbf{b}_2$: l'écart est nul seulement si $\mathbf{X}_2$ n'a pas d'effet ($\mathbf{b}_2 = \mathbf{0}$) ou si $\mathbf{X}_1 \perp \mathbf{X}_2$.

Vérification numérique (simulation, $n = 200$)

Modèle $y = 1 + 2x_1 - x_2 + \epsilon$ avec $x_2 = 0,7x_1 + u$ (variables corrélées). La régression complète donne $b_2 = -1,17573366$; la procédure FWL en trois étapes donne $b_2 = -1,17573366$. Identiques à la dernière décimale, comme le théorème l'affirme.

Attention / piège fréquent

Les *coefficients* sont identiques, mais l'écart-type affiché par le logiciel à l'étape 3 est légèrement faux : il divise la somme des carrés des résidus par $n - K_2$ au lieu de $n - K$ (il « ignore » que K_1 paramètres ont été estimés à l'étape 1). Il faut corriger par le facteur $\sqrt{(n - K_2)/(n - K)}$.

Pour aller plus loin / histoire

Le résultat remonte en fait à **George Udny Yule** (1907), qui analysait déjà les régressions partielles. **Ragnar Frisch** (premier prix Nobel d'économie, 1969) et **Frederick Waugh** l'établissent en 1933 dans « Partial Time Regressions as Compared with Individual Trends » (*Econometrica*), avec une preuve par déterminants et règle de Cramer, pour montrer qu'on peut soit inclure une tendance, soit détendancier les séries. **Michael Lovell** (1963, *JASA*) généralise le résultat et en donne la preuve matricielle simple par projections, d'où le nom « FWL » (certains auteurs disent désormais « YFWL »).

8 Le coefficient de détermination R^2 (Greene 3.5)

8.1 La matrice $\mathbf{M}^0$ qui centre

$\mathbf{M}^0 = \mathbf{I}_n - \boldsymbol{\iota}(\boldsymbol{\iota}'\boldsymbol{\iota})^{-1}\boldsymbol{\iota}' = \mathbf{I}_n - \frac{1}{n}\boldsymbol{\iota}\boldsymbol{\iota}'$ est la matrice $\mathbf{M}$ de la régression sur une constante seule. Or la régression de $\mathbf{y}$ sur une constante donne $b = \bar{y}$ (la moyenne), donc les résidus sont $y_i - \bar{y}$:

$$\mathbf{M}^0\mathbf{y} = (y_1 - \bar{y}, \dots, y_n - \bar{y})', \quad \mathbf{P}^0\mathbf{y} = (\bar{y}, \dots, \bar{y})'.$$

C'est ce que l'exemple $n = 3$ du cours [53]–[57] vérifie à la main. Comme toute matrice $\mathbf{M}$, $\mathbf{M}^0$ est symétrique et idempotente, d'où

$$\mathbf{y}'\mathbf{M}^0\mathbf{y} = (\mathbf{M}^0\mathbf{y})'(\mathbf{M}^0\mathbf{y}) = \sum_{i=1}^n (y_i - \bar{y})^2.$$

8.2 La décomposition $SCT = SCR + SCE$ [58]–[66]

Calcul détaillé

Partons de $\mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{e}$ et multiplions par $\mathbf{M}^0$: $\mathbf{M}^0\mathbf{y} = \mathbf{M}^0\mathbf{X}\mathbf{b} + \mathbf{M}^0\mathbf{e}$. Avec une constante, $\bar{e} = 0$, donc $\mathbf{M}^0\mathbf{e} = \mathbf{e} - \bar{e}\mathbf{1} = \mathbf{e}$. Ainsi $\mathbf{M}^0\mathbf{y} = \mathbf{M}^0\mathbf{X}\mathbf{b} + \mathbf{e}$. On calcule le carré de la norme :

$$\mathbf{y}'\mathbf{M}^0\mathbf{y} = \mathbf{b}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\mathbf{b} + 2\mathbf{b}'\mathbf{X}'\mathbf{M}^0\mathbf{e} + \mathbf{e}'\mathbf{e}.$$

Le terme croisé est nul : $\mathbf{X}'\mathbf{M}^0\mathbf{e} = \mathbf{X}'\mathbf{e} = \mathbf{0}$. Donc

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{SCT} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SCR} + \underbrace{\sum_{i=1}^n e_i^2}_{SCE}.$$

(Pour SCR : $\mathbf{M}^0\mathbf{X}\mathbf{b} = \mathbf{M}^0\hat{\mathbf{y}}$ est le vecteur des $\hat{y}_i - \bar{\hat{y}} = \hat{y}_i - \bar{y}$.)

Intuition

C'est Pythagore dans l'espace des variables centrées : la variation totale de y autour de sa moyenne se décompose en une partie « expliquée » par la régression et une partie « inexpliquée » (résiduelle), sans terme croisé car $\hat{\mathbf{y}} \perp \mathbf{e}$.

Attention aux sigles !

Les notes utilisent les sigles français : SCR = somme des carrés de la *régression* (expliquée), SCE = somme des carrés des *erreurs* (résidus). Or en anglais, selon les manuels, *SSR* désigne tantôt « *sum of squared residuals* » (= notre SCE !) tantôt « *regression sum of squares* », et *SSE* tantôt « *explained* » tantôt « *error* ». Les notes elles-mêmes passent de SCE à « SSE » en section 2.4.1. Toujours vérifier la définition utilisée plutôt que le sigle.

8.3 Définition et interprétation du R^2

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT} = 1 - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{y}'\mathbf{M}^0\mathbf{y}} \in [0, 1] \quad (\text{avec constante}).$$

- Proportion de la variance de y expliquée (linéairement) par les x .
- Propriété utile : $R^2 = [\widehat{\text{corr}}(y, \hat{y})]^2$; en bivarié, $R^2 = [\widehat{\text{corr}}(x, y)]^2$.
- Un R^2 faible ne veut pas dire que le modèle est « faux » ni que les coefficients sont mal estimés (en microéconomie appliquée, $R^2 \approx 0,1$ est courant). Un R^2 élevé ne veut pas dire qu'on a un effet causal (deux séries avec tendance ont souvent un R^2 énorme : régression fallacieuse).

Exemple numérique

$SCT = \sum (y_i - 4)^2 = 4 + 0 + 1 + 0 + 1 = 6$; $SCE = 0,64 + 0,36 + 1 + 0,36 + 0,04 = 2,4$; $SCR = \sum (\hat{y}_i - 4)^2 = 1,44 + 0,36 + 0 + 0,36 + 1,44 = 3,6$. On vérifie $6 = 3,6 + 2,4$ ✓, et $R^2 = 3,6/6 = 0,6$.

Attention / piège fréquent

Sans constante, $\mathbf{M}^0 \mathbf{e} \neq \mathbf{e}$ en général, la décomposition échoue et $1 - \text{SCE}/\text{SCT}$ peut être **négatif**. Les logiciels rapportent alors un « R^2 non centré » $(1 - \mathbf{e}'\mathbf{e}/\mathbf{y}'\mathbf{y})$, qui n'est pas comparable au R^2 usuel.

8.4 Pourquoi le R^2 augmente quand on ajoute une variable [68]–(fin 2.4.1)

Le résultat : si l'on ajoute une variable $\mathbf{x}_2$ à $\mathbf{X}_1$,

$$\text{SCE}_2 = \text{SCE}_1 - \tilde{b}_2^2 \mathbf{x}_2' \mathbf{M}_1 \mathbf{x}_2 \leq \text{SCE}_1$$

La démonstration en version courte (via FWL)

Par FWL, les résidus du grand modèle s'obtiennent en régressant $\mathbf{e}_1 = \mathbf{M}_1 \mathbf{y}$ sur $\tilde{\mathbf{x}}_2 = \mathbf{M}_1 \mathbf{x}_2$: $\mathbf{e}_2 = \mathbf{e}_1 - \tilde{\mathbf{x}}_2 \tilde{b}_2$ avec $\tilde{b}_2 = \tilde{\mathbf{x}}_2' \mathbf{e}_1 / \tilde{\mathbf{x}}_2' \tilde{\mathbf{x}}_2$. Donc

$$\mathbf{e}_2' \mathbf{e}_2 = \mathbf{e}_1' \mathbf{e}_1 - 2 \tilde{b}_2 \tilde{\mathbf{x}}_2' \mathbf{e}_1 + \tilde{b}_2^2 \tilde{\mathbf{x}}_2' \tilde{\mathbf{x}}_2.$$

Or $\tilde{\mathbf{x}}_2' \mathbf{e}_1 = \tilde{b}_2 \tilde{\mathbf{x}}_2' \tilde{\mathbf{x}}_2$ (définition de $\tilde{b}_2$). D'où $\mathbf{e}_2' \mathbf{e}_2 = \mathbf{e}_1' \mathbf{e}_1 - \tilde{b}_2^2 \tilde{\mathbf{x}}_2' \tilde{\mathbf{x}}_2 = \mathbf{e}_1' \mathbf{e}_1 - \tilde{b}_2^2 \mathbf{x}_2' \mathbf{M}_1 \mathbf{x}_2$. Comme $\mathbf{x}_2' \mathbf{M}_1 \mathbf{x}_2 = \|\mathbf{M}_1 \mathbf{x}_2\|^2 \geq 0$ et $\tilde{b}_2^2 \geq 0$, la SCE ne peut que baisser (ou rester égale si $\tilde{b}_2 = 0$).

La démonstration longue du cours [75]–[76] fait exactement ce calcul, en développant le carré et en montrant que le terme du milieu $-2 \tilde{b}_2 \mathbf{x}_2' \mathbf{M}_1 \mathbf{e}_1$ vaut $-2 \tilde{b}_2^2 \mathbf{x}_2' \mathbf{M}_1 \mathbf{x}_2$.

Intuition

Argument sans calcul : le grand modèle peut toujours reproduire le petit en posant $\tilde{b}_2 = 0$. Minimiser sur un ensemble plus grand ne peut donner qu'un minimum plus petit ou égal. Ajouter n'importe quelle variable, même générée au hasard, fait donc baisser SCE et monter R^2 . Avec $K = n$ variables (plein rang), l'ajustement est parfait : $R^2 = 1$.

8.5 Complément : le R^2 ajusté et les critères d'information

Pour comparer des modèles ayant des nombres de variables différents, on pénalise le nombre de paramètres (Theil, 1961) :

$$\bar{R}^2 = 1 - \frac{\text{SCE}/(n - K)}{\text{SCT}/(n - 1)} = 1 - \frac{n - 1}{n - K} (1 - R^2).$$

Il n'augmente lorsqu'on ajoute une variable que si la baisse de SCE « paie » la perte d'un degré de liberté (on peut montrer : si et seulement si la statistique t de la nouvelle variable est supérieure à 1 en valeur absolue). Des critères plus exigeants existent : AIC = $\ln(\text{SCE}/n) + 2K/n$ et BIC (ou critère de Schwarz) = $\ln(\text{SCE}/n) + K \ln(n)/n$ (Greene, ch. 5).




FIGURE 3 – Simulation ($n = 50$) : le vrai modèle n’a qu’une variable. On ajoute une à une 45 variables de pur bruit. Le R^2 passe de 0,12 à 0,94 alors qu’aucune de ces variables n’a de lien avec y ; le R^2 ajusté, lui, stagne puis devient négatif.

9 Propriétés statistiques des MCO (Greene 4.1–4.3)

9.1 Les hypothèses du modèle classique, une par une

Hypothèse	Signification	Exemple de violation
H1 Linéarité	$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$: linéaire <i>dans les paramètres</i> (x^2 , $\ln x$ sont permis)	$y = \beta_1 x^{\beta_2} + \epsilon$ (non linéaire en β_2)
H2 Plein rang	aucune colinéarité parfaite ; $\mathbf{X}'\mathbf{X}$ inversible	piège des indicatrices ; $n < K$
H3 Exogénéité $\mathbb{E}[\boldsymbol{\epsilon} \mathbf{X}] = \mathbf{0}$	les $\mathbf{X}$ ne contiennent aucune information sur les erreurs	variable omise corrélée (habileté et scolarité), simultanéité, erreur de mesure sur x
H4 $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mathbf{X}] = \sigma^2 \mathbf{I}_n$	homoscédasticité (même variance) et absence d’autocorrélation	variance du revenu qui croît avec le revenu ; chocs persistants en séries temporelles
H5 Normalité	$\boldsymbol{\epsilon} \mathbf{X} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$	erreurs asymétriques ou à queues épaisses

Lecture de H4 : l’élément (i, j) de $\boldsymbol{\epsilon}\boldsymbol{\epsilon}'$ est $\epsilon_i \epsilon_j$. Donc $\mathbb{E}[\epsilon_i^2 | \mathbf{X}] = \sigma^2$ (diagonale : même variance pour tous) et $\mathbb{E}[\epsilon_i \epsilon_j | \mathbf{X}] = 0$ pour $i \neq j$ (hors diagonale : pas de corrélation entre observations).

À retenir

- Absence de biais : H1, H2, H3.
- Formule de variance $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ et Gauss-Markov : H1–H4.
- Loi exacte (normale) de $\mathbf{b}$, tests t et F exacts en petit échantillon : H1–H5.

9.2 Absence de biais [79]–[80]

Calcul détaillé

Étape 1 — écrire l'estimateur en fonction de l'erreur (substituer le vrai modèle) :

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \underbrace{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}}_{\mathbf{I}_K}\boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon} = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}.$$

Cette « décomposition de l'erreur d'échantillonnage » $\mathbf{b} - \boldsymbol{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}$ est la clé de toutes les preuves qui suivent.

Étape 2 — prendre l'espérance conditionnelle à $\mathbf{X}$: conditionnellement à $\mathbf{X}$, la matrice $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ est une constante et sort de l'espérance :

$$\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \boldsymbol{\beta} + \mathbf{0} = \boldsymbol{\beta}.$$

Étape 3 (complément) — loi des espérances itérées : $\mathbb{E}[\mathbf{b}] = \mathbb{E}[\mathbb{E}[\mathbf{b} \mid \mathbf{X}]] = \mathbb{E}[\boldsymbol{\beta}] = \boldsymbol{\beta}$. L'estimateur est donc sans biais aussi inconditionnellement.

Intuition

« Sans biais » ne veut pas dire que $\mathbf{b} = \boldsymbol{\beta}$ dans votre échantillon ! Cela veut dire que si l'on répétait l'expérience une infinité de fois, la moyenne des $\mathbf{b}$ obtenus serait $\boldsymbol{\beta}$: l'estimateur ne se trompe pas *systématiquement* dans une direction. L'étude de Monte Carlo (section 12) le visualise.

Attention / piège fréquent

Si H3 échoue (par exemple une variable omise corrélée avec $\mathbf{X}$), $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] \neq \mathbf{0}$ et $\mathbf{b}$ est biaisé — et ce biais ne disparaît pas quand n augmente. C'est le problème central de l'économétrie appliquée (d'où les variables instrumentales, plus tard dans le cours).

9.3 Variance [81]–[82]

Calcul détaillé

Par définition, $\text{Var}(\mathbf{b} \mid \mathbf{X}) = \mathbb{E}[(\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})' \mid \mathbf{X}]$, une matrice $K \times K$: la diagonale contient les variances des b_k , hors diagonale les covariances.

$$\begin{aligned} (\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})' &= ((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon})((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon})' \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{X}[(\mathbf{X}'\mathbf{X})^{-1}]' & (\mathbf{AB})' &= \mathbf{B}'\mathbf{A}' \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} & (\mathbf{X}'\mathbf{X})^{-1} &\text{symétrique.} \end{aligned}$$

Espérance conditionnelle (tout sauf $\boldsymbol{\epsilon}\boldsymbol{\epsilon}'$ est constant sachant $\mathbf{X}$) puis H4 :

$$\text{Var}(\mathbf{b} \mid \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}]}_{\sigma^2\mathbf{I}_n}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}.$$

Cas bivarié : ce qui rend un estimateur précis

En bivarié, l'élément de $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ correspondant à la pente est

$$\text{Var}(b_2 | \mathbf{X}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{n \widehat{\text{Var}}(x)}.$$

La pente est estimée plus précisément quand : (i) les erreurs sont peu dispersées (σ^2 petit) ; (ii) on a beaucoup d'observations (n grand) ; (iii) x varie beaucoup dans l'échantillon. Avec plusieurs variables, on montre (via FWL) que $\text{Var}(b_k | \mathbf{X}) = \sigma^2 / [(1 - R_k^2) \sum (x_{ik} - \bar{x}_k)^2]$, où R_k^2 est le R^2 de la régression de x_k sur les autres variables : la **multicolinéarité** (non parfaite) gonfle la variance. Le facteur $1/(1 - R_k^2)$ s'appelle le VIF (*variance inflation factor*).

10 Le théorème de Gauss-Markov (Greene 4.3.5)

Théorème. Sous $H1-H4$, l'estimateur MCO $\mathbf{b}$ est le **meilleur estimateur linéaire sans biais** (BLUE : Best Linear Unbiased Estimator) : pour tout autre estimateur linéaire sans biais $\mathbf{b}^*$, la matrice $\text{Var}(\mathbf{b}^* | \mathbf{X}) - \text{Var}(\mathbf{b} | \mathbf{X})$ est semi-définie positive.

10.1 Décortiquer l'énoncé

- **Linéaire** : $\mathbf{b}^* = \mathbf{C}\mathbf{y}$, avec $\mathbf{C}$ ($K \times n$) qui peut dépendre de $\mathbf{X}$ mais pas de $\mathbf{y}$. Les MCO en font partie avec $\mathbf{C} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. Autres exemples : n'utiliser que la moitié des observations ; en bivarié, la pente entre le premier et le dernier point $(y_n - y_1)/(x_n - x_1)$; les moindres carrés pondérés.
- **Sans biais** : $\mathbb{E}[\mathbf{C}\mathbf{y} | \mathbf{X}] = \mathbf{C}\mathbf{X}\boldsymbol{\beta} + \mathbf{C}\mathbb{E}[\boldsymbol{\epsilon} | \mathbf{X}] = \mathbf{C}\mathbf{X}\boldsymbol{\beta}$. Pour que cela vaille $\boldsymbol{\beta}$ quel que soit $\boldsymbol{\beta}$, il faut $\mathbf{C}\mathbf{X} = \mathbf{I}_K$.
- **Meilleur** : de plus petite variance, au sens matriciel.

Attention / piège fréquent

Coquille dans les notes : il est écrit $\mathbf{C}\mathbf{X} = \mathbf{I}_n$. Or $\mathbf{C}$ est $K \times n$ et $\mathbf{X}$ est $n \times K$, donc $\mathbf{C}\mathbf{X}$ est $K \times K$: la condition correcte est $\mathbf{C}\mathbf{X} = \mathbf{I}_K$ (idem pour [87]–[90]).

10.2 La preuve, étape par étape

Calcul détaillé

1. **Variance de $\mathbf{b}^*$.** Avec $\mathbf{C}\mathbf{X} = \mathbf{I}_K$: $\mathbf{b}^* = \mathbf{C}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \boldsymbol{\beta} + \mathbf{C}\boldsymbol{\epsilon}$, donc $\text{Var}(\mathbf{b}^* | \mathbf{X}) = \mathbb{E}[\mathbf{C}\boldsymbol{\epsilon}\boldsymbol{\epsilon}'\mathbf{C}' | \mathbf{X}] = \mathbf{C}(\sigma^2\mathbf{I})\mathbf{C}' = \sigma^2\mathbf{C}\mathbf{C}'$.
2. **Écrire $\mathbf{C}$ comme « MCO + écart ».** $\mathbf{D} = \mathbf{C} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, soit $\mathbf{C} = \mathbf{D} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.
3. **Contrainte sur $\mathbf{D}$.** $\mathbf{C}\mathbf{X} = \mathbf{D}\mathbf{X} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{D}\mathbf{X} + \mathbf{I}_K = \mathbf{I}_K \Rightarrow \mathbf{D}\mathbf{X} = \mathbf{0}$ (et en transposant, $\mathbf{X}'\mathbf{D}' = \mathbf{0}$).
4. **Développer $\mathbf{C}\mathbf{C}'$.**

$$\begin{aligned} \mathbf{C}\mathbf{C}' &= (\mathbf{D} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\mathbf{D}' + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}) \\ &= \mathbf{D}\mathbf{D}' + \underbrace{\mathbf{D}\mathbf{X}}_{\mathbf{0}}(\mathbf{X}'\mathbf{X})^{-1} + (\mathbf{X}'\mathbf{X})^{-1}\underbrace{\mathbf{X}'\mathbf{D}'}_{\mathbf{0}} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}. \end{aligned}$$

Donc $\mathbf{C}\mathbf{C}' = \mathbf{D}\mathbf{D}' + (\mathbf{X}'\mathbf{X})^{-1}$ et

$$\text{Var}(\mathbf{b}^* | \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} + \sigma^2\mathbf{D}\mathbf{D}' = \text{Var}(\mathbf{b} | \mathbf{X}) + \sigma^2\mathbf{D}\mathbf{D}'.$$

5. Conclusion. $\mathbf{D}\mathbf{D}'$ est semi-définie positive (§1.5), donc la variance de $\mathbf{b}^*$ dépasse celle de $\mathbf{b}$ d'une matrice « positive ». Égalité seulement si $\mathbf{D} = \mathbf{0}$, c'est-à-dire $\mathbf{b}^* = \mathbf{b}$.

Intuition

« $\text{Var}(\mathbf{b}^*) - \text{Var}(\mathbf{b})$ semi-définie positive » implique en particulier que **chaque** coefficient est estimé avec une variance plus faible par MCO ($\text{Var}(b_k) \leq \text{Var}(b_k^*)$, en prenant $\mathbf{c} =$ vecteur unitaire k), et plus généralement toute combinaison linéaire $\mathbf{c}'\boldsymbol{\beta}$ (une prévision, un effet marginal) est estimée au mieux par $\mathbf{c}'\mathbf{b}$.

10.3 Ce que le théorème ne dit pas

- Il ne compare les MCO qu'aux estimateurs *linéaires* et *sans biais*. Un estimateur biaisé (par exemple la régression « ridge » ou LASSO en apprentissage automatique) peut avoir une erreur quadratique moyenne plus faible.
- Il ne requiert *pas* la normalité (H5). Sous normalité, on a un résultat plus fort : les MCO sont les meilleurs parmi *tous* les estimateurs sans biais, linéaires ou non (borne de Cramér-Rao).
- Si H4 échoue (hétéroscédasticité, autocorrélation), les MCO restent sans biais mais ne sont plus BLUE : c'est l'estimateur des moindres carrés généralisés (MCG) qui l'est (théorème d'Aitken, 1935). De plus, la formule $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ devient fausse (d'où les écarts-types « robustes » de White).

Pour aller plus loin / histoire

Gauss a démontré ce résultat en 1821–1823 (*Theoria combinationis observationum*), sans supposer la normalité. **Andreï Markov** le redémontre dans son manuel de probabilités de 1900. **Alexander Aitken** (1935) l'étend aux erreurs de matrice de variance quelconque (MCG). Bruce Hansen a récemment (*Econometrica*, 2022) proposé une « version moderne » du théorème qui retire la restriction aux estimateurs linéaires, ce qui a suscité un débat dans la littérature.

11 L'estimation de σ^2 (Greene 4.3.4)

11.1 Le problème

$\text{Var}(\mathbf{b} | \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ contient σ^2 , inconnu. L'idée naturelle serait $\frac{1}{n} \sum e_i^2$, l'analogue empirique de $\frac{1}{n} \sum \epsilon_i^2$. Mais les résidus sont systématiquement « trop petits » : les MCO choisissent $\mathbf{b}$ pour minimiser $\sum e_i^2$, donc $\sum e_i^2 \leq \sum \epsilon_i^2$ (le vrai $\boldsymbol{\beta}$ est un candidat parmi d'autres!).

11.2 Calcul de $\mathbb{E}[\mathbf{e}'\mathbf{e} \mid \mathbf{X}]$ [94]–[106]

Calcul détaillé

1. Les résidus en fonction des erreurs. $\mathbf{e} = \mathbf{M}\mathbf{y} = \mathbf{M}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \mathbf{M}\boldsymbol{\epsilon}$ car $\mathbf{M}\mathbf{X} = \mathbf{0}$. Donc $\mathbf{e}'\mathbf{e} = \boldsymbol{\epsilon}'\mathbf{M}'\mathbf{M}\boldsymbol{\epsilon} = \boldsymbol{\epsilon}'\mathbf{M}\boldsymbol{\epsilon}$.

2. L'astuce de la trace. $\boldsymbol{\epsilon}'\mathbf{M}\boldsymbol{\epsilon}$ est un scalaire, donc égal à sa trace, et par permutation circulaire : $\boldsymbol{\epsilon}'\mathbf{M}\boldsymbol{\epsilon} = \text{tr}(\boldsymbol{\epsilon}'\mathbf{M}\boldsymbol{\epsilon}) = \text{tr}(\mathbf{M}\boldsymbol{\epsilon}\boldsymbol{\epsilon}')$. L'intérêt : on a regroupé les $\boldsymbol{\epsilon}$ en $\boldsymbol{\epsilon}\boldsymbol{\epsilon}'$, dont on connaît l'espérance.

3. Espérance. La trace est une somme, donc linéaire, et commute avec l'espérance : $\mathbb{E}[\text{tr}(\mathbf{M}\boldsymbol{\epsilon}\boldsymbol{\epsilon}') \mid \mathbf{X}] = \text{tr}(\mathbf{M} \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}]) = \text{tr}(\mathbf{M} \sigma^2 \mathbf{I}_n) = \sigma^2 \text{tr}(\mathbf{M})$.

4. Trace de $\mathbf{M}$. $\text{tr}(\mathbf{M}) = \text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = n - \text{tr}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}) = n - \text{tr}(\mathbf{I}_K) = n - K$. (On a permuté $\mathbf{X}$ de la première à la dernière position : la matrice passe de $n \times n$ à $K \times K$.)

Conclusion. $\mathbb{E}[\mathbf{e}'\mathbf{e} \mid \mathbf{X}] = (n - K)\sigma^2$.

À retenir

$$s^2 = \frac{\mathbf{e}'\mathbf{e}}{n - K} \quad \text{est sans biais pour } \sigma^2,$$

$$\widehat{\text{Var}}(\mathbf{b} \mid \mathbf{X}) = s^2(\mathbf{X}'\mathbf{X})^{-1}, \quad \text{e.t.}(b_k) = \sqrt{s^2 [(\mathbf{X}'\mathbf{X})^{-1}]_{kk}}.$$

$s = \sqrt{s^2}$ s'appelle l'erreur-type de la régression (« Root MSE » dans Stata, « Residual standard error » dans R).

Intuition : les degrés de liberté

Les n résidus ne sont pas libres : ils doivent satisfaire les K équations $\mathbf{X}'\mathbf{e} = \mathbf{0}$. Il ne reste donc que $n - K$ « degrés de liberté ». Géométriquement, $\mathbf{e} = \mathbf{M}\boldsymbol{\epsilon}$ vit dans un sous-espace de dimension $n - K$ (celui orthogonal à $\mathbf{X}$) : il ne capte que $n - K$ des n « directions » de variation de $\boldsymbol{\epsilon}$, chacune d'espérance σ^2 . C'est le même phénomène que le $n - 1$ de la variance empirique $\frac{1}{n-1} \sum (x_i - \bar{x})^2$, qui est le cas particulier $K = 1$ (régression sur une constante).

Exemple numérique

$$\text{SCE} = 2,4, \quad n - K = 5 - 2 = 3, \quad \text{donc } s^2 = 0,8. \quad \widehat{\text{Var}}(\mathbf{b}) = 0,8 \times \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 0,88 & -0,24 \\ -0,24 & 0,08 \end{pmatrix}.$$

Écarts-types : $\text{e.t.}(b_1) = \sqrt{0,88} \approx 0,938$, $\text{e.t.}(b_2) = \sqrt{0,08} \approx 0,283$. La statistique t de la pente est $0,6/0,283 \approx 2,12$. (Vérifiable avec `reg y x` dans Stata ou `lm(y~x)` dans R.)

Attention / piège fréquent

s^2 est sans biais pour σ^2 , mais s est (légèrement) *biaisé* pour σ : la racine est concave, donc $\mathbb{E}[s] \leq \sqrt{\mathbb{E}[s^2]} = \sigma$ (inégalité de Jensen). L'absence de biais ne se conserve pas par transformation non linéaire. De même, les écarts-types estimés ne sont pas exactement sans biais, mais le biais est négligeable (voir Monte Carlo).

12 Les études de Monte Carlo (Greene 15.5)

12.1 Principe

Une propriété statistique (sans biais, variance, loi) décrit ce qui se passe *en échantillons répétés*. Dans la réalité, on n'observe qu'un seul échantillon et on ne connaît pas β . En simulation, on **fabrique** le monde : on choisit β et σ^2 , on génère des milliers d'échantillons, on estime sur chacun, et on regarde la distribution des estimations. C'est un « laboratoire » où la vérité est connue.

Utilité : vérifier un résultat théorique (comme ici), étudier des situations où la théorie est trop difficile (petits échantillons, estimateurs non linéaires, violations d'hypothèses), et introduction au *bootstrap*.

Pour aller plus loin / histoire

La méthode a été formalisée à Los Alamos vers 1946–1949 par **Stanislaw Ulam** et **John von Neumann** (avec Nicholas Metropolis, qui trouva le nom en référence au casino de Monaco), pour simuler la diffusion des neutrons sur les premiers ordinateurs (ENIAC). Ulam en eut l'idée en se demandant quelle était la probabilité de réussir une patience aux cartes.

12.2 Générer des nombres (pseudo-)aléatoires [110]

Un ordinateur est déterministe ; il produit des suites qui *ressemblent* à du hasard. Le générateur congruentiel linéaire (GCL) :

$$x_t = (\alpha + \lambda x_{t-1}) \bmod m, \quad u_t = x_t/m \in [0, 1).$$

$a \bmod b$ est le reste de la division entière de a par b (par ex. $17 \bmod 5 = 2$).

Un GCL « jouet » calculé à la main

$\alpha = 3$, $\lambda = 5$, $m = 16$, graine $x_0 = 7$: $x_1 = (3 + 35) \bmod 16 = 38 \bmod 16 = 6$; $x_2 = (3 + 30) \bmod 16 = 1$; $x_3 = (3 + 5) \bmod 16 = 8$; $x_4 = 43 \bmod 16 = 11$; ...

La suite complète : 6, 1, 8, 11, 10, 5, 12, 15, 14, 9, 0, 3, 2, 13, 4, 7, **6, 1, 8, ...**

Après 16 termes, on retombe sur 7 puis la suite **se répète** : la *période* est au plus m . C'est pourquoi on prend m très grand ($2^{31} - 1$, $2^{63} - 1$...). Et la même graine redonne toujours la même suite : c'est ce qui rend les simulations **reproductibles**.

Attention / piège fréquent

Les GCL ont des défauts : les k -uplets successifs (u_t, u_{t+1}, u_{t+2}) se rangent sur un petit nombre d'hyperplans (théorème de Marsaglia, 1968). Le célèbre générateur RANDU d'IBM (années 1960) plaçait tous les triplets sur seulement 15 plans, ce qui a jeté le doute sur de nombreux résultats de simulation de l'époque. Les logiciels modernes utilisent de meilleurs générateurs : Stata (depuis la v. 14) et R utilisent par défaut le *Mersenne Twister* (période $2^{19937} - 1$). Le principe (graine, suite déterministe) reste le même.

12.3 Obtenir n'importe quelle loi : la transformation inverse

Si $U \sim U[0, 1]$ et F est une fonction de répartition (continue, strictement croissante), alors $X = F^{-1}(U)$ suit la loi F .

Pourquoi ça marche (une ligne)

$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$, car pour une uniforme $P(U \leq a) = a$.

Exemple numérique

Loi exponentielle de paramètre λ : $F(x) = 1 - e^{-\lambda x}$. On résout $u = 1 - e^{-\lambda x}$: $x = -\ln(1 - u)/\lambda$. Pour la loi normale, $F^{-1} = \Phi^{-1}$ n'a pas de formule explicite ; on l'approxime numériquement, ou on utilise la méthode de Box-Muller : $Z = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$ est $N(0, 1)$.




FIGURE 4 – Gauche : 4000 nombres produits par un GCL ($\lambda = 1\,103\,515\,245$, $\alpha = 12\,345$, $m = 2^{31}$) ont l'air uniformes. Droite : transformés par $-\ln(1 - u)/2$, ils suivent une loi exponentielle de paramètre 2.

12.4 Les étapes de l'étude (cours p. 24)

1. Fixer les « vraies » valeurs : β_0 , β_1 , σ^2 .
2. Garder les x_i **fixes** d'une réplcation à l'autre (on étudie les propriétés conditionnelles à $\mathbf{X}$, comme dans la théorie).
3. Pour $r = 1, \dots, R$: tirer de nouvelles erreurs ϵ_i^* , construire $y_i^* = \beta_0 + \beta_1 x_i + \epsilon_i^*$, estimer par MCO, sauvegarder b_{0r}^* , b_{1r}^* (et l'écart-type).
4. Analyser les R estimations : moyenne (pour le biais), écart-type (pour la variance), histogramme (pour la loi).

Intuition

La moyenne des R estimations est elle-même une estimation de $\mathbb{E}[b_1]$, avec une erreur de simulation d'écart-type e.t.(b_1)/ $\sqrt{R}$. Avec $R = 10\,000$ et e.t.(b_1) $\approx 0,034$, cette erreur est $\approx 0,00034$: un écart $|\bar{b}_1^* - \beta_1|$ de l'ordre de 0,0005 (comme dans les résultats du cours) est donc tout à fait compatible avec l'absence de biais.

12.5 Le code Stata commenté

```
capture drop _all          // vide la mémoire
set seed 12345678          // graine : résultats reproductibles
```

```

scalar beta0 = 1 // vraies valeurs des paramètres
scalar beta1 = 1
scalar sigma = 1
global Nreps = 10000 // R : nombre de réplifications
global Nobs = 250 // n : taille de chaque échantillon
set obs $Nobs
gener double x = exp(rnormal(0,1)) // x log-normal, tiré UNE SEULE FOIS (fixe)
summarize x
scalar varbeta1 = sigma/( r(Var)*($Nobs-1) ) // Var(b1) = sigma^2 / somme (x-xbar)^2
scalar sdbeta1 = sqrt(varbeta1) // vrai écart-type théorique
gener my = beta0 + beta1*x // E[y|x], partie non aléatoire
gener epsilon = . // variables vides à remplir
gener sy = .
tempname simulate
postfile `simulate' b se using simresults, replace // fichier de résultats
quietly {
  forvalues i = 1/$Nreps {
    replace epsilon = rnormal(0,sigma) // nouvelles erreurs à chaque tour
    replace sy = my + epsilon // nouvel échantillon y*
    reg sy x // MCO
    scalar b = _b[x] // pente estimée
    scalar se = _se[x] // son écart-type estimé
    post `simulate' (b) (se) // sauvegarde
  }
}
postclose `simulate'
use simresults, clear
summarize // moyenne et écart-type des 10 000 b et se
scalar list sdbeta1
histogram b, normal // histogramme + densité normale superposée

```

Remarques. (i) $r(\text{Var}) * (\$Nobs - 1) = \sum (x_i - \bar{x})^2$ car la variance empirique de Stata divise par $n - 1$. (ii) La formule utilise `sigma` là où il faudrait `sigma^2`; c'est sans conséquence ici puisque $\sigma = 1$, mais le code serait faux pour $\sigma \neq 1$. (iii) `rnormal(0,sigma)` prend l'écart-type (pas la variance) en second argument, comme `rnorm` en R.

Le code R du cours fait exactement la même chose avec `set.seed`, `rnorm`, `lm` et une boucle `for`; `summary(model)$coef[2,1:2]` extrait la pente et son écart-type.

12.6 Lecture des résultats

	Stata (cours)	R (cours)	Python (notre réplification)
Moyenne des b_1^*	0,999501	1,0002	0,99972
Écart-type des b_1^*	0,03432	–	0,02505
Moyenne des e.t. estimés	0,03441	0,03472	0,02521
Vrai e.t. théorique	0,03444	0,03475	0,02525
Min / Max des b_1^*	0,876 / 1,120	0,863 / 1,120	0,899 / 1,104

(Les x_i tirés diffèrent d'un logiciel à l'autre — même graine mais générateurs différents —, d'où des valeurs théoriques légèrement différentes; dans notre tirage, les x sont un peu plus dispersés, ce qui réduit la variance.)

Trois conclusions, toutes conformes à la théorie :

1. **Sans biais** : la moyenne des b_1^* est à moins de 0,0005 de la vraie valeur 1.
2. **Formule de variance correcte** : l'écart-type empirique des b_1^* (0,0343) est égal à la valeur théorique $\sigma / \sqrt{\sum (x_i - \bar{x})^2}$ (0,0344).

3. **Écart-type estimé sans biais (en pratique)** : la moyenne des e.t. calculés par `reg` (0,0344) retrouve la vraie valeur. Chaque e.t. individuel varie pourtant (de 0,028 à 0,041) : lui aussi est une variable aléatoire.

Complément de notre réplication : l'intervalle de confiance à 95 % $b_1 \pm t_{0,975;248} \text{e.t.}(b_1)$ contient la vraie valeur 1 dans **95,4 %** des 10 000 échantillons — exactement ce qu'il doit faire.




FIGURE 5 – Réplication de l'étude du cours ($n = 250$, $R = 10\,000$) : l'histogramme des pentes estimées coïncide avec la loi normale prédite par la théorie.

12.7 Pourquoi l'histogramme est normal

En bivarié, $b_1 = \sum k_i y_i$ avec $k_i = (x_i - \bar{x}) / \sum (x_j - \bar{x})^2$ [118]. En remplaçant y_i : $b_1 = \beta_1 + \sum k_i \epsilon_i$ (car $\sum k_i = 0$ et $\sum k_i x_i = 1$). L'estimateur est donc une **combinaison linéaire des erreurs**. Une combinaison linéaire de variables normales indépendantes est normale, donc

$$b_1 \mid \mathbf{X} \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right).$$

Et en général, sous H5 : $\mathbf{b} \mid \mathbf{X} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$ — c'est la base des tests t et F du chapitre suivant.

Et si les erreurs ne sont pas normales ?

Nous avons refait la simulation avec des erreurs très asymétriques (khi-deux à 1 degré de liberté, centrée et réduite). Résultat : moyenne des $b_1^* = 0,99987$ (toujours sans biais, puisque H5 n'est pas nécessaire pour cela) et un histogramme toujours quasi normal, car $\sum k_i \epsilon_i$ est une somme de nombreux termes indépendants : c'est le **théorème central limite**, qui justifiera l'inférence « asymptotique » plus tard dans le cours.

13 Coquilles et imprécisions relevées dans les notes

Pour ne pas être déstabilisé en relisant les notes :

Endroit	Écrit	Correct / remarque
[12]	$-\mathbf{X}'\mathbf{y} + (\mathbf{X}'\mathbf{X})\mathbf{b} = 0$	facteur 2 omis (sans conséquence) ; $\mathbf{b}_0$ devient $\mathbf{b}$ à l'optimum
§1.2, [16]	modèle en β_0, β_1 , estimateurs b_1, b_2	indices décalés : b_1 estime la constante, b_2 la pente
[24]	$\mathbf{e} = \mathbf{X}\mathbf{b} - \mathbf{y}$	$\mathbf{e} = \mathbf{y} - \mathbf{X}\mathbf{b}$ (signe sans effet car $= 0$)
[31]	$\hat{y}_i = \bar{y}_i$	pas d'indice i : $\bar{\hat{y}} = \bar{y}$
[70]–[71]	$(\mathbf{y} - \mathbf{X}_1\mathbf{b}_0)(\mathbf{y} - \mathbf{X}_1\mathbf{b}_0)$	manque un prime : $(\mathbf{y} - \mathbf{X}_1\mathbf{b}_0)'(\mathbf{y} - \mathbf{X}_1\mathbf{b}_0)$
[75]	$\mathbf{X}_2$	$\mathbf{x}_2$ (une seule variable ajoutée)
§2.4.1	SCE puis SSE	même quantité (somme des carrés des résidus)
[81]	$\mathbb{E}[(\mathbf{b} - \mathbb{E}(\mathbf{b})) \dots]$	correct ; on remplace $\mathbb{E}(\mathbf{b})$ par $\boldsymbol{\beta}$ grâce à l'absence de biais
§4, [87]–[90]	$\mathbf{C}\mathbf{X} = \mathbf{I}_n, \mathbf{D}\mathbf{X} + \mathbf{I}_n = \mathbf{I}_n$	$\mathbf{I}_K$ (matrice $K \times K$)
[93]	$\text{Var}(\mathbf{b} \mid \mathbf{X}) \leq \text{Var}(\mathbf{b}^* \mid \mathbf{X})$	au sens matriciel : la différence est semi-définie positive
[106]–[107]	parenthèses en trop	$\mathbb{E}(\mathbf{e}'\mathbf{e} \mid \mathbf{X}) = \sigma^2(n-K), \mathbb{E}(s^2 \mid \mathbf{X}) = \sigma^2$
Code Stata	<code>sigma/(r(Var)*(\$Nobs-1))</code>	devrait être <code>sigma^2/(...)</code> ; identique ici car $\sigma = 1$
p. 27	« la variance de b_1 est $\text{sd}(b_1) = \dots$ »	c'est l'écart-type (racine de la variance)

14 Fiche de révision

Les formules essentielles

Estimateur : $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ (bivarié : $b_2 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$, $b_1 = \bar{y} - b_2\bar{x}$)

Équations normales : $\mathbf{X}'\mathbf{e} = \mathbf{0}$ (avec constante : $\sum e_i = 0$, $\bar{y} = \bar{\mathbf{x}}'\mathbf{b}$, $\bar{\hat{y}} = \bar{y}$)

Projections : $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, $\mathbf{M} = \mathbf{I} - \mathbf{P}$; $\mathbf{M}\mathbf{X} = \mathbf{0}$, $\mathbf{P}\mathbf{X} = \mathbf{X}$

FWL : $\mathbf{b}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{y}$

Décomposition : $\text{SCT} = \text{SCR} + \text{SCE}$, $R^2 = 1 - \text{SCE}/\text{SCT}$, $\bar{R}^2 = 1 - \frac{n-1}{n-K}(1 - R^2)$

Ajout d'une variable : $\text{SCE}_2 = \text{SCE}_1 - \tilde{b}_2^2 \mathbf{x}_2'\mathbf{M}_1\mathbf{x}_2 \leq \text{SCE}_1$

Sans biais (H1–H3) : $\mathbf{b} = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}$, $\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta}$

Variance (H4) : $\text{Var}(\mathbf{b} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$

Gauss-Markov : $\text{Var}(\mathbf{b}^* \mid \mathbf{X}) = \text{Var}(\mathbf{b} \mid \mathbf{X}) + \sigma^2\mathbf{D}\mathbf{D}'$

Estimation de σ^2 : $s^2 = \mathbf{e}'\mathbf{e}/(n-K)$, $\mathbb{E}[\mathbf{e}'\mathbf{e}] = \sigma^2 \text{tr}(\mathbf{M}) = \sigma^2(n-K)$

Normalité (H5) : $\mathbf{b} \mid \mathbf{X} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$

Les 8 idées à comprendre (pas seulement à mémoriser)

1. Les MCO minimisent une somme de carrés ; la solution est la projection orthogonale de $\mathbf{y}$ sur l'espace des $\mathbf{X}$.
2. Les résidus sont orthogonaux aux régresseurs *par construction* : cela ne prouve rien sur l'exogénéité.

3. Propriétés numériques = toujours vraies ; propriétés statistiques = dépendent des hypothèses.
4. FWL = « toutes choses égales par ailleurs » en langage matriciel.
5. Le R^2 ne baisse jamais quand on ajoute une variable : il ne sert pas à choisir un modèle.
6. Sans biais repose sur $\mathbb{E}[\epsilon | \mathbf{X}] = \mathbf{0}$; la formule de variance sur $\sigma^2 \mathbf{I}$.
7. Gauss-Markov : parmi les estimateurs linéaires sans biais, les MCO ont la plus petite variance (pas besoin de normalité).
8. On divise par $n - K$ car K degrés de liberté sont « consommés » par l'estimation de $\mathbf{b}$.

15 Exercices corrigés

Exercice 1. Montrer que dans une régression sur une constante seule ($\mathbf{X} = \mathbf{1}$), $b = \bar{y}$ et s^2 est la variance empirique usuelle.

Corrigé. $\mathbf{1}'\mathbf{1} = n$ et $\mathbf{1}'\mathbf{y} = \sum y_i$, donc $b = \frac{1}{n} \sum y_i = \bar{y}$. Les résidus sont $y_i - \bar{y}$ et $K = 1$, d'où $s^2 = \frac{1}{n-1} \sum (y_i - \bar{y})^2$. On retrouve le « $n - 1$ » du cours de statistique comme cas particulier de $n - K$.

Exercice 2. On multiplie la variable x par 100 (on passe de dollars en cents). Que deviennent b_2 , b_1 , les résidus et le R^2 ?

Corrigé. $\sum (100x_i - 100\bar{x})(y_i - \bar{y}) / \sum (100x_i - 100\bar{x})^2 = b_2/100$. $b_1 = \bar{y} - (b_2/100)(100\bar{x})$ est inchangé. Les valeurs prédites, donc les résidus et le R^2 , sont inchangés : $\mathbf{P}$ ne dépend que de l'espace engendré par les colonnes de $\mathbf{X}$, qui ne change pas quand on multiplie une colonne par une constante.

Exercice 3. Montrer que $\text{tr}(\mathbf{P}) = K$ et en déduire $\sum_i p_{ii} = K$ (la moyenne des leviers est K/n).

Corrigé. $\text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = \text{tr}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}) = \text{tr}(\mathbf{I}_K) = K$. La trace étant la somme des éléments diagonaux, $\sum p_{ii} = K$.

Exercice 4. Avec l'exemple numérique ($x = 1, \dots, 5$), on considère l'estimateur « premier et dernier point » $b_2^* = (y_5 - y_1)/(x_5 - x_1)$. (a) Montrer qu'il est linéaire et sans biais. (b) Comparer sa variance à celle des MCO.

Corrigé. (a) $b_2^* = (y_5 - y_1)/4$ est linéaire en $\mathbf{y}$. $\mathbb{E}[b_2^*] = \frac{(\beta_1 + 5\beta_2) - (\beta_1 + \beta_2)}{4} = \beta_2$: sans biais. (b) $\text{Var}(b_2^*) = \frac{2\sigma^2}{16} = 0,125\sigma^2$, contre $\text{Var}(b_2) = \sigma^2 / \sum (x_i - \bar{x})^2 = \sigma^2/10 = 0,1\sigma^2$. Les MCO sont plus précis, comme le garantit Gauss-Markov.

Exercice 5. Pourquoi ne peut-on pas utiliser $\frac{1}{n} \sum e_i^2$ pour estimer σ^2 ? Calculer son biais.

Corrigé. $\mathbb{E}[\frac{1}{n} \mathbf{e}'\mathbf{e}] = \frac{n-K}{n} \sigma^2 < \sigma^2$: il sous-estime σ^2 d'un facteur $(n - K)/n$. Le biais, $-\frac{K}{n} \sigma^2$, disparaît quand $n \rightarrow \infty$ (l'estimateur est convergent), mais peut être important en petit échantillon (dans notre exemple, $n = 5$, $K = 2$: 40 % de sous-estimation).

Exercice 6. Vrai ou faux : « Comme $\sum x_i e_i = 0$ dans ma régression, l'hypothèse $\mathbb{E}[\epsilon | x] = 0$ est vérifiée. »

Corrigé. Faux. $\sum x_i e_i = 0$ est une propriété numérique vraie pour n'importe quelles données, même si x est endogène. L'exogénéité porte sur les *erreurs* inobservables, pas sur les résidus ; elle se justifie par un argument économique (ou un dispositif expérimental), pas par ce calcul.

Exercice 7 (Monte Carlo). Dans l'étude du cours, que se passerait-il si l'on générait des erreurs avec $\mathbb{E}[\epsilon_i | x_i] = 0,2 x_i$?

Corrigé. Alors $y_i = 1 + x_i + \epsilon_i$ avec $\epsilon_i = 0,2x_i + u_i$, soit $y_i = 1 + 1,2x_i + u_i$. Les MCO estimerait en moyenne 1,2 au lieu de 1 : biais de 0,2, visible comme un décalage de l'histogramme, qui ne disparaîtrait pas en augmentant R ou n . C'est une illustration de la violation de H3.

Références et sources consultées

- W. H. Greene, *Econometric Analysis*, Pearson (ch. 3 : MCO ; ch. 4 : propriétés statistiques ; ch. 15.5 : Monte Carlo).
- A.-M. Legendre (1805), *Nouvelles méthodes pour la détermination des orbites des comètes*, appendice « Sur la méthode des moindres carrés ». Présentation : <http://www.bibnum.education.fr/mathematiques/algebre/legendre-et-la-methode-des-moindres-carres>
- « Méthode des moindres carrés », Wikipédia : https://fr.wikipedia.org/wiki/M%C3%A9thode_des_moindres_carr%C3%A9s
- R. Frisch et F. V. Waugh (1933), « Partial Time Regressions as Compared with Individual Trends », *Econometrica* 1(4). M. C. Lovell (1963), « Seasonal Adjustment of Economic Time Series and Multiple Regression Analysis », *JASA* 58.
- D. Basu (2023), « The Yule-Frisch-Waugh-Lovell Theorem », <https://arxiv.org/abs/2307.00369>
- P. Ding (2021), « The Frisch–Waugh–Lovell theorem for standard errors », *Statistics & Probability Letters*.
- « Gauss–Markov theorem », Wikipédia : https://en.wikipedia.org/wiki/Gauss%E2%80%93Markov_theorem; A. C. Aitken (1935), « On Least Squares and Linear Combinations of Observations », *Proc. Royal Soc. Edinburgh* 55.
- B. E. Hansen (2022), « A Modern Gauss-Markov Theorem », *Econometrica* 90(3) : <https://users.ssc.wisc.edu/~behansen/papers/gauss.pdf>
- H. Theil (1961), *Economic Forecasts and Policy* (introduction du R^2 ajusté).
- « Linear congruential generator » et « RANDU », Wikipédia : https://en.wikipedia.org/wiki/Linear_congruential_generator, <https://en.wikipedia.org/wiki/RANDU>; G. Marsaglia (1968), « Random numbers fall mainly in the planes », *PNAS* 61.
- N. Metropolis et S. Ulam (1949), « The Monte Carlo Method », *JASA* 44.

Les figures et la réplique de Monte Carlo ont été produites avec Python (NumPy, Matplotlib) ; le script `figures.py` est fourni avec ce document.