Inférence et tests d'hypothèse : corrigé

Intervalles de confiance, tests t et F, contraintes linéaires, Monte Carlo

S'appuie sur W. H. Greene, *Econometric Analysis* (ch. 4, 5, 8, 9 et 20)

Référence Greene

- **Ch. 4** : loi des MCO sous normalité, $\mathbf{b} \mid \mathbf{X} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$; statistique t et intervalles de confiance ; Monte Carlo.
- **Ch. 5** : tests d'hypothèses linéaires $\mathbf{R}\boldsymbol{\beta} = \mathbf{r}$, statistique F (version Wald et version « somme des carrés des résidus contrainte / non contrainte »), estimation sous contrainte, reparamétrisation.
- **Ch. 9** : hétéroscédasticité et écarts-types robustes de White. **Ch. 8** : endogénéité, variables instrumentales et doubles moindres carrés.

Les deux formules de base (Greene, ch. 4–5). Sous normalité des erreurs, avec $s^2 = \mathbf{e}'\mathbf{e}/(n-K)$:

$$t = \frac{b_k - \beta_k^0}{\text{e.t.}(b_k)} \sim t(n-K), \qquad \text{e.t.}(b_k) = \sqrt{s^2\,[(\mathbf{X}'\mathbf{X})^{-1}]_{kk}},$$

$$F = \frac{(\text{SCE}_r - \text{SCE}_u)/r}{\text{SCE}_u/(n-K)} \sim F(r,\, n-K).$$

Table des matières

1 Exercice 1 : intervalle de confiance et test t 1

2 Exercice 2 : test d'une combinaison linéaire $\beta_1 + \beta_2 = 2$ 2

3 Exercice 3 : transformer les contraintes en restrictions nulles 3

4 Exercice 4 : Monte Carlo du biais des MCO selon n 4

5 Exercice 5 : estimer sous la contrainte $\beta_2 + \beta_3 = 1$ 5

6 Exercice 6 : variable omise et hétéroscédasticité 6

7 Exercice 7 : x_i corrélé avec les erreurs 7

8 Exercice 8 : $\tilde{\beta} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{y}$ est sans biais 8

9 Exercice 9 : heures de travail et salaires (Ontario) 8

1 Exercice 1 : intervalle de confiance et test t

Données : $b_k = 5$, $\hat{\sigma} = s = 1$ (erreur-type de la régression), $[(\mathbf{X}'\mathbf{X})^{-1}]_{kk} = 0{,}04$, $\alpha = 0{,}05$.

Attention

L'énoncé ne précise ni l'hypothèse nulle ni la taille de l'échantillon. On teste l'hypothèse usuelle $H_0 : \beta_k = 0$ contre $H_1 : \beta_k \neq 0$, et on utilise la valeur critique 1,96 (grand échantillon). Avec $n - K$ degrés de liberté connus, il faudrait $t_{0,975;\, n-K}$, un peu plus grand ; les conclusions ne changent pas ici.

1. Intervalle de confiance à 95 %

Étape 1 : l'écart-type de b_k. D'après la formule $\widehat{\mathrm{Var}}(\mathbf{b}) = s^2(\mathbf{X}'\mathbf{X})^{-1}$:

$$\text{e.t.}(b_k) = \sqrt{s^2\,[(\mathbf{X}'\mathbf{X})^{-1}]_{kk}} = \sqrt{1^2 \times 0{,}04} = 0{,}2.$$

Étape 2 : la formule de l'IC. Comme $\frac{b_k - \beta_k}{\text{e.t.}(b_k)}$ suit une loi de Student (environ $N(0,1)$ en grand échantillon), $P(-1{,}96 \leq \frac{b_k - \beta_k}{\text{e.t.}} \leq 1{,}96) = 0{,}95$, d'où

$$\text{IC}_{95\%}(\beta_k) = b_k \pm 1{,}96 \times \text{e.t.}(b_k) = 5 \pm 1{,}96 \times 0{,}2 = 5 \pm 0{,}392.$$

Réponse

$\text{IC}_{95\%}(\beta_k) = [4{,}608\ ;\ 5{,}392]$. Interprétation : si l'on répétait l'échantillonnage un grand nombre de fois, 95 % des intervalles construits ainsi contiendraient la vraie valeur β_k.

2. Statistique t

$$t = \frac{b_k - 0}{\text{e.t.}(b_k)} = \frac{5}{0{,}2} = 25.$$

3. Décision au seuil de 5 %

Réponse

$|t| = 25 > 1{,}96$: on **rejette** $H_0 : \beta_k = 0$. C'est cohérent avec l'IC, qui ne contient pas 0 (dualité IC–test).

4. p-value

Réponse

$p = 2\,P(|T| > 25) \approx 0$ (de l'ordre de 10^{-137} avec la loi normale). **Interprétation** : si β_k était vraiment nul, la probabilité d'obtenir une estimation aussi éloignée de 0 que 5 (soit 25 écarts-types) serait pratiquement nulle. Comme $p < 0{,}05$, on rejette $H_0 : \beta_k$ est statistiquement significatif.

2 Exercice 2 : test d'une combinaison linéaire $\beta_1 + \beta_2 = 2$

Données : $\hat{\beta}_1 = 1{,}2$; $\hat{\beta}_2 = 0{,}8$; $\mathrm{Var}(\hat{\beta}_1) = 0{,}04$; $\mathrm{Var}(\hat{\beta}_2) = 0{,}03$; $\mathrm{Cov}(\hat{\beta}_1, \hat{\beta}_2) = 0{,}01$; $n - K = 12$; valeur critique 2,18.

1. Écart-type de $\hat{\beta}_1 + \hat{\beta}_2$

Idée de la démarche

Variance d'une somme de deux variables aléatoires corrélées : $\text{Var}(A+B) = \text{Var}(A) + \text{Var}(B) + 2\,\text{Cov}(A,B)$. **Ne pas oublier la covariance** : $\hat{\beta}_1$ et $\hat{\beta}_2$ sont estimés sur les mêmes données.

$$\text{Var}(\hat{\beta}_1 + \hat{\beta}_2) = 0{,}04 + 0{,}03 + 2 \times 0{,}01 = 0{,}09 \qquad \Longrightarrow \qquad \text{e.t.}(\hat{\beta}_1 + \hat{\beta}_2) = \sqrt{0{,}09} = 0{,}3.$$

(En écriture matricielle : $\mathbf{R} = (0,1,1,0)$, $\text{Var}(\mathbf{Rb}) = \mathbf{R}\,\widehat{\text{Var}}(\mathbf{b})\,\mathbf{R}'$, Greene ch. 5.)

2. Hypothèse nulle pour γ

On définit le paramètre $\gamma = \beta_1 + \beta_2 - 2$ (l'énoncé écrit $\hat{\beta}$: l'hypothèse porte sur les vrais paramètres, son estimateur est $\hat{\gamma} = \hat{\beta}_1 + \hat{\beta}_2 - 2$).

$$H_0 : \gamma = 0 \qquad \text{contre} \qquad H_1 : \gamma \neq 0.$$

3. Le test

$$\hat{\gamma} = 1{,}2 + 0{,}8 - 2 = 0, \qquad \text{e.t.}(\hat{\gamma}) = \text{e.t.}(\hat{\beta}_1 + \hat{\beta}_2) = 0{,}3,$$

(soustraire la constante 2 ne change pas la variance), d'où

$$t = \frac{\hat{\gamma}}{\text{e.t.}(\hat{\gamma})} = \frac{0}{0{,}3} = 0.$$

Réponse

$|t| = 0 < 2{,}18 = t_{0{,}975;\,12}$: on **ne rejette pas** H_0. Les estimations vérifient exactement la contrainte ($\hat{\beta}_1 + \hat{\beta}_2 = 2$) : les données sont parfaitement compatibles avec $\beta_1 + \beta_2 = 2$ (p-value $= 1$).
Version par reparamétrisation (Greene, ch. 5) : avec $\beta_1 = \gamma + 2 - \beta_2$, le modèle devient $y_i - 2x_{1i} = \beta_0 + \gamma\, x_{1i} + \beta_2(x_{2i} - x_{1i}) + \beta_3 x_{3i} + \epsilon_i$; le t du coefficient de x_{1i} est exactement celui calculé ci-dessus.

3 Exercice 3 : transformer les contraintes en restrictions nulles

Idée de la démarche

Généraliser la reparamétrisation de l'exercice 2 : définir de nouveaux paramètres $\boldsymbol{\gamma}_1 = \mathbf{R}\boldsymbol{\beta} - \mathbf{r}$, de sorte que la contrainte devienne $\boldsymbol{\gamma}_1 = \mathbf{0}$ (contrainte d'exclusion), puis réécrire le modèle en fonction de $\boldsymbol{\gamma}_1$.

Étape 1 : partitionner. $\mathbf{R}$ est $r \times k$ de rang r (contraintes non redondantes). Quitte à réordonner les colonnes de $\mathbf{X}$, on écrit

$$\mathbf{R} = [\mathbf{R}_1 \;\; \mathbf{R}_2], \qquad \boldsymbol{\beta} = \begin{pmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{pmatrix}, \qquad \mathbf{X} = [\mathbf{X}_1 \;\; \mathbf{X}_2],$$

avec $\mathbf{R}_1$ de dimension $r \times r$ **inversible** et $\boldsymbol{\beta}_1$ de dimension $r \times 1$.

Étape 2 : nouveaux paramètres.

$$\boldsymbol{\gamma}_1 = \mathbf{R}_1\boldsymbol{\beta}_1 + \mathbf{R}_2\boldsymbol{\beta}_2 - \mathbf{r} = \mathbf{R}\boldsymbol{\beta} - \mathbf{r} \quad (r \times 1), \qquad \boldsymbol{\gamma}_2 = \boldsymbol{\beta}_2.$$

La contrainte $\mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ équivaut à $\boldsymbol{\gamma}_1 = \mathbf{0}$.

Étape 3 : exprimer $\boldsymbol{\beta}_1$ en fonction de $\boldsymbol{\gamma}_1$.

$$\boldsymbol{\beta}_1 = \mathbf{R}_1^{-1}(\boldsymbol{\gamma}_1 + \mathbf{r} - \mathbf{R}_2\boldsymbol{\beta}_2).$$

Étape 4 : substituer dans le modèle.

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{u} = \mathbf{X}_1\mathbf{R}_1^{-1}\boldsymbol{\gamma}_1 + \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{r} - \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{R}_2\boldsymbol{\beta}_2 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{u}.$$

On regroupe :

$$\boxed{\underbrace{\mathbf{y} - \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{r}}_{\mathbf{y}^*} = \underbrace{\mathbf{X}_1\mathbf{R}_1^{-1}}_{\mathbf{Z}_1}\boldsymbol{\gamma}_1 + \underbrace{\left(\mathbf{X}_2 - \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{R}_2\right)}_{\mathbf{Z}_2}\boldsymbol{\beta}_2 + \mathbf{u}}$$

Réponse

Le modèle $\mathbf{y}^* = \mathbf{Z}_1\boldsymbol{\gamma}_1 + \mathbf{Z}_2\boldsymbol{\beta}_2 + \mathbf{u}$ est le même modèle que l'original (même ajustement, mêmes résidus, car $[\mathbf{Z}_1\ \mathbf{Z}_2]$ est une transformation inversible de $[\mathbf{X}_1\ \mathbf{X}_2]$; voir le devoir 1, question 1(a)). Les r restrictions $\mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ y deviennent r **restrictions d'exclusion** $\boldsymbol{\gamma}_1 = \mathbf{0}$: on teste que les r variables $\mathbf{Z}_1$ peuvent être retirées (test F sur $\mathbf{Z}_1$, ou test t si $r = 1$).
Vérification sur l'exercice 2 : $\mathbf{R} = (0, 1, 1, 0)$, $\mathbf{r} = 2$, on prend $\mathbf{R}_1 = 1$ (coefficient de β_1), $\mathbf{R}_2 = (0, 1, 0)$ pour $(\beta_0, \beta_2, \beta_3)$. Alors $\mathbf{y}^* = \mathbf{y} - 2\mathbf{x}_1$, $\mathbf{Z}_1 = \mathbf{x}_1$, et $\mathbf{Z}_2 = [\boldsymbol{\iota},\ \mathbf{x}_2 - \mathbf{x}_1,\ \mathbf{x}_3]$: c'est exactement la reparamétrisation de l'exercice 2.

4 Exercice 4 : Monte Carlo du biais des MCO selon n

Modèle : $y = \beta_1 + \beta_2 x_1 + u$, $u \sim NID(0, 1)$, $\beta_1 = 1$, $\beta_2 = 0{,}8$.

Les étapes

1. Fixer la graine ; choisir $n = 25$ et générer x_1 **une seule fois** (par ex. $N(0, 1)$), gardé fixe.
2. Répéter R fois ($R \geq 100$; ici $R = 1000$) : tirer $u \sim N(0, 1)$, construire $y = 1 + 0{,}8x_1 + u$, estimer par MCO, sauvegarder $\hat{\beta}_1$ et $\hat{\beta}_2$.
3. Calculer les moyennes $\bar{\hat{\beta}}_1, \bar{\hat{\beta}}_2$ et les biais estimés $\bar{\hat{\beta}}_1 - 1$ et $\bar{\hat{\beta}}_2 - 0{,}8$.
4. Recommencer avec $n = 50, 100, 200$.

```
* Stata : une taille d'échantillon (changer N pour 25, 50, 100, 200)
clear all
set seed 2024
local N = 25
set obs `N'
gen x1 = rnormal()
gen y = .
tempname sim
postfile `sim' b1 b2 using mc_n`N', replace
quietly forvalues r = 1/1000 {
    replace y = 1 + 0.8*x1 + rnormal()
    regress y x1
```

```
    post 'sim' (_b[_cons]) (_b[x1])
}
postclose 'sim'
use mc_n'N', clear
summarize b1 b2        // moyennes -> biais = moyenne - vraie valeur
```

Résultats (réplication en Python, $R = 1000$)

n	moy. $\hat\beta_1$	moy. $\hat\beta_2$	biais $\hat\beta_1$	biais $\hat\beta_2$	é.-t. $\hat\beta_2$	erreur MC sur le biais de $\hat\beta_2$
25	1,0039	0,8086	+0,0039	+0,0086	0,198	0,0063
50	1,0023	0,7982	+0,0023	−0,0018	0,154	0,0049
100	0,9986	0,8024	−0,0014	+0,0024	0,091	0,0029
200	0,9994	0,7980	−0,0006	−0,0020	0,069	0,0022

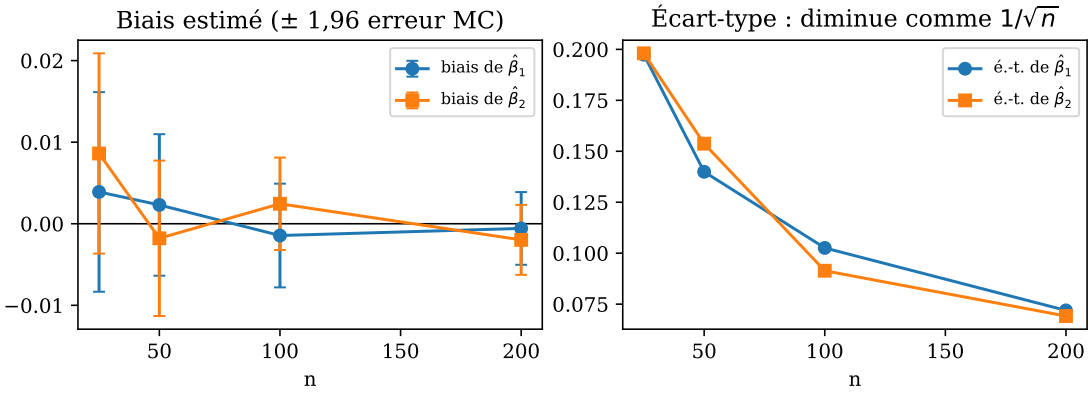


FIGURE 1 – Gauche : biais estimés, toujours compatibles avec 0. Droite : la dispersion des estimateurs diminue avec n.

Réponse

Le biais est nul pour toutes les tailles d'échantillon, y compris $n = 25$: les biais estimés sont minuscules et du même ordre que l'erreur de simulation (é.-t.$/\sqrt{R}$), donc statistiquement indiscernables de 0. C'est attendu : sous $\mathbb{E}[\mathbf{u} \mid \mathbf{X}] = \mathbf{0}$, les MCO sont **sans biais en échantillon fini** ($\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta}$ pour tout n), le biais n'a donc pas à « diminuer ». Ce qui change avec n, c'est la **précision** : l'écart-type de $\hat\beta_2$ diminue à peu près comme $1/\sqrt{n}$ (0,198 $\to$ 0,069 quand n passe de 25 à 200, soit environ $\div\sqrt{8} \approx 2{,}8$). Les biais estimés fluctuent donc de moins en moins autour de 0. C'est la convergence : $\mathrm{Var}(\mathbf{b}) \to \mathbf{0}$ et $\operatorname{plim} \mathbf{b} = \boldsymbol{\beta}$.

5 Exercice 5 : estimer sous la contrainte $\beta_2 + \beta_3 = 1$

Modèle contraint. On remplace $\beta_3 = 1 - \beta_2$:

$$y_t = \beta_1 + \beta_2 x_{t2} + (1-\beta_2) x_{t3} + u_t \iff \boxed{y_t - x_{t3} = \beta_1 + \beta_2 (x_{t2} - x_{t3}) + u_t}$$

On crée $y_t^* = y_t - x_{t3}$ et $z_t = x_{t2} - x_{t3}$, on régresse y^* sur une constante et z. On obtient $\tilde\beta_1$, $\tilde\beta_2$, puis $\tilde\beta_3 = 1 - \tilde\beta_2$: la contrainte est respectée par construction. (C'est l'estimateur des moindres carrés contraints de Greene, ch. 5, obtenu ici par substitution.)

Modèle non contraint reparamétré. On pose $\gamma = \beta_2 + \beta_3 - 1$, donc $\beta_3 = \gamma + 1 - \beta_2$:

$$y_t = \beta_1 + \beta_2 x_{t2} + (\gamma + 1 - \beta_2) x_{t3} + u_t \iff \boxed{y_t - x_{t3} = \beta_1 + \beta_2 (x_{t2} - x_{t3}) + \gamma\, x_{t3} + u_t}$$

Réponse

- **Contraint** : régresser $y_t - x_{t3}$ sur une constante et $(x_{t2} - x_{t3})$.
- **Non contraint** : régresser $y_t - x_{t3}$ sur une constante, $(x_{t2} - x_{t3})$ *et* x_{t3}. C'est le même modèle que l'original, et le coefficient de x_{t3} est $\hat{\gamma} = \hat{\beta}_2 + \hat{\beta}_3 - 1$.
- Si les données respectent **exactement** la contrainte ($\hat{\beta}_2 + \hat{\beta}_3 = 1$ dans la régression non contrainte), alors $\hat{\gamma} = 0$: le coefficient de x_{t3} est nul. Le test t de ce coefficient est le test de $H_0 : \beta_2 + \beta_3 = 1$.

6 Exercice 6 : variable omise et hétéroscédasticité

Vrai modèle : $y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \epsilon_i$, avec $x_{2,i} = \eta x_{1,i} + u_i$ ($\eta \neq 0$), et $\mathrm{Var}(\epsilon_i \mid x_i) = \sigma_i^2$ non constante. On estime le modèle **court** $y_i = \beta_0 + \beta_1 x_{1,i} + \epsilon_i$.

1. Impact sur $\hat{\beta}_1$ et étude de Monte Carlo

Deux problèmes distincts se superposent.

1. **L'omission de x_2 crée un biais** (si $\beta_2 \neq 0$), exactement comme à l'intra 2021 :

$$\mathbb{E}[\hat{\beta}_1 \mid x_1] = \beta_1 + \beta_2 \eta, \qquad \operatorname{plim} \hat{\beta}_1 = \beta_1 + \beta_2 \eta.$$

2. **L'hétéroscédasticité ne crée pas de biais**, mais elle change la variance (Greene, ch. 9). La vraie variance de la pente est

$$\mathrm{Var}(\hat{\beta}_1 \mid \mathbf{X}) = \frac{\sum (x_{1,i} - \bar{x}_1)^2 \sigma_i^2}{\left[\sum (x_{1,i} - \bar{x}_1)^2\right]^2} \neq \frac{\sigma^2}{\sum (x_{1,i} - \bar{x}_1)^2} \quad \text{(formule MCO usuelle).}$$

   L'écart-type affiché par défaut est donc **faux** (biaisé), et les MCO ne sont plus efficaces.

Étapes de la simulation.

1. Choisir $\beta_0, \beta_1, \beta_2, \eta$ (ex. 1, 1, 0,5, 0,5), n, R, la graine, et une forme d'hétéroscédasticité, par ex. $\sigma_i^2 = 0{,}5 + x_{1,i}^2$.
2. Générer une fois $x_1 \sim N(0,1)$, $u \sim N(0,1)$, $x_2 = \eta x_1 + u$.
3. À chaque répétition : tirer $\epsilon_i = \sigma_i z_i$ avec $z_i \sim N(0,1)$; construire y avec le vrai modèle ; régresser y sur $(1, x_1)$; sauvegarder $\hat{\beta}_1$, l'écart-type classique et l'écart-type robuste de White.
4. Comparer : moyenne de $\hat{\beta}_1$ vs β_1 et $\beta_1 + \beta_2 \eta$; écart-type empirique des $\hat{\beta}_1$ (la vraie variabilité) vs moyenne des écarts-types classiques et robustes.

Ce qu'on obtient (réplication Python, $R = 2000$) :

n	moy. $\hat{\beta}_1$	$\beta_1 + \beta_2 \hat{\delta}$	é.-t. empirique	moy. é.-t. classique	moy. é.-t. White
100	1,186	1,193	0,194	0,127	0,185
1000	1,240	1,239	0,058	0,042	0,059

($\hat{\delta}$: pente de la régression de x_2 sur x_1 dans l'échantillon simulé, proche de $\eta = 0{,}5$.)

Réponse

— **Biais** : $\hat{\beta}_1$ est centré sur $\beta_1 + \beta_2\eta$, pas sur β_1 (variable omise). L'hétéroscédasticité n'y est pour rien et n'ajoute aucun biais.
— **Variance** : la vraie variance de $\hat{\beta}_1$ suit la formule « sandwich » ci-dessus. La formule MCO usuelle la **sous-estime** ici (0,127 contre 0,194), parce que la variance des erreurs est plus forte là où x_1 est loin de sa moyenne. L'écart-type robuste de White, $\sqrt{[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\hat{\mathbf{\Sigma}}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}]_{22}}$, retrouve la bonne valeur. (Si la variance était au contraire plus forte près de la moyenne, la formule usuelle la surestimerait.)

2. Proportion de rejets de $H_0 : \beta_2 = 0$ avec un test t robuste

Ce test se fait dans le modèle **complet** (qui contient x_2), avec des écarts-types de White.

Réponse

— **Si la vraie valeur est** $\beta_2 = 0$ (H_0 vraie) : on doit rejeter dans environ **5 %** des échantillons, soit le niveau α (erreur de type I). Le test robuste a la bonne taille *asymptotiquement* ; en petit échantillon, il peut s'en écarter un peu. Simulation : 6,2 % pour $n = 100$, 4,0 % pour $n = 1000$.
— **Si** $\beta_2 \neq 0$ (H_0 fausse, comme dans l'exemple $\beta_2 = 0{,}5$) : la proportion de rejets est la **puissance** du test ; elle tend vers 100 % quand n augmente. Simulation : 98,9 % pour $n = 100$, 100 % pour $n = 1000$.

Avec un test t *classique* (non robuste), la proportion de rejets sous H_0 ne serait en général pas égale à 5 % (l'écart-type est mal estimé) ; c'est pourquoi on utilise la version ajustée pour l'hétéroscédasticité.

7 Exercice 7 : x_i corrélé avec les erreurs

Attention

L'énoncé écrit à la fois $\mathbb{E}[\epsilon \mid X] = 0$ et « les x_i sont corrélés avec les erreurs » : c'est contradictoire ($\mathbb{E}[\epsilon \mid X] = 0$ implique $\mathrm{Cov}(x_i, \epsilon_i) = 0$). On retient l'hypothèse qui fait l'objet de l'exercice : $\mathrm{Cov}(x_i, \epsilon_i) \neq 0$ (endogénéité).

1. Impact sur $\hat{\beta}$ et Monte Carlo

Biais attendu. Comme à l'exercice 2 du document d'analyse asymptotique :

$$\hat{\beta} = \beta + \frac{\frac{1}{n}\sum(x_i - \bar{x})\epsilon_i}{\frac{1}{n}\sum(x_i - \bar{x})^2} \quad \Longrightarrow \quad \operatorname{plim}\hat{\beta} = \beta + \frac{\mathrm{Cov}(x, \epsilon)}{\mathrm{Var}(x)} \neq \beta.$$

$\hat{\beta}$ est **biaisé et non convergent** ; le biais a le signe de $\mathrm{Cov}(x, \epsilon)$ et ne disparaît pas quand n augmente.

Étapes de la simulation.

1. Choisir α, β (ex. $\alpha = 0$, $\beta = 1$), n, R, la graine.
2. À chaque répétition, générer **conjointement** x et ϵ corrélés, par ex. $\epsilon_i \sim N(0,1)$, $z_i \sim N(0,1)$ et $x_i = \mu_x + z_i + 0{,}5\,\epsilon_i$. (On ne peut pas garder x fixe : il doit bouger avec ϵ.) Ici $\mathrm{Cov}(x, \epsilon) = 0{,}5$ et $\mathrm{Var}(x) = 1{,}25$.

3. Construire $y_i = \alpha + \beta x_i + \epsilon_i$, estimer par MCO, sauvegarder $\hat{\alpha}$, $\hat{\beta}$ et le t de $\hat{\alpha}$.
4. Comparer la moyenne des $\hat{\beta}$ à β et à la valeur théorique $\beta + \text{Cov} / \text{Var}$; refaire pour plusieurs n.

Réponse

Biais théorique : $\text{Cov}(x,\epsilon)/\text{Var}(x) = 0{,}5/1{,}25 = 0{,}4$, donc $\hat{\beta}$ se concentre autour de 1,4 au lieu de 1. Simulation ($R = 2000$) : moyenne de $\hat{\beta} = 1{,}400$ pour $n = 100$ et $n = 1000$: le biais ne diminue pas avec n.

2. Proportion de rejets de $H_0 : \alpha = 0$

L'estimateur de la constante hérite du biais de la pente. $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$, donc

$$\operatorname{plim} \hat{\alpha} = \alpha + \beta\mu_x - (\operatorname{plim} \hat{\beta})\mu_x = \alpha - \frac{\text{Cov}(x,\epsilon)}{\text{Var}(x)}\,\mu_x, \qquad \mu_x = \mathbb{E}[x].$$

Réponse

Supposons que la vraie valeur soit $\alpha = 0$ (H_0 vraie).

— **Si** $\mathbb{E}[x] \neq 0$: $\hat{\alpha}$ converge vers $-0{,}4\,\mu_x \neq 0$. Le test rejette H_0 (à tort) de plus en plus souvent, et la proportion de rejets tend vers **100 %** quand n augmente. Simulation avec $\mu_x = 2$: 99,1 % ($n = 100$) et 100 % ($n = 1000$), au lieu de 5 %.

— **Si** $\mathbb{E}[x] = 0$: le biais de la pente ne contamine pas la constante à la limite, et la proportion de rejets reste proche de 5 % (simulation : 4,4 % et 5,8 %).

Leçon : avec des régresseurs endogènes, les tests ne contrôlent plus leur niveau. On ne rejette plus dans « $\alpha = 5\,\%$ des cas sous H_0 » : l'inférence est invalide. La solution est d'utiliser des variables instrumentales (Greene, ch. 8 ; exercice 8).

8 Exercice 8 : $\tilde{\beta} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{y}$ est sans biais

C'est l'estimateur des **doubles moindres carrés** (Greene, ch. 8). Hypothèses : $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, $\mathbf{X}'\mathbf{P}_z\mathbf{X}$ définie positive (donc inversible), $\mathbf{Z}$ de plein rang colonne.

Étape 1 : écrire $\tilde{\beta}$ en fonction de l'erreur.

$$\tilde{\beta} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \underbrace{(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{X}}_{\mathbf{I}}\boldsymbol{\beta} + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\boldsymbol{\epsilon}.$$

Étape 2 : espérance conditionnelle. La matrice $(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z$ ne dépend que de $\mathbf{X}$ et $\mathbf{Z}$:

$$\mathbb{E}[\tilde{\beta} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\,\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta}.$$

Étape 3 : loi des espérances itérées. $\mathbb{E}[\tilde{\beta}] = \boldsymbol{\beta}$.

Réponse

$\tilde{\beta}$ est sans biais. Remarque : on peut l'écrire $\tilde{\beta} = \left[(\mathbf{P}_z\mathbf{X})'(\mathbf{P}_z\mathbf{X})\right]^{-1}(\mathbf{P}_z\mathbf{X})'\mathbf{y}$, c'est-à-dire la régression de $\mathbf{y}$ sur $\hat{\mathbf{X}} = \mathbf{P}_z\mathbf{X}$ (la partie de $\mathbf{X}$ expliquée par les instruments). Sous l'hypothèse forte $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, il est sans biais mais moins efficace que les MCO ; son vrai intérêt est le cas où $\mathbf{X}$ est endogène (exercice 7), où il reste *convergent* si $\mathbb{E}[\mathbf{Z}'\boldsymbol{\epsilon}] = \mathbf{0}$.

9 Exercice 9 : heures de travail et salaires (Ontario)

Modèle : $y_i = \beta_0 + \beta_1 Hours_i + \beta_2 Exper_i + \beta_3 PartTime_i + \epsilon_i$, y_i = log du salaire annuel, $n = 1200$, $K = 4$, donc $n - K = 1196$; valeur critique $t_{0{,}975;\,1196} = 1{,}962$.

1. Interprétation de $\hat{\beta}_1 = 0{,}0756$

Réponse

À expérience et statut (temps partiel ou non) donnés, une heure de travail hebdomadaire de plus est associée à un salaire annuel plus élevé d'environ **7,6 %** ($100\hat{\beta}_1$, car y est en log ; exactement $e^{0{,}0756} - 1 = 7{,}9\,\%$). Très significatif : $t = 11{,}14$, IC à 95 % [0,062 ; 0,089]. C'est une association « toutes choses égales par ailleurs » (par FWL), pas forcément causale.

2. Interprétation de $\hat{\beta}_3 = -0{,}3529$

Réponse

À heures et expérience égales, les travailleurs à temps partiel gagnent environ **35,3 %** de moins que les travailleurs à temps plein (catégorie de référence) ; l'écart exact est $e^{-0{,}3529} - 1 = -29{,}7\,\%$. Comme les heures sont déjà contrôlées, cet écart ne vient pas du simple fait de travailler moins d'heures : c'est une « pénalité » propre au temps partiel (salaire horaire plus faible, types d'emplois différents, moins d'avantages). Graphiquement : deux droites parallèles, celle du temps partiel 0,353 plus bas en log.

3. Pourquoi ne pas inclure aussi $FullTime_i$?

Réponse

$PartTime_i + FullTime_i = 1$ pour tout i : la somme des deux colonnes est la colonne de la constante. C'est le **piège des variables indicatrices** : multicolinéarité parfaite, $\mathbf{X}$ n'est pas de plein rang, $\mathbf{X}'\mathbf{X}$ n'est pas inversible et les MCO ne sont pas définis. On garde une seule indicatrice ; le temps plein sert de référence. (Alternative : les deux indicatrices sans constante.)

4. p-value de l'expérience (0,053)

Réponse

Interprétation : si l'expérience n'avait aucun effet ($\beta_2 = 0$), on aurait 5,3 % de chances d'obtenir par hasard une estimation au moins aussi éloignée de 0 que celle observée.
Décision :

- au seuil de **5 %** : 0,053 > 0,05, on **ne rejette pas** $H_0 : \beta_2 = 0$ (de justesse) ;
- au seuil de **10 %** : 0,053 < 0,10, on **rejette** H_0.

Valeurs manquantes retrouvées : $p = 0{,}053$ avec 1196 degrés de liberté donne $|t| \approx 1{,}94$, d'où e.t.$(\hat{\beta}_2) \approx 0{,}0299/1{,}94 \approx 0{,}0154$.

5. Rejette-t-on $\beta_3 = 0$ au seuil de 5 % ?

Réponse

Oui : l'IC à 95 %, $[-0{,}4019\ ;\ -0{,}3039]$, ne contient pas 0, donc on rejette $H_0 : \beta_3 = 0$ (dualité : 0 hors de l'IC $\iff |t| > 1{,}962$). Valeurs retrouvées : demi-largeur $= 0{,}0490 = 1{,}962 \times$ e.t., d'où e.t.$(\hat{\beta}_3) \approx 0{,}0250$ et $t \approx -14{,}1$ ($p \approx 0$).

6. Test F de $H_0 : \beta_1 - \beta_2 = 0$

1. **Modèle non contraint** : estimer le modèle ; récupérer SCE_u ; $K = 4$, $n - K = 1196$.
2. **Modèle contraint** : sous H_0, $\beta_1 = \beta_2 = \beta$, donc $y_i = \beta_0 + \beta\,(Hours_i + Exper_i) + \beta_3 PartTime_i + \epsilon_i$. Créer $S_i = Hours_i + Exper_i$, régresser y sur une constante, S et $PartTime$; récupérer SCE_r.
3. **Statistique** ($r = 1$ restriction) :

$$F = \frac{\text{SCE}_r - \text{SCE}_u}{\text{SCE}_u} \cdot \frac{n-K}{r} = \frac{\text{SCE}_r - \text{SCE}_u}{\text{SCE}_u} \cdot \frac{1196}{1} \ \sim\ F(1, 1196) \text{ sous } H_0.$$

4. **Décision** : rejeter H_0 si $F > F_{0{,}95;\,1;\,1196} = 3{,}85$ (ou $p < 0{,}05$).

Réponse

H_0 : une heure de travail hebdomadaire et une année d'expérience ont le même effet sur le salaire. Une seule restriction, donc $F = t^2$ avec le t de la question 7 ($3{,}85 = 1{,}962^2$).

7. Reparamétrisation pour un test t d'exclusion

Avec $\theta = \beta_1 - \beta_2$, soit $\beta_1 = \theta + \beta_2$:

$$\beta_1 Hours_i + \beta_2 Exper_i = \theta\, Hours_i + \beta_2\,(Hours_i + Exper_i),$$

$$y_i = \beta_0 + \theta\, Hours_i + \beta_2\,(Hours_i + Exper_i) + \beta_3 PartTime_i + \epsilon_i.$$

Réponse

On régresse y sur une constante, $Hours$, $S = Hours + Exper$ et $PartTime$. Le coefficient de $Hours$ est $\theta = \beta_1 - \beta_2$; tester $H_0 : \beta_1 = \beta_2$ revient à tester l'exclusion de $Hours$ par son t : $t = \hat{\theta}/\text{e.t.}(\hat{\theta}) \sim t(1196)$, rejet si $|t| > 1{,}962$.

8. Même effet des heures pour temps partiel et temps plein

Modèle avec interaction.

$$y_i = \beta_0 + \beta_1 Hours_i + \beta_2 Exper_i + \beta_3 PartTime_i + \beta_4\,(PartTime_i \times Hours_i) + \epsilon_i.$$

Effet d'une heure : β_1 pour le temps plein, $\beta_1 + \beta_4$ pour le temps partiel.

Réponse

$H_0 : \beta_4 = 0$ (même effet des heures), contrainte d'exclusion de l'interaction. Créer $PartTime \times Hours$, estimer ($K = 5$, $n - K = 1195$), et faire le test t : $t = \hat{\beta}_4/\text{e.t.}(\hat{\beta}_4)$, rejet si $|t| > 1{,}962$. Équivalent : test F avec $r = 1$ comparant ce modèle (non contraint) au modèle de départ (contraint), $F = t^2$.