Inférence et tests d'hypothèse – Corrigé (format examen)

Exercice 1

(On teste $H_0 : \beta_k = 0$ contre $H_1 : \beta_k \neq 0$; valeur critique 1,96.)

1. e.t.$(b_k) = \sqrt{\hat{\sigma}^2[(\mathbf{X}'\mathbf{X})^{-1}]_{kk}} = \sqrt{1 \times 0{,}04} = 0{,}2$. $\text{IC}_{95\%} = b_k \pm 1{,}96 \times 0{,}2 = 5 \pm 0{,}392 = [4{,}608\ ;\ 5{,}392]$.

2. $t = \dfrac{b_k - 0}{\text{e.t.}(b_k)} = \dfrac{5}{0{,}2} = 25$.

3. $|t| = 25 > 1{,}96$: on rejette H_0 (0 n'est pas dans l'IC).

4. $p = 2P(|T| > 25) \approx 0 < 0{,}05$: sous H_0, obtenir une estimation aussi éloignée de 0 est pratiquement impossible. On rejette H_0.

Exercice 2

1. $\text{Var}(\hat{\beta}_1 + \hat{\beta}_2) = \text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_2) + 2\,\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = 0{,}04 + 0{,}03 + 0{,}02 = 0{,}09$, e.t. $= 0{,}3$.

2. $\gamma = \beta_1 + \beta_2 - 2$; $H_0 : \gamma = 0$ contre $H_1 : \gamma \neq 0$.

3. $\hat{\gamma} = 1{,}2 + 0{,}8 - 2 = 0$, e.t.$(\hat{\gamma}) = 0{,}3$, $t = 0/0{,}3 = 0$. Comme $|t| = 0 < 2{,}18$, on ne rejette pas H_0.

Exercice 3

On réordonne pour écrire $\mathbf{R} = [\mathbf{R}_1\ \mathbf{R}_2]$ avec $\mathbf{R}_1$ $(r \times r)$ inversible, $\boldsymbol{\beta} = (\boldsymbol{\beta}_1', \boldsymbol{\beta}_2')'$, $\mathbf{X} = [\mathbf{X}_1\ \mathbf{X}_2]$. On pose $\boldsymbol{\gamma}_1 = \mathbf{R}\boldsymbol{\beta} - \mathbf{r}$, d'où $\boldsymbol{\beta}_1 = \mathbf{R}_1^{-1}(\boldsymbol{\gamma}_1 + \mathbf{r} - \mathbf{R}_2\boldsymbol{\beta}_2)$. En substituant :

$$\mathbf{y} - \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{r} = \mathbf{X}_1\mathbf{R}_1^{-1}\boldsymbol{\gamma}_1 + (\mathbf{X}_2 - \mathbf{X}_1\mathbf{R}_1^{-1}\mathbf{R}_2)\boldsymbol{\beta}_2 + \mathbf{u}.$$

Les restrictions $\mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ deviennent les r restrictions nulles $\boldsymbol{\gamma}_1 = \mathbf{0}$ (exclusion des r régresseurs $\mathbf{X}_1\mathbf{R}_1^{-1}$).

Exercice 4

Étapes. (1) Fixer la graine, $n = 25$, générer x_1 une fois. (2) Répéter $R \geq 100$ fois : $u \sim N(0,1)$, $y = 1 + 0{,}8x_1 + u$, MCO, sauvegarder $\hat{\beta}_1, \hat{\beta}_2$. (3) Biais estimé = moyenne − vraie valeur. (4) Refaire avec $n = 50, 100, 200$.

Résultat attendu. Le biais est nul (aux erreurs de simulation près) *pour toutes les tailles*, car $\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta}$ dès que $\mathbb{E}[\mathbf{u} \mid \mathbf{X}] = \mathbf{0}$: il ne « diminue » pas. Ce qui diminue avec n, c'est la variance ($\propto 1/n$) : les estimations se concentrent autour de la vraie valeur (convergence). Simulation ($R = 1000$) : biais de $\hat{\beta}_2$ de $+0{,}009$, $-0{,}002$, $+0{,}002$, $-0{,}002$ pour $n = 25, 50, 100, 200$; écart-type de 0,20 à 0,07.

Exercice 5

Contraint ($\beta_3 = 1 - \beta_2$) : $y_t - x_{t3} = \beta_1 + \beta_2(x_{t2} - x_{t3}) + u_t$; on régresse $y_t - x_{t3}$ sur une constante et $(x_{t2} - x_{t3})$, puis $\tilde{\beta}_3 = 1 - \tilde{\beta}_2$.

Non contraint reparamétré ($\gamma = \beta_2 + \beta_3 - 1$) : $y_t - x_{t3} = \beta_1 + \beta_2(x_{t2} - x_{t3}) + \gamma\, x_{t3} + u_t$. Le coefficient de x_{t3} est $\hat\gamma = \hat\beta_2 + \hat\beta_3 - 1$: il vaut 0 si la contrainte est exactement respectée par les données, et son t teste $\beta_2 + \beta_3 = 1$.

Exercice 6

1. L'omission de x_2 biaise $\hat\beta_1$: $\mathbb{E}[\hat\beta_1] = \beta_1 + \beta_2\eta$ (non convergent si $\beta_2 \neq 0$). L'hétéroscédasticité n'ajoute pas de biais mais change la variance :

$$\operatorname{Var}(\hat\beta_1 \mid \mathbf{X}) = \frac{\sum(x_{1i} - \bar x_1)^2\sigma_i^2}{\left[\sum(x_{1i} - \bar x_1)^2\right]^2} \neq \frac{\sigma^2}{\sum(x_{1i} - \bar x_1)^2}.$$

L'écart-type MCO usuel est donc biaisé (et les MCO inefficaces) ; il faut l'écart-type de White $\sqrt{[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\hat{\mathbf{\Sigma}}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}]_{22}}$.

Monte Carlo : fixer $\beta_0, \beta_1, \beta_2, \eta$, n, R, graine et $\sigma_i^2 = f(x_{1i})$ (ex. $0{,}5 + x_{1i}^2$) ; générer x_1, u, $x_2 = \eta x_1 + u$ une fois ; à chaque répétition tirer $\epsilon_i = \sigma_i z_i$, générer y avec le vrai modèle, régresser y sur $(1, x_1)$, sauvegarder $\hat\beta_1$, l'écart-type classique et celui de White. *Attendu* : moyenne des $\hat\beta_1 \approx \beta_1 + \beta_2\eta$; l'écart-type empirique des $\hat\beta_1$ diffère de la moyenne des écarts-types classiques mais est proche de la moyenne des écarts-types de White.

2. Dans le modèle complet, avec un t robuste : si la vraie valeur est $\beta_2 = 0$, on rejette dans environ $\alpha = 5\,\%$ des échantillons (erreur de type I ; taille correcte asymptotiquement). Si $\beta_2 \neq 0$, la proportion est la puissance du test et tend vers 100 % quand n augmente.

Exercice 7

(On retient $\operatorname{Cov}(x_i, \epsilon_i) \neq 0$; l'hypothèse $\mathbb{E}[\epsilon \mid X] = 0$ de l'énoncé est contradictoire avec elle.)

1. $\hat\beta = \beta + \dfrac{\frac{1}{n}\sum(x_i - \bar x)\epsilon_i}{\frac{1}{n}\sum(x_i - \bar x)^2}$, donc $\operatorname{plim}\hat\beta = \beta + \dfrac{\operatorname{Cov}(x,\epsilon)}{\operatorname{Var}(x)} \neq \beta$: biaisé et non convergent ; le biais a le signe de $\operatorname{Cov}(x, \epsilon)$ et ne disparaît pas avec n.

Monte Carlo : à chaque répétition, générer x et ϵ *ensemble* (ex. $\epsilon \sim N(0,1)$, $x = \mu_x + z + 0{,}5\epsilon$, $z \sim N(0,1)$), puis $y = \alpha + \beta x + \epsilon$, estimer, sauvegarder $\hat\beta$. *Attendu* : moyenne des $\hat\beta \approx \beta + 0{,}5/1{,}25 = \beta + 0{,}4$, quel que soit n.

2. $\operatorname{plim}\hat\alpha = \alpha - \dfrac{\operatorname{Cov}(x,\epsilon)}{\operatorname{Var}(x)}\,\mathbb{E}[x]$. Si $\alpha = 0$ et $\mathbb{E}[x] \neq 0$: $\hat\alpha$ ne converge pas vers 0, on rejette H_0 bien plus que 5 % des fois, et la proportion tend vers 100 % quand n augmente. Si $\mathbb{E}[x] = 0$: environ 5 %. L'inférence n'est pas fiable avec un régresseur endogène.

Exercice 8

$$\tilde\beta = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z(\mathbf{X}\boldsymbol\beta + \boldsymbol\epsilon) = \boldsymbol\beta + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\boldsymbol\epsilon.$$

$(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z$ ne dépend que de $(\mathbf{X}, \mathbf{Z})$, donc $\mathbb{E}[\tilde\beta \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol\beta + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbb{E}[\boldsymbol\epsilon \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol\beta$, et $\mathbb{E}[\tilde\beta] = \boldsymbol\beta$ (espérances itérées). Sans biais.

Exercice 9

($n - K = 1200 - 4 = 1196$; valeur critique 1,962.)

1. À expérience et statut donnés, une heure de travail hebdomadaire de plus est associée à un salaire annuel plus élevé d'environ 7,6 % (y en log ; exactement $e^{0{,}0756} - 1 = 7{,}9\,\%$). Significatif ($t = 11{,}14$).

2. À heures et expérience égales, les travailleurs à temps partiel gagnent environ 35,3 % de moins que les travailleurs à temps plein (exactement $e^{-0{,}3529} - 1 = -29{,}7\,\%$).

3. $PartTime_i + FullTime_i = 1$ = constante : multicolinéarité parfaite (piège des indicatrices), $\mathbf{X}'\mathbf{X}$ non inversible. Le temps plein sert de catégorie de référence.

4. Si $\beta_2 = 0$, la probabilité d'obtenir une estimation au moins aussi éloignée de 0 est de 5,3 %. 0,053 > 0,05 : on ne rejette pas $H_0 : \beta_2 = 0$ à 5 % ; on le rejette à 10 %.

5. Oui : l'IC à 95 %, [−0,402 ; −0,304], ne contient pas 0, donc on rejette $H_0 : \beta_3 = 0$ à 5 %.

6. Non contraint : le modèle estimé, SCE_u. Contraint ($\beta_1 = \beta_2 = \beta$) : $y_i = \beta_0 + \beta(Hours_i + Exper_i) + \beta_3 PartTime_i + \epsilon_i$, SCE_r. Avec $r = 1$, $K = 4$:

$$F = \frac{\text{SCE}_r - \text{SCE}_u}{\text{SCE}_u} \cdot \frac{1196}{1} \sim F(1, 1196) \text{ sous } H_0; \quad \text{rejet si } F > 3{,}85.$$

7. Avec $\theta = \beta_1 - \beta_2$: $y_i = \beta_0 + \theta\, Hours_i + \beta_2(Hours_i + Exper_i) + \beta_3 PartTime_i + \epsilon_i$. Le t du coefficient de $Hours$ teste $H_0 : \theta = 0$, soit $\beta_1 = \beta_2$; rejet si $|t| > 1{,}962$.

8. $y_i = \beta_0 + \beta_1 Hours_i + \beta_2 Exper_i + \beta_3 PartTime_i + \beta_4(PartTime_i \times Hours_i) + \epsilon_i$. Effet d'une heure : β_1 (temps plein), $\beta_1 + \beta_4$ (temps partiel). Test t de $H_0 : \beta_4 = 0$ (exclusion de l'interaction) : $t = \hat{\beta}_4 / \text{e.t.}(\hat{\beta}_4) \sim t(1195)$, rejet si $|t| > 1{,}962$.