Examen intra ECN-6025 (automne 2020)

Corrigé détaillé, démarche pas à pas

Références : notes du chapitre 2 (MCO) ; W. H. Greene, *Econometric Analysis*, ch. 3 à 5

Comment lire ce corrigé

Pour chaque question : l'**idée de la démarche**, le **calcul ou l'argument complet**, la **réponse** encadrée et, quand c'est utile, une **intuition**. Pour les « vrai, faux ou incertain », la note dépend de l'*explication* : on donne donc toujours l'argument mathématique ou économétrique qui justifie la réponse.

Table des matières

1 Question 1 : vrai, faux ou incertain (20 points) 1

2 Question 2 : l'estimateur $\tilde{\mathbf{b}} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{y}$ (20 points) 3

3 Question 3 : prime salariale du secteur privé (20 points) 4

4 Question 4 : variable non pertinente et Monte Carlo (25 points) 6

5 Question 5 : éducation et salaires (15 points) 7

1 Question 1 : vrai, faux ou incertain (20 points)

(a) Sans normalité, les MCO sont biaisés ?

Idée de la démarche

Reprendre la preuve de l'absence de biais et regarder *quelles hypothèses elle utilise réellement.*

On écrit l'estimateur en fonction de l'erreur :

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon}.$$

Puis on prend l'espérance conditionnelle à $\mathbf{X}$:

$$\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\,\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \boldsymbol{\beta} \quad \text{si} \quad \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}.$$

La preuve n'utilise que trois hypothèses : la linéarité du modèle, le plein rang de $\mathbf{X}$ (pour que $(\mathbf{X}'\mathbf{X})^{-1}$ existe) et l'exogénéité $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$. **La normalité n'intervient nulle part.**

Réponse

Faux. L'absence de biais repose sur $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$, pas sur la normalité. Sans normalité, les MCO restent sans biais, et même BLUE si $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}] = \sigma^2\mathbf{I}_n$ (Gauss-Markov n'exige pas la normalité).
Ce que la normalité apporte : la loi *exacte* de $\mathbf{b}$ en échantillon fini, $\mathbf{b} \mid \mathbf{X} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$, et donc la validité exacte des tests t et F. Sans normalité, ces tests ne sont valables qu'approximativement en grand échantillon (théorème central limite).

(b) $\frac{1}{n}\sum x_{j,i}e_i = 0$ prouve l'indépendance entre erreurs et régresseurs ?

Idée de la démarche

Distinguer une propriété *numérique* des MCO (vraie pour n'importe quelles données) d'une hypothèse *statistique* sur la population.

Les conditions du premier ordre des MCO (équations normales) s'écrivent $\mathbf{X}'\mathbf{e} = \mathbf{0}$, soit, pour chaque régresseur j :

$$\sum_{i=1}^{n} x_{j,i}\, e_i = 0 \qquad \Longrightarrow \qquad \frac{1}{n}\sum_{i=1}^{n} x_{j,i}\, e_i = 0, \quad j = 1, 2.$$

C'est vrai **par construction**, quelles que soient les données et que le modèle soit bon ou mauvais. (Remarque : le modèle (1) n'a pas de constante, mais l'orthogonalité tient pour tous les régresseurs inclus ; seule $\sum e_i = 0$ n'est plus garantie.)

Réponse

Faux. L'orthogonalité entre résidus et régresseurs est une propriété numérique des MCO : les résidus sont *choisis* pour être orthogonaux à x_1 et x_2. Elle serait observée même si les erreurs étaient fortement corrélées avec les régresseurs (variable omise, simultanéité, erreur de mesure).
L'hypothèse du modèle classique porte sur les **erreurs** ϵ_i, inobservables, et non sur les résidus e_i : $\mathbb{E}[\epsilon \mid x_1, x_2] = 0$ (ou l'indépendance) ne peut pas être vérifiée de cette façon. Elle doit se justifier par un argument économique ou par le dispositif de collecte des données. De plus, orthogonalité (corrélation nulle) n'est pas indépendance.

(c) Mêmes coefficients pour (2) $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ et (3) $\mathbf{P}_x\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$?

Idée de la démarche

Le modèle (3) régresse $\mathbf{P}_x\mathbf{y} = \hat{\mathbf{y}}$ (les valeurs prédites de (2)) sur les mêmes régresseurs $\mathbf{X} = (\mathbf{X}_1\ \mathbf{X}_2)$. On applique la formule des MCO et les propriétés de $\mathbf{P}_x$: symétrique, idempotente, $\mathbf{P}_x\mathbf{X} = \mathbf{X}$.

$$\mathbf{b}_{(3)} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{P}_x\mathbf{y}) = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{P}_x\mathbf{X})'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{b}_{(2)},$$

car $\mathbf{X}'\mathbf{P}_x = \mathbf{X}'\mathbf{P}_x' = (\mathbf{P}_x\mathbf{X})' = \mathbf{X}'$.

Réponse

Vrai. Les deux régressions donnent exactement les mêmes coefficients ($\mathbf{b}_1$ et $\mathbf{b}_2$). Intuition : $\mathbf{P}_x\mathbf{y}$ est la partie de $\mathbf{y}$ « expliquée » par $\mathbf{X}$. Retirer à $\mathbf{y}$ la partie que $\mathbf{X}$ ne peut pas expliquer ($\mathbf{M}_x\mathbf{y}$, orthogonale à $\mathbf{X}$) ne change pas ce que $\mathbf{X}$ explique : $\mathbf{X}'\mathbf{y} = \mathbf{X}'\mathbf{P}_x\mathbf{y} + \mathbf{X}'\mathbf{M}_x\mathbf{y} = \mathbf{X}'\mathbf{P}_x\mathbf{y}$.

(d) Mêmes résidus pour (2) et (3) ?

Avec les mêmes coefficients (question c) :

$$\mathbf{e}_{(2)} = \mathbf{y} - \mathbf{X}\mathbf{b} = \mathbf{M}_x\mathbf{y}, \qquad \mathbf{e}_{(3)} = \mathbf{P}_x\mathbf{y} - \mathbf{X}\mathbf{b} = \mathbf{P}_x\mathbf{y} - \mathbf{P}_x\mathbf{y} = \mathbf{0}.$$

Réponse

Faux. Les résidus de (3) sont tous nuls : $\mathbf{P}_x\mathbf{y}$ appartient à l'espace engendré par les colonnes de $\mathbf{X}$, donc il est expliqué parfaitement ($R^2 = 1$). Les résidus de (2) valent $\mathbf{M}_x\mathbf{y}$, qui n'est nul que dans le cas sans intérêt où $\mathbf{y}$ est exactement une combinaison linéaire des colonnes de $\mathbf{X}$.
Conséquence pratique : même si les coefficients de (3) sont identiques, ses écarts-types (calculés avec $s^2 = \mathbf{e}'\mathbf{e}/(n-K) = 0$) seraient nuls et donc complètement faux.

2 Question 2 : l'estimateur $\tilde{\mathbf{b}} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{y}$ (20 points)

Hypothèses : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, et $\mathbf{Z}'\mathbf{X}$ ($K \times K$) définie positive, donc inversible. (C'est la forme de l'estimateur des *variables instrumentales*, Greene ch. 8.)

(a) $\tilde{\mathbf{b}}$ est sans biais

Idée de la démarche

Même démarche que pour les MCO : remplacer $\mathbf{y}$ par $\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, écrire $\tilde{\mathbf{b}} = \boldsymbol{\beta} + (\text{poids}) \times \boldsymbol{\epsilon}$, puis prendre l'espérance conditionnelle à $(\mathbf{X}, \mathbf{Z})$.

Étape 1 : écrire $\tilde{\mathbf{b}}$ en fonction de l'erreur.

$$\tilde{\mathbf{b}} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \underbrace{(\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{X}}_{\mathbf{I}_K}\boldsymbol{\beta} + (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\boldsymbol{\epsilon} = \boldsymbol{\beta} + (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\boldsymbol{\epsilon}.$$

Étape 2 : espérance conditionnelle. Sachant $(\mathbf{X}, \mathbf{Z})$, la matrice $(\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'$ est une constante :

$$\mathbb{E}[\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta} + (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\,\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta} + \mathbf{0} = \boldsymbol{\beta}.$$

Étape 3 : loi des espérances itérées. $\mathbb{E}[\tilde{\mathbf{b}}] = \mathbb{E}[\mathbb{E}[\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}]] = \boldsymbol{\beta}$.

Réponse

$\mathbb{E}[\tilde{\mathbf{b}}] = \boldsymbol{\beta}$: $\tilde{\mathbf{b}}$ est sans biais. On a utilisé l'inversibilité de $\mathbf{Z}'\mathbf{X}$ (pour que $\tilde{\mathbf{b}}$ existe et que $(\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{X} = \mathbf{I}_K$) et $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$.

(b) $\tilde{\mathbf{b}}$ est inefficace par rapport aux MCO

Idée de la démarche

$\tilde{\mathbf{b}} = \mathbf{C}\mathbf{y}$ est un estimateur *linéaire* (en $\mathbf{y}$) et *sans biais*. Sous homoscédasticité, le théorème de Gauss-Markov dit que les MCO ont la plus petite variance parmi ces estimateurs. On refait la preuve du cours avec $\mathbf{C} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'$.

Étape 1 : variance de $\tilde{\mathbf{b}}$. Avec $\tilde{\mathbf{b}} - \boldsymbol{\beta} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\boldsymbol{\epsilon}$ et $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}, \mathbf{Z}] = \sigma^2\mathbf{I}_n$:

$$\mathrm{Var}(\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}) = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\,\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}, \mathbf{Z}]\,\mathbf{Z}(\mathbf{X}'\mathbf{Z})^{-1} = \sigma^2(\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{Z}(\mathbf{X}'\mathbf{Z})^{-1}.$$

Étape 2 : variance des MCO. Comme $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$ et $\mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}' \mid \mathbf{X}, \mathbf{Z}] = \sigma^2\mathbf{I}_n$, la formule du cours donne, conditionnellement à $(\mathbf{X}, \mathbf{Z})$: $\mathrm{Var}(\mathbf{b} \mid \mathbf{X}, \mathbf{Z}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$.

Étape 3 : écrire C comme « MCO + écart ». Soit $\mathbf{C} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'$ et $\mathbf{D} = \mathbf{C} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. Comme $\mathbf{CX} = \mathbf{I}_K$:

$$\mathbf{DX} = \mathbf{CX} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_K - \mathbf{I}_K = \mathbf{0}.$$

Étape 4 : comparaison. $\mathrm{Var}(\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}) = \sigma^2\mathbf{CC}'$ et

$$\mathbf{CC}' = (\mathbf{D} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\mathbf{D}' + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}) = \mathbf{DD}' + \underbrace{\mathbf{DX}}_{\mathbf{0}}(\mathbf{X}'\mathbf{X})^{-1} + (\mathbf{X}'\mathbf{X})^{-1}\underbrace{\mathbf{X}'\mathbf{D}'}_{\mathbf{0}} + (\mathbf{X}'\mathbf{X})^{-1}.$$

Donc

$$\mathrm{Var}(\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} + \sigma^2\mathbf{DD}' = \mathrm{Var}(\mathbf{b} \mid \mathbf{X}, \mathbf{Z}) + \sigma^2\mathbf{DD}'.$$

$\mathbf{DD}'$ est semi-définie positive ($\mathbf{c}'\mathbf{DD}'\mathbf{c} = \|\mathbf{D}'\mathbf{c}\|^2 \geq 0$).

Réponse

$\mathrm{Var}(\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}) - \mathrm{Var}(\mathbf{b} \mid \mathbf{X}, \mathbf{Z}) = \sigma^2\mathbf{DD}'$ est semi-définie positive : chaque coefficient (et toute combinaison linéaire $\mathbf{c}'\boldsymbol{\beta}$) est estimé avec une variance au moins aussi grande par $\tilde{\mathbf{b}}$ que par les MCO. $\tilde{\mathbf{b}}$ est donc **inefficace relativement aux MCO**. L'égalité n'a lieu que si $\mathbf{D} = \mathbf{0}$, c'est-à-dire si $\tilde{\mathbf{b}} = \mathbf{b}$ (par exemple si $\mathbf{Z} = \mathbf{XA}$ avec $\mathbf{A}$ inversible).

Autre démonstration (plus directe). On compare les inverses des variances :

$$\mathrm{Var}(\tilde{\mathbf{b}})^{-1} = \frac{1}{\sigma^2}\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X} = \frac{1}{\sigma^2}\mathbf{X}'\mathbf{P}_Z\mathbf{X}, \qquad \mathrm{Var}(\mathbf{b})^{-1} = \frac{1}{\sigma^2}\mathbf{X}'\mathbf{X}.$$

$\mathbf{X}'\mathbf{X} - \mathbf{X}'\mathbf{P}_Z\mathbf{X} = \mathbf{X}'\mathbf{M}_Z\mathbf{X} = (\mathbf{M}_Z\mathbf{X})'(\mathbf{M}_Z\mathbf{X})$ est semi-définie positive, donc $\mathrm{Var}(\mathbf{b})^{-1} \geq \mathrm{Var}(\tilde{\mathbf{b}})^{-1}$, et en inversant (l'inversion renverse l'ordre des matrices définies positives), $\mathrm{Var}(\mathbf{b}) \leq \mathrm{Var}(\tilde{\mathbf{b}})$.

Intuition

$\tilde{\mathbf{b}}$ n'utilise que la partie de la variation de $\mathbf{X}$ qui est corrélée avec $\mathbf{Z}$ ($\mathbf{P}_Z\mathbf{X}$) ; il « jette » la partie $\mathbf{M}_Z\mathbf{X}$. Quand $\mathbf{X}$ est exogène (ici $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$), cette partie jetée est de l'information utile : les MCO l'exploitent, d'où leur plus grande précision. L'estimateur à variables instrumentales n'est intéressant que lorsque $\mathbf{X}$ est *endogène* : les MCO sont alors biaisés, et l'on accepte une variance plus grande en échange de l'absence de biais (asymptotique).

3 Question 3 : prime salariale du secteur privé (20 points)

(a) Différence de salaire constante

Variables.

- w_i : salaire annuel de l'individu i (travailleur à temps plein, Québec, 2010) ; on utilise $\ln w_i$, de sorte que les coefficients se lisent en pourcentages ;
- $educ_i$: années d'éducation ; $exper_i$: années d'expérience ;
- $prive_i = 1$ si l'individu travaille dans le secteur privé, 0 s'il travaille dans le secteur public (catégorie de référence).

Modèle.

$$\ln w_i = \beta_0 + \beta_1\, educ_i + \beta_2\, exper_i + \delta\, prive_i + \epsilon_i, \qquad \mathbb{E}[\epsilon_i \mid educ_i, exper_i, prive_i] = 0.$$

Dans le public, la constante est β_0 ; dans le privé, elle est $\beta_0 + \delta$. Les pentes sont communes : la différence de salaire δ est la même à tous les niveaux d'éducation et d'expérience (droites parallèles). On peut ajouter $exper_i^2$ pour tenir compte de la concavité du profil salarial ; cela ne change pas le test.

Test. $H_0 : \delta = 0$ (pas de différence, à éducation et expérience égales) contre $H_a : \delta \neq 0$.

1. Estimer le modèle par MCO.
2. Calculer $t = \hat{\delta}/\text{e.t.}(\hat{\delta})$, qui suit sous H_0 une loi de Student à $n-4$ degrés de liberté (exactement sous normalité, approximativement sinon).
3. Rejeter H_0 au seuil de 5 % si $|t| > t_{0{,}975;\,n-4} \approx 1{,}96$, ou si la p-value est inférieure à 0,05.

Pour tester spécifiquement une *prime* pour le privé, on peut faire un test unilatéral $H_a : \delta > 0$ (rejet si $t > 1{,}645$).

Réponse

Interprétation : $\hat{\delta} \approx$ différence de salaire en % entre privé et public à éducation et expérience égales (exactement $100(e^{\hat{\delta}} - 1)$ %). On conclut à une différence (ou à une prime si $\hat{\delta} > 0$) si $H_0 : \delta = 0$ est rejetée.

(b) Effets de l'éducation et de l'expérience différents selon le secteur

Modèle avec interactions.

$$\ln w_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \delta_0\, prive_i + \delta_1\,(prive_i \times educ_i) + \delta_2\,(prive_i \times exper_i) + \epsilon_i.$$

Rendement de l'éducation : β_1 dans le public, $\beta_1 + \delta_1$ dans le privé ; rendement de l'expérience : β_2 dans le public, $\beta_2 + \delta_2$ dans le privé.

Test. $H_0 : \delta_1 = \delta_2 = 0$ (mêmes effets dans les deux secteurs) contre H_a : au moins un $\delta_j \neq 0$. C'est une hypothèse **jointe** (2 restrictions) : on utilise un test F.

1. Estimer le modèle non contraint (ci-dessus) : SCE_{NC}, avec $n - 6$ degrés de liberté.
2. Estimer le modèle contraint (celui de (a), sans les interactions) : SCE_C.
3. Calculer
$$F = \frac{(\text{SCE}_C - \text{SCE}_{NC})/2}{\text{SCE}_{NC}/(n-6)} \;\sim\; F(2,\, n-6) \text{ sous } H_0.$$
4. Rejeter H_0 si $F > F_{0{,}95;\,2;\,n-6} \approx 3{,}0$ (ou $p < 0{,}05$). En Stata : `test 1.prive#c.educ 1.prive#c.exper`.

Remarque. Si l'on veut tester que les deux marchés sont *entièrement* identiques (constante comprise), on teste $\delta_0 = \delta_1 = \delta_2 = 0$ (3 restrictions) : c'est le test de Chow.

(c) Même somme des effets de l'éducation et de l'expérience : test t

Idée de la démarche

Traduire l'hypothèse en une *combinaison linéaire* des coefficients, puis soit calculer son écart-type avec la covariance, soit reparamétrer pour que la combinaison devienne un coefficient du modèle.

L'hypothèse. Somme des effets dans le public : $\beta_1 + \beta_2$; dans le privé : $(\beta_1 + \delta_1) + (\beta_2 + \delta_2)$. Égalité $\iff$

$$H_0 :\ \theta \equiv \delta_1 + \delta_2 = 0 \qquad \text{contre} \qquad H_a :\ \delta_1 + \delta_2 \neq 0.$$

C'est une seule restriction linéaire : un test t convient.

Méthode 1 : écart-type de la combinaison linéaire. Dans le modèle de (b) :

$$t = \frac{\hat{\delta}_1 + \hat{\delta}_2}{\text{e.t.}(\hat{\delta}_1 + \hat{\delta}_2)}, \qquad \text{e.t.}(\hat{\delta}_1 + \hat{\delta}_2) = \sqrt{\widehat{\text{Var}}(\hat{\delta}_1) + \widehat{\text{Var}}(\hat{\delta}_2) + 2\,\widehat{\text{Cov}}(\hat{\delta}_1, \hat{\delta}_2)}.$$

Les variances et la covariance se lisent dans la matrice $s^2(\mathbf{X}'\mathbf{X})^{-1}$ (`estat vce` dans Stata). **Ne pas oublier la covariance** : $\hat{\delta}_1$ et $\hat{\delta}_2$ sont estimés sur les mêmes données et sont corrélés. Sous H_0, $t \sim t(n-6)$; on rejette si $|t| > 1{,}96$ environ. (En Stata : `lincom 1.prive#c.educ + 1.prive#c.exper`.)

Méthode 2 : reparamétrisation. On pose $\delta_1 = \theta - \delta_2$ et on substitue :

$$\delta_1(\mathit{prive} \times \mathit{educ}) + \delta_2(\mathit{prive} \times \mathit{exper}) = \theta\,(\mathit{prive} \times \mathit{educ}) + \delta_2\,(\mathit{prive} \times \mathit{exper} - \mathit{prive} \times \mathit{educ}).$$

On estime donc

$$\ln w_i = \beta_0 + \beta_1 \mathit{educ}_i + \beta_2 \mathit{exper}_i + \delta_0 \mathit{prive}_i + \theta\,(\mathit{prive}_i\,\mathit{educ}_i) + \delta_2\,[\mathit{prive}_i(\mathit{exper}_i - \mathit{educ}_i)] + \epsilon_i.$$

Le coefficient de $\mathit{prive} \times \mathit{educ}$ est directement $\theta = \delta_1 + \delta_2$: la ligne correspondante du tableau de régression donne $\hat{\theta}$, son écart-type, la statistique t et la p-value du test.

Réponse

H_0 : $\delta_1 + \delta_2 = 0$, testé par $t = (\hat{\delta}_1 + \hat{\delta}_2)/\text{e.t.}(\hat{\delta}_1 + \hat{\delta}_2) \sim t(n-6)$, l'écart-type incluant $2\widehat{\text{Cov}}(\hat{\delta}_1, \hat{\delta}_2)$; ou, de façon équivalente, par le t du coefficient de $\mathit{prive} \times \mathit{educ}$ dans le modèle reparamétré. Les deux méthodes donnent exactement la même statistique.

4 Question 4 : variable non pertinente et Monte Carlo (25 points)

Le vrai modèle est (4) : $y_i = \beta_0 + \beta_1 x_{1,i} + \epsilon_i$, $\epsilon_i \sim N(0, \sigma^2)$. On estime (5), qui contient en plus $x_{2,i}$.

(a) Étapes de l'étude de Monte Carlo et biais attendu

Les étapes.

1. **Fixer le « monde » simulé** : choisir des valeurs pour β_0, β_1, σ^2 (par ex. $\beta_0 = 2$, $\beta_1 = 1$, $\sigma^2 = 1$), la taille d'échantillon n (par ex. 250) et le nombre de répétitions R (par ex. 1000 ou 10 000). Fixer la graine (`set seed`) pour pouvoir reproduire les résultats.
2. **Générer les régresseurs une seule fois** : $x_{1,i}$ (par ex. $N(0,1)$) et la variable non pertinente $x_{2,i}$, de préférence *corrélée* avec x_1 pour que l'expérience soit intéressante (par ex. $x_{2,i} = \gamma x_{1,i} + \eta_i$, $\eta_i \sim N(0,1)$, $\gamma = 0{,}5$). Elles restent fixes d'une répétition à l'autre (on étudie les propriétés conditionnelles à $\mathbf{X}$), et sont générées indépendamment des erreurs.
3. **Pour chaque répétition** $r = 1, \ldots, R$:
   (a) tirer de nouvelles erreurs $\epsilon_i^{(r)} \sim N(0, \sigma^2)$;
   (b) générer $y_i^{(r)} = \beta_0 + \beta_1 x_{1,i} + \epsilon_i^{(r)}$ avec le **vrai** modèle (4), donc sans x_2 ;
   (c) estimer par MCO le modèle (5) : $y^{(r)}$ sur une constante, x_1 et x_2 ;
   (d) sauvegarder $b_1^{(r)}$, son écart-type, $b_2^{(r)}$ et la statistique t de β_2 (pour la partie b).
4. **Analyser les R estimations** : moyenne $\bar{b}_1 = \frac{1}{R}\sum_r b_1^{(r)}$ comparée à β_1 (biais estimé $\bar{b}_1 - \beta_1$, à juger par rapport à l'erreur de simulation e.t.$(b_1)/\sqrt{R}$, ou par un test t de $H_0 : \mathbb{E}[b_1] = \beta_1$) ; écart-type des $b_1^{(r)}$ (précision) ; histogramme (loi). Idéalement, comparer avec les estimations du modèle correct (4) sur les mêmes échantillons.

Ce que l'on attend : b_1 sans biais. Démonstration formelle.

Le modèle estimé (5) s'écrit $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ avec $\mathbf{X} = (\boldsymbol{\iota}\ \mathbf{x}_1\ \mathbf{x}_2)$ et $\boldsymbol{\beta} = (\beta_0, \beta_1, \beta_2)'$. Puisque (4) a généré les données, (5) est le vrai modèle avec $\beta_2 = 0$: $\boldsymbol{\beta} = (\beta_0, \beta_1, 0)'$. Alors

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\epsilon},$$

$$\mathbb{E}[\mathbf{b} \mid \mathbf{X}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \boldsymbol{\beta},$$

car $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_1, \mathbf{x}_2] = \mathbf{0}$ (x_2 est généré indépendamment des erreurs). En lisant la deuxième composante : $\mathbb{E}[b_1 \mid \mathbf{X}] = \beta_1$, et $\mathbb{E}[b_2 \mid \mathbf{X}] = 0$.

Version par FWL. Soit $\mathbf{M}_2$ la matrice qui crée les résidus d'une régression sur $(\boldsymbol{\iota}\ \mathbf{x}_2)$. Par FWL, $b_1 = (\mathbf{x}_1'\mathbf{M}_2\mathbf{x}_1)^{-1}\mathbf{x}_1'\mathbf{M}_2\mathbf{y}$. Comme $\mathbf{y} = \boldsymbol{\iota}\beta_0 + \mathbf{x}_1\beta_1 + \boldsymbol{\epsilon}$ et $\mathbf{M}_2\boldsymbol{\iota} = \mathbf{0}$:

$$b_1 = \beta_1 + \frac{\mathbf{x}_1'\mathbf{M}_2\boldsymbol{\epsilon}}{\mathbf{x}_1'\mathbf{M}_2\mathbf{x}_1} \quad \Longrightarrow \quad \mathbb{E}[b_1 \mid \mathbf{X}] = \beta_1.$$

Réponse

On s'attend à ce que la moyenne des $b_1^{(r)}$ soit statistiquement indiscernable de β_1 : **inclure une variable non pertinente ne biaise pas** b_1, car le modèle (5) reste correctement spécifié ($\beta_2 = 0$, $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}] = \mathbf{0}$).
En revanche, on s'attend à une **variance plus grande** que dans le modèle correct si x_1 et x_2 sont corrélés :

$$\mathrm{Var}(b_1 \mid \mathbf{X}) = \frac{\sigma^2}{\sum(x_{1,i} - \bar{x}_1)^2\,(1 - r_{12}^2)} \ \geq\ \frac{\sigma^2}{\sum(x_{1,i} - \bar{x}_1)^2},$$

où r_{12} est la corrélation empirique entre x_1 et x_2 : c'est une perte d'efficacité, pas un biais. (À l'inverse, *omettre* une variable pertinente corrélée avec x_1 créerait un biais.)

(b) Proportion de rejets de $H_0 : \beta_2 = 0$

Réponse

On s'attend à rejeter H_0 dans environ **5 % des échantillons** (si le test est fait au seuil $\alpha = 5\,\%$), c'est-à-dire dans une proportion égale à α.
Explication. Les données sont générées par (4), donc $H_0 : \beta_2 = 0$ est *vraie*. Sous H_0 et avec des erreurs normales, $t = b_2/\text{e.t.}(b_2)$ suit exactement une loi de Student à $n-3$ degrés de liberté. Par définition de la valeur critique, $P(|t| > t_{0{,}975;\,n-3} \mid H_0) = 0{,}05$. Le niveau α est la probabilité d'une **erreur de type I** (rejeter une hypothèse vraie). Chaque rejet est ici un « faux positif ».
Sur R répétitions, le nombre de rejets suit une loi binomiale $(R;\, 0{,}05)$: avec $R = 1000$, on s'attend à environ 50 rejets, la proportion observée fluctuant typiquement dans $0{,}05 \pm 1{,}96\sqrt{0{,}05 \times 0{,}95/1000} = [3{,}6\,\%;\ 6{,}4\,\%]$.

Attention

L'énoncé de (b) renvoie au « Monte Carlo en (b) » : il s'agit de celui de la partie (a).

5 Question 5 : éducation et salaires (15 points)

Modèle : $y_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 expersq_i + \epsilon_i$, $n = 1000$.

Unité de y

L'énoncé dit que y_i est le salaire annuel. L'ordre de grandeur des coefficients (0,085 pour l'éducation, constante 0,39) est typique d'une régression où la variable dépendante est le **logarithme** du salaire. On donne l'interprétation dans les deux cas : en niveau, l'effet est en unités de y ; en log, il est (approximativement) en pourcentage. À adapter selon la définition retenue par le professeur.

(a) Interprétation de $\hat{\beta}_1 = 0{,}085$

$\beta_1 = \partial y / \partial educ$ *à expérience constante* : la variation de y associée à une année d'éducation supplémentaire, toutes choses égales par ailleurs (même expérience).

Réponse

- Si y est le salaire en niveau : une année d'études de plus est associée à un salaire annuel plus élevé de 0,085 unité de y (par ex. 85 $ si y est en milliers de dollars), à expérience égale.
- Si $y = \ln(\text{salaire})$: une année d'études de plus est associée à un salaire plus élevé d'environ **8,5 %** (exactement $e^{0{,}085} - 1 = 8{,}9\,\%$), à expérience égale. C'est le « rendement de l'éducation ».

« À expérience égale » vient de la régression multiple (théorème FWL) : $\hat{\beta}_1$ n'utilise que la variation de l'éducation non expliquée par l'expérience. C'est une **association** : si l'habileté (dans ϵ) est corrélée à l'éducation, $\hat{\beta}_1$ est biaisé et ne mesure pas un effet causal.

(b) Effet de l'expérience

Idée de la démarche

L'expérience entre deux fois dans le modèle ($exper$ et $exper^2$) : son effet n'est pas un seul coefficient, c'est une *dérivée* qui dépend du niveau d'expérience.

$$\frac{\partial y}{\partial exper} = \hat{\beta}_2 + 2\hat{\beta}_3\, exper = 0{,}033764 - 2(0{,}000661)\, exper = 0{,}033764 - 0{,}001322\, exper.$$

Expérience (années)	0	5	10	20	25	30
Effet marginal $\partial y/\partial exper$	0,0338	0,0272	0,0205	0,0073	0,0007	−0,0059

Point de retournement : l'effet s'annule quand $0{,}033764 - 0{,}001322\, exper = 0$, soit

$$exper^* = \frac{\hat{\beta}_2}{-2\hat{\beta}_3} = \frac{0{,}033764}{2 \times 0{,}000661} \approx 25{,}5 \text{ ans.}$$

Réponse

L'effet de l'expérience est **positif mais décroissant** (profil concave, car $\hat{\beta}_3 < 0$, très significatif : $t = -7{,}38$) :
- la première année d'expérience augmente y d'environ 0,034 (soit $\approx 3{,}4\,\%$ si y est en log) ;
- à 10 ans d'expérience, une année de plus n'apporte plus que $\approx 2{,}1\,\%$;
- l'effet devient nul vers 25,5 ans d'expérience, puis **négatif** au-delà.

Est-il positif ? **Oui pour l'essentiel des travailleurs** (moins de 25,5 ans d'expérience), non pour les plus expérimentés. Le négatif au-delà de 25,5 ans reflète en partie la forme quadratique imposée et peut concerner peu d'observations. Les deux termes sont individuellement très significatifs ($t = 8{,}22$ et $-7{,}38$) ; pour tester que l'expérience n'a aucun effet, il faudrait tester conjointement $\beta_2 = \beta_3 = 0$ (test F).

(c) p-value du coefficient de l'éducation

$t = \hat{\beta}_1/\text{e.t.}(\hat{\beta}_1) = 0{,}085/0{,}04 = 2{,}125$, avec $n - K = 1000 - 4 = 996$ degrés de liberté.

Réponse

Interprétation de la p-value (0,036) : si le vrai coefficient était nul ($H_0 : \beta_1 = 0$), la probabilité d'obtenir une statistique t au moins aussi grande en valeur absolue que celle observée ($|t| \geq 2{,}125$) serait d'environ 3,6 %. C'est aussi le plus petit seuil auquel on rejetterait H_0.

Décision :
- au seuil de **5 %** : $0{,}036 < 0{,}05$ (et $|t| = 2{,}125 > 1{,}962$), on **rejette** H_0 : l'éducation a un effet statistiquement significatif ;
- au seuil de 10 % : on rejette aussi ;
- au seuil de **1 %** : $0{,}036 > 0{,}01$ (et $2{,}125 < 2{,}581$), on **ne rejette pas** H_0.

La conclusion dépend donc du seuil choisi ; au seuil conventionnel de 5 %, on rejette $\beta_1 = 0$. Nuances : la p-value n'est pas la probabilité que H_0 soit vraie. Et significatif ne veut pas dire précis : l'écart-type (0,04) est grand, l'intervalle de confiance à 95 % est $0{,}085 \pm 1{,}96 \times 0{,}04 = [0{,}007\ ;\ 0{,}163]$.

Attention

Recalculée à partir des valeurs arrondies du tableau, la p-value vaut $2P(T_{996} > 2{,}125) \approx 0{,}034$; l'écart avec 0,036 vient des arrondis du coefficient et de l'écart-type. La conclusion est la même.