Examen intra ECN-6025 (automne 2021)

Corrigé détaillé, démarche pas à pas

Références : notes du chapitre 2 (MCO) ; W. H. Greene, *Econometric Analysis*, ch. 3 à 5 et 8

Comment lire ce corrigé

Pour chaque question : l'**idée de la démarche**, le **calcul ou l'argument complet**, la **réponse** encadrée et, quand c'est utile, une **intuition**. Pour les « vrai, faux ou incertain », la note dépend de l'explication : on donne toujours l'argument qui justifie la réponse.

Table des matières

1 Question 1 : vrai, faux ou incertain (25 points) 1

2 Question 2 : $\tilde{\mathbf{b}} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{y}$ est sans biais (10 points) 3

3 Question 3 : omission d'une variable pertinente (25 points) 4

4 Question 4 : éducation, salaires et immigration (40 points) 6

1 Question 1 : vrai, faux ou incertain (25 points)

(a) $\frac{1}{n}\sum e_i = 0$ forcément ?

Idée de la démarche

Les équations normales des MCO imposent $\mathbf{X}'\mathbf{e} = \mathbf{0}$. La question est de savoir si l'une des colonnes de $\mathbf{X}$ est la colonne de 1.

Le modèle contient une constante β_0, donc la première colonne de $\mathbf{X}$ est $\boldsymbol{\iota} = (1, \ldots, 1)'$. La première équation normale s'écrit

$$\boldsymbol{\iota}'\mathbf{e} = \sum_{i=1}^{n} e_i = 0 \qquad \Longrightarrow \qquad \frac{1}{n}\sum_{i=1}^{n} e_i = 0.$$

Réponse

Vrai. C'est une propriété *numérique* des MCO : dès que le modèle contient une constante, la condition du premier ordre par rapport à β_0, $-2\sum(y_i - b_0 - b_1 x_{1,i} - b_2 x_{2,i}) = 0$, impose que les résidus somment à zéro. C'est vrai pour n'importe quelles données, que les hypothèses du modèle soient vérifiées ou non.
Remarque : sans constante, ce ne serait plus garanti (seule l'orthogonalité $\sum x_{j,i} e_i = 0$ aux régresseurs inclus le serait). Et ce résultat ne dit rien sur $\mathbb{E}[\epsilon]$: ce sont les *résidus*, pas les erreurs.

(b) $\mathbb{E}[\epsilon_i \mid X] = \mu < 0$: biais vers le bas pour β_0 et β_1 ?

Idée de la démarche

Réécrire le modèle avec une erreur de moyenne nulle, $u_i = \epsilon_i - \mu$, et voir quel coefficient « absorbe » μ.

Posons $u_i = \epsilon_i - \mu$, de sorte que $\mathbb{E}[u_i \mid X] = 0$. Alors

$$y_i = \beta_0 + \beta_1 x_{1,i} + \mu + u_i = \underbrace{(\beta_0 + \mu)}_{\text{nouvelle constante}} + \beta_1 x_{1,i} + u_i.$$

Ce modèle satisfait l'exogénéité, donc les MCO estiment sans biais ses coefficients :

$$\mathbb{E}[b_0] = \beta_0 + \mu < \beta_0, \qquad \mathbb{E}[b_1] = \beta_1.$$

Calcul direct pour la pente : $b_1 = \beta_1 + \dfrac{\sum(x_{1,i} - \bar{x}_1)\epsilon_i}{\sum(x_{1,i} - \bar{x}_1)^2}$, donc $\mathbb{E}[b_1 \mid X] = \beta_1 + \dfrac{\mu \sum(x_{1,i} - \bar{x}_1)}{\sum(x_{1,i} - \bar{x}_1)^2} = \beta_1 + 0$, car $\sum(x_{1,i} - \bar{x}_1) = 0$.

Réponse

Faux. Seule la constante est biaisée vers le bas ($\mathbb{E}[b_0] = \beta_0 + \mu$, biais $\mu < 0$). La pente b_1 reste **sans biais** : une erreur de moyenne *constante* déplace la droite verticalement sans changer sa pente. Ce qui biaiserait b_1, c'est une moyenne conditionnelle qui *varie avec* x_1 (par exemple $\mathbb{E}[\epsilon_i \mid X] = \alpha_0 + \alpha_1 x_{1,i}$ avec $\alpha_1 \neq 0$; voir le devoir 1, question 1(c)). La normalité ne joue aucun rôle dans ce raisonnement.

(c) Même $\mathbf{b}_2$ pour (1) $\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\epsilon}$ et (2) $\mathbf{P}_x\mathbf{y} = \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\epsilon}$?

Idée de la démarche

Dans (2), on régresse $\mathbf{P}_x\mathbf{y} = \hat{\mathbf{y}}$ sur $\mathbf{X}_2$ **seulement** : $\mathbf{X}_1$ a été retiré des régresseurs. On calcule l'estimateur de (2) et on le compare à celui de (1).

Notons $\mathbf{b}_1, \mathbf{b}_2$ les estimateurs de (1). Alors $\mathbf{P}_x\mathbf{y} = \mathbf{X}\mathbf{b} = \mathbf{X}_1\mathbf{b}_1 + \mathbf{X}_2\mathbf{b}_2$. L'estimateur de (2) est

$$\mathbf{b}_2^{(2)} = (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{P}_x\mathbf{y} = (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'(\mathbf{X}_1\mathbf{b}_1 + \mathbf{X}_2\mathbf{b}_2) = \mathbf{b}_2 + (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\,\mathbf{b}_1.$$

(On peut aussi noter que $\mathbf{X}_2'\mathbf{P}_x = \mathbf{X}_2'$, car $\mathbf{P}_x\mathbf{X}_2 = \mathbf{X}_2$: donc $\mathbf{b}_2^{(2)} = (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{y}$, c'est-à-dire l'estimateur de la régression « courte » de $\mathbf{y}$ sur $\mathbf{X}_2$ seul.)

Réponse

Incertain (faux en général). $\mathbf{b}_2^{(2)} = \mathbf{b}_2 + (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1\mathbf{b}_1$. Les deux estimateurs sont identiques seulement si $\mathbf{X}_2'\mathbf{X}_1\mathbf{b}_1 = \mathbf{0}$, par exemple :

- si $\mathbf{X}_1$ et $\mathbf{X}_2$ sont orthogonaux ($\mathbf{X}_1'\mathbf{X}_2 = \mathbf{0}$) ;
- ou si $\mathbf{b}_1 = \mathbf{0}$.

Sinon, ils diffèrent : le modèle (2) revient à omettre $\mathbf{X}_1$, et l'écart est exactement la formule du biais de variable omise (version numérique). À comparer avec l'intra 2020, où $\mathbf{P}_x\mathbf{y}$ était régressé sur *tout* $\mathbf{X}$: là, les coefficients étaient identiques.

(d) $b_1 = 1$ dans l'échantillon, donc $\beta_1 = 1$?

Réponse

Faux. « Sans biais » signifie $\mathbb{E}[b_1] = \beta_1$: *en moyenne sur des échantillons répétés*, l'estimateur tombe sur la vraie valeur. Dans un échantillon donné, $b_1 = \beta_1 + \dfrac{\sum(x_{1,i} - \bar{x}_1)\epsilon_i}{\sum(x_{1,i} - \bar{x}_1)^2}$ contient une erreur d'échantillonnage aléatoire, de variance $\sigma^2 / \sum(x_{1,i} - \bar{x}_1)^2 > 0$. L'estimation 1 est une réalisation d'une variable aléatoire ; avec des erreurs normales (loi continue), $P(b_1 = \beta_1) = 0$.
Ce que l'on peut dire de β_1 : construire un intervalle de confiance, $1 \pm t_{0{,}975;\, n-2}$ e.t.(b_1), ou tester des hypothèses sur β_1. L'étude de Monte Carlo du cours l'illustre : les b_1^* varient de 0,88 à 1,12 autour de la vraie valeur 1.

(e) $\hat{\mu} = \frac{1}{n-1}\sum y_i$ sans biais et convergent ?

Idée de la démarche

Deux propriétés à vérifier séparément : le biais (espérance) et la convergence (biais et variance tendent vers 0 quand $n \to \infty$).

Biais. $\mathbb{E}[\hat{\mu}] = \dfrac{1}{n-1}\sum_{i=1}^{n} \mathbb{E}[y_i] = \dfrac{n\mu}{n-1}$, d'où $\text{Biais}(\hat{\mu}) = \dfrac{n\mu}{n-1} - \mu = \dfrac{\mu}{n-1} \neq 0$ (sauf si $\mu = 0$).

Convergence. $\text{Var}(\hat{\mu}) = \dfrac{1}{(n-1)^2}\sum_{i=1}^{n} \text{Var}(y_i) = \dfrac{n\sigma^2}{(n-1)^2} \to 0$, et le biais $\mu/(n-1) \to 0$. L'erreur quadratique moyenne $\text{EQM} = \text{Var} + \text{Biais}^2 \to 0$, donc $\hat{\mu}$ converge en moyenne quadratique, et donc en probabilité : $\operatorname{plim} \hat{\mu} = \mu$. (Autre argument : $\hat{\mu} = \frac{n}{n-1}\bar{y}$, avec $\frac{n}{n-1} \to 1$ et $\operatorname{plim} \bar{y} = \mu$ par la loi des grands nombres.)

Réponse

Faux. $\hat{\mu}$ est **biaisé** (biais $\mu/(n-1)$, sauf dans le cas particulier $\mu = 0$), mais il est **convergent** (biais et variance tendent vers 0). L'affirmation, qui exige les deux propriétés, est donc fausse. On retient : convergent n'implique pas sans biais, et inversement.

2 Question 2 : $\tilde{\mathbf{b}} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{y}$ est sans biais (10 points)

Hypothèses : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, $\mathbf{Z}$ de dimension $n \times K_z$ avec $K_z > K_x$, $\mathbf{X}'\mathbf{P}_z\mathbf{X}$ définie positive (donc inversible), $\mathbf{P}_z = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$. C'est l'estimateur des **doubles moindres carrés** (variables instrumentales avec plus d'instruments que de régresseurs ; Greene, ch. 8).

Idée de la démarche

Même démarche que pour les MCO : remplacer $\mathbf{y}$ par $\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, écrire $\tilde{\mathbf{b}} = \boldsymbol{\beta} + (\text{matrice})\,\boldsymbol{\epsilon}$, puis prendre l'espérance conditionnelle à $(\mathbf{X}, \mathbf{Z})$. La matrice ne dépend que de $\mathbf{X}$ et $\mathbf{Z}$.

Étape 1 : écrire $\tilde{\mathbf{b}}$ en fonction de l'erreur.

$$\tilde{\mathbf{b}} = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}) = \underbrace{(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{X}}_{\mathbf{I}_{K_x}}\boldsymbol{\beta} + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\boldsymbol{\epsilon}$$

$$= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\boldsymbol{\epsilon}.$$

Étape 2 : espérance conditionnelle. La matrice $(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z = (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$ ne dépend que de $\mathbf{X}$ et $\mathbf{Z}$: sachant $(\mathbf{X}, \mathbf{Z})$, c'est une constante. Donc

$$\mathbb{E}[\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\,\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \boldsymbol{\beta} + \mathbf{0} = \boldsymbol{\beta}.$$

Étape 3 : loi des espérances itérées. $\mathbb{E}[\tilde{\mathbf{b}}] = \mathbb{E}\big[\mathbb{E}[\tilde{\mathbf{b}} \mid \mathbf{X}, \mathbf{Z}]\big] = \boldsymbol{\beta}$.

Réponse

$\mathbb{E}[\tilde{\mathbf{b}}] = \boldsymbol{\beta}$: $\tilde{\mathbf{b}}$ est sans biais. Hypothèses utilisées :
- $\mathbf{X}'\mathbf{P}_z\mathbf{X}$ inversible, pour que $\tilde{\mathbf{b}}$ existe et que $(\mathbf{X}'\mathbf{P}_z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_z\mathbf{X} = \mathbf{I}$;
- $\mathbf{Z}'\mathbf{Z}$ inversible ($\mathbf{Z}$ de plein rang colonne), pour que $\mathbf{P}_z$ soit défini ;
- $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, pour annuler le second terme.

Intuition

$\mathbf{P}_z\mathbf{X}$ est la partie de $\mathbf{X}$ « expliquée » par les instruments $\mathbf{Z}$. On peut écrire $\tilde{\mathbf{b}} = \big[(\mathbf{P}_z\mathbf{X})'(\mathbf{P}_z\mathbf{X})\big]^{-1}(\mathbf{P}_z\mathbf{X})'\mathbf{y}$: c'est la régression de $\mathbf{y}$ sur $\hat{\mathbf{X}} = \mathbf{P}_z\mathbf{X}$, d'où le nom « doubles moindres carrés » (première étape : $\mathbf{X}$ sur $\mathbf{Z}$; seconde : $\mathbf{y}$ sur $\hat{\mathbf{X}}$). Ici, avec $\mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$, l'estimateur est sans biais, mais il serait moins efficace que les MCO (même argument que l'intra 2020, question 2(b)). Son intérêt apparaît quand $\mathbf{X}$ est endogène.

3 Question 3 : omission d'une variable pertinente (25 points)

Vrai modèle (3) : $y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \epsilon_i$, avec $x_{2,i} = \eta x_{1,i} + u_i$, $\eta \neq 0$, $\mathbb{E}[u_i \mid x_{1,i}] = 0$. On estime le modèle (4) qui **omet** x_2.

(a) Les étapes de l'étude de Monte Carlo (15 points)

1. **Fixer le « monde » simulé.** Choisir β_0, β_1, β_2 **avec** $\beta_2 \neq 0$ (sinon x_2 n'est pas pertinente et il n'y a rien à étudier), σ^2, et $\eta \neq 0$. Exemple : $\beta_0 = 2$, $\beta_1 = 1$, $\beta_2 = 0{,}5$, $\sigma^2 = 1$, $\eta = 0{,}5$. Choisir n (par ex. 250) et R (par ex. 1000 ou 10 000). Fixer la graine (`set seed`) pour pouvoir reproduire les résultats.
2. **Générer les régresseurs une seule fois** (fixes d'une répétition à l'autre) :
   (a) $x_{1,i}$, par ex. $N(0,1)$;
   (b) $u_i \sim N(0,1)$, indépendant de x_1 (ce qui assure $\mathbb{E}[u_i \mid x_{1,i}] = 0$) ;
   (c) $x_{2,i} = \eta x_{1,i} + u_i$.
3. **Pour chaque répétition** $r = 1, \ldots, R$:
   (a) tirer de nouvelles erreurs $\epsilon_i^{(r)} \sim N(0, \sigma^2)$, indépendantes de x_1 et x_2 ;
   (b) générer $y_i^{(r)} = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \epsilon_i^{(r)}$ avec le **vrai** modèle (3) ;
   (c) estimer par MCO le modèle **court** (4) : $y^{(r)}$ sur une constante et x_1 seulement ;
   (d) sauvegarder $b_1^{(r)}$ (et son écart-type). Idéalement, estimer aussi le modèle complet (3) sur le même échantillon pour comparer.
4. **Analyser les résultats** :
   — moyenne $\bar{b}_1 = \frac{1}{R}\sum_r b_1^{(r)}$ et biais estimé $\bar{b}_1 - \beta_1$, comparé à l'erreur de simulation e.t.$(b_1)/\sqrt{R}$ (ou test t de $H_0 : \mathbb{E}[b_1] = \beta_1$) ;
   — comparer le biais estimé au biais théorique $\beta_2\hat{\delta}$ (voir (b)) ;

— histogramme des $b_1^{(r)}$: centré sur $\beta_1 + \beta_2\eta$, pas sur β_1 ;
— prolongements : faire varier η et β_2 (le biais change de taille et de signe), et n (le biais ne disparaît pas).

(b) Le biais attendu de b_1 : démonstration formelle (10 points)

Idée de la démarche

Écrire b_1 (formule de la régression simple) en remplaçant y_i par le *vrai* modèle (3), qui contient x_2. Le terme en $\beta_2 x_2$ ne disparaît pas : c'est lui qui crée le biais.

Étape 1 : formule de b_1 dans le modèle court.

$$b_1 = \frac{\sum(x_{1,i} - \bar{x}_1)y_i}{\sum(x_{1,i} - \bar{x}_1)^2}.$$

Étape 2 : on remplace y_i par le vrai modèle (3). Avec $\sum(x_{1,i} - \bar{x}_1) = 0$ et $\sum(x_{1,i} - \bar{x}_1)x_{1,i} = \sum(x_{1,i} - \bar{x}_1)^2$:

$$b_1 = \beta_1 + \beta_2 \underbrace{\frac{\sum(x_{1,i} - \bar{x}_1)x_{2,i}}{\sum(x_{1,i} - \bar{x}_1)^2}}_{\hat{\delta}} + \frac{\sum(x_{1,i} - \bar{x}_1)\epsilon_i}{\sum(x_{1,i} - \bar{x}_1)^2}.$$

$\hat{\delta}$ est la pente MCO de la régression de x_2 sur x_1 (avec constante).

Étape 3 : espérance conditionnelle à (x_1, x_2). Avec $\mathbb{E}[\epsilon \mid X] = 0$, le dernier terme a une espérance nulle :

$$\mathbb{E}[b_1 \mid x_1, x_2] = \beta_1 + \beta_2\,\hat{\delta}.$$

Étape 4 : utiliser $x_2 = \eta x_1 + u$.

$$\hat{\delta} = \frac{\sum(x_{1,i} - \bar{x}_1)(\eta x_{1,i} + u_i)}{\sum(x_{1,i} - \bar{x}_1)^2} = \eta + \frac{\sum(x_{1,i} - \bar{x}_1)u_i}{\sum(x_{1,i} - \bar{x}_1)^2}, \qquad \mathbb{E}[\hat{\delta} \mid x_1] = \eta$$

car $\mathbb{E}[u_i \mid x_{1,i}] = 0$. Par la loi des espérances itérées :

$$\mathbb{E}[b_1 \mid x_1] = \beta_1 + \beta_2\,\eta, \qquad \mathbb{E}[b_1] = \beta_1 + \beta_2\eta.$$

Réponse

$$\text{Biais}(b_1) = \beta_2\,\eta \;\neq 0 \qquad (\beta_2 \neq 0,\ \eta \neq 0).$$

On s'attend donc à ce que la moyenne des $b_1^{(r)}$ soit significativement différente de β_1, proche de $\beta_1 + \beta_2\eta$ (exemple : $1 + 0{,}5 \times 0{,}5 = 1{,}25$). Dans la simulation, avec x_1, x_2 fixes, le centre exact est $\beta_1 + \beta_2\hat{\delta}$, très proche de $\beta_1 + \beta_2\eta$ quand n est grand.
Signe du biais : celui de $\beta_2\eta$.

	$\eta > 0$ (corrélation positive)	$\eta < 0$
$\beta_2 > 0$	biais > 0 (surestimation)	biais < 0
$\beta_2 < 0$	biais < 0	biais > 0

Le biais ne disparaît pas quand n augmente : $\operatorname{plim} b_1 = \beta_1 + \beta_2\eta$; b_1 n'est pas convergent.

Intuition

En omettant x_2, on le met dans l'erreur du modèle court : $y_i = \beta_0 + \beta_1 x_{1,i} + \underbrace{(\beta_2 x_{2,i} + \epsilon_i)}_{\text{nouvelle erreur}}$.
Comme x_2 est corrélé avec x_1 ($\eta \neq 0$), cette nouvelle erreur est corrélée avec x_1 : l'hypothèse d'exogénéité est violée. Quand x_1 augmente d'une unité, x_2 augmente en moyenne de η, ce qui fait varier y de $\beta_2\eta$ en plus. Le modèle court attribue cet effet indirect à x_1. À comparer avec l'intra 2020 (question 4) : *ajouter* une variable non pertinente ne crée pas de biais ; *omettre* une variable pertinente et corrélée en crée un.

Attention

L'énoncé numérote deux sous-questions « (a) » ; la seconde (10 points) est la partie (b) ci-dessus.

4 Question 4 : éducation, salaires et immigration (40 points)

Modèle (5) : $y_i = \beta_0 + \beta_1 Educ_i + \beta_2 Exper_i + \beta_3 Immigrant_i + \epsilon_i$, où y_i est le **logarithme** du salaire annuel, $n = 1000$, $K = 4$, donc $n - K = 996$ degrés de liberté. Valeur critique : $t_{0{,}975;\,996} = 1{,}962$.

(a) Interprétation de $\hat{\beta}_1 = 0{,}0874$

Réponse

À expérience et statut d'immigrant donnés, une année de scolarité supplémentaire est associée à un salaire annuel plus élevé d'environ **8,7 %** (comme y est en log, $100\hat{\beta}_1 \approx$ variation en % ; exactement $e^{0{,}0874} - 1 = 9{,}1\,\%$). C'est le « rendement de l'éducation ».

- « À … donnés » : par FWL, $\hat{\beta}_1$ n'utilise que la variation de l'éducation non expliquée par l'expérience et le statut d'immigrant.
- Le coefficient est très précis ($t = 15{,}57$, IC à 95 % : [0,076 ; 0,098]).
- C'est une association : si l'habileté (dans ϵ) est corrélée à l'éducation, $\hat{\beta}_1$ est biaisé et ne mesure pas un effet causal.

(b) Interprétation de $\hat{\beta}_3 = -0{,}2688$

Réponse

β_3 mesure l'écart de salaire entre immigrants et non-immigrants (catégorie de référence) **à éducation et expérience égales**. Les immigrants gagnent environ **26,9 %** de moins (approximation $100\hat{\beta}_3$) ; l'écart exact est $e^{-0{,}2688} - 1 = -23{,}6\,\%$ (l'approximation en log est moins bonne pour un grand coefficient).
Graphiquement : deux droites de salaire parallèles, celle des immigrants 0,2688 plus bas en log. L'écart est supposé *constant*, quels que soient l'éducation et l'expérience. Prudence : cet écart conditionnel ne prouve pas une discrimination ; il peut refléter des facteurs omis (langue, reconnaissance des diplômes étrangers, expérience acquise à l'étranger moins valorisée, réseaux).

(c) Pourquoi ne pas inclure aussi $NonImmigrant_i$?

Réponse

Parce que $Immigrant_i + NonImmigrant_i = 1$ pour tout i : la somme des deux colonnes est exactement la colonne de la constante. C'est le **piège des variables indicatrices** : il y a **multicolinéarité parfaite**, $\mathbf{X}$ n'est pas de plein rang colonne, $\mathbf{X}'\mathbf{X}$ n'est pas inversible, et $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ n'existe pas. Les paramètres ne sont pas identifiés : on ne peut pas séparer l'effet de la constante de celui des deux indicatrices.
On inclut donc une seule indicatrice ; l'autre groupe (les non-immigrants) sert de **référence**, et β_3 s'interprète comme un écart par rapport à ce groupe. (Alternative équivalente : inclure les deux indicatrices et retirer la constante.)

(d) p-value du coefficient de l'expérience (0,044)

Réponse

Interprétation : si $\beta_2 = 0$ était vrai, la probabilité d'obtenir une statistique t au moins aussi grande en valeur absolue que celle observée serait de 4,4 %. C'est aussi le plus petit seuil auquel on rejetterait H_0.
Décision ($H_0 : \beta_2 = 0$ contre $H_a : \beta_2 \neq 0$) :
- au seuil de **5 %** : 0,044 < 0,05, on **rejette** H_0 : l'expérience a un effet significatif ;
- au seuil de 10 % : on rejette aussi ;
- au seuil de **1 %** : 0,044 > 0,01, on **ne rejette pas** H_0.

Au seuil conventionnel de 5 %, on rejette $\beta_2 = 0$, mais de peu.
Les valeurs manquantes se retrouvent : $p = 0{,}044$ avec 996 degrés de liberté correspond à $|t| \approx 2{,}02$, donc e.t.$(\hat{\beta}_2) \approx 0{,}0339/2{,}02 \approx 0{,}0168$.

(e) Rejette-t-on $\beta_3 = 0$ au seuil de 5 % ?

Idée de la démarche

Utiliser la dualité entre intervalle de confiance et test : on rejette $H_0 : \beta_3 = 0$ au seuil de 5 % si et seulement si 0 n'est pas dans l'intervalle de confiance à 95 %.

Réponse

Oui. L'intervalle de confiance à 95 % est $[-0{,}3244\ ;\ -0{,}2131]$: il ne contient pas 0, donc on rejette $H_0 : \beta_3 = 0$ contre $H_a : \beta_3 \neq 0$ au seuil de 5 %.
Justification de la dualité : l'IC est $\hat{\beta}_3 \pm 1{,}962$ e.t.$(\hat{\beta}_3)$. Le nombre 0 est hors de l'IC si et seulement si $|\hat{\beta}_3 - 0| > 1{,}962$ e.t.$(\hat{\beta}_3)$, c'est-à-dire $|t| > 1{,}962$.
Valeurs manquantes retrouvées : la demi-largeur de l'IC vaut $(-0{,}2131 + 0{,}3244)/2 = 0{,}0556 = 1{,}962 \times$ e.t., d'où e.t.$(\hat{\beta}_3) \approx 0{,}0283$, $t \approx -0{,}2688/0{,}0283 \approx -9{,}48$, et une p-value pratiquement nulle. L'écart est très significatif.

(f) Test F de $H_0 : \beta_1 - \beta_2 = 0$

Idée de la démarche

On estime le modèle deux fois : sans contrainte, puis en imposant $\beta_1 = \beta_2$. Si la contrainte est vraie, elle ne devrait pas faire beaucoup augmenter la somme des carrés des résidus.

Étape 1 : modèle non contraint. Estimer (5) par MCO et récupérer $\text{SCE}_u = \sum e_i^2$. Ici $K = 4$ et $n - K = 996$.

Étape 2 : modèle contraint. Sous H_0, $\beta_1 = \beta_2 \equiv \beta$:

$$y_i = \beta_0 + \beta\, Educ_i + \beta\, Exper_i + \beta_3 Immigrant_i + \epsilon_i = \beta_0 + \beta\,(Educ_i + Exper_i) + \beta_3 Immigrant_i + \epsilon_i.$$

On crée la variable $S_i = Educ_i + Exper_i$, on régresse y sur une constante, S et $Immigrant$, et on récupère SCE_r. On a $\text{SCE}_r \geq \text{SCE}_u$ (minimiser sous contrainte ne peut pas faire mieux).

Étape 3 : statistique. Une seule restriction, $r = 1$:

$$F = \frac{(\text{SCE}_r - \text{SCE}_u)/r}{\text{SCE}_u/(n-K)} = \frac{(\text{SCE}_r - \text{SCE}_u)/1}{\text{SCE}_u/996} \;\sim\; F(1,\, 996) \quad \text{sous } H_0$$

(loi exacte, puisque $\epsilon \mid X \sim N(0, \sigma^2)$). Les sommes « des écarts résiduels » de l'énoncé sont les sommes des *carrés* des résidus.

Étape 4 : décision. Rejeter H_0 au seuil de 5 % si $F > F_{0{,}95;\,1;\,996} = 3{,}85$, ou si la p-value $P(F_{1,996} > F)$ est inférieure à 0,05.

Réponse

Modèle contraint : y sur une constante, $(Educ + Exper)$ et $Immigrant$; $F = \dfrac{(\text{SCE}_r - \text{SCE}_u)/1}{\text{SCE}_u/996}$; rejet si $F > 3{,}85$. Interprétation : H_0 dit qu'une année d'éducation et une année d'expérience ont le même effet sur le salaire. Avec une seule restriction, $F = t^2$, où t est la statistique de la question (g) ; d'ailleurs $3{,}85 = 1{,}962^2$. En Stata : `test educ = exper`.

(g) Reparamétrisation pour un test t d'exclusion

Idée de la démarche

Faire apparaître $\theta = \beta_1 - \beta_2$ comme coefficient d'une variable du modèle. Tester $\theta = 0$ revient alors à tester l'exclusion de cette variable, avec le t du tableau.

On pose $\theta = \beta_1 - \beta_2$, donc $\beta_1 = \theta + \beta_2$, et on substitue dans (5) :

$$\beta_1 Educ_i + \beta_2 Exper_i = (\theta + \beta_2) Educ_i + \beta_2 Exper_i = \theta\, Educ_i + \beta_2\,(Educ_i + Exper_i).$$

Le modèle reparamétré est

$$y_i = \beta_0 + \theta\, Educ_i + \beta_2\,(Educ_i + Exper_i) + \beta_3 Immigrant_i + \epsilon_i.$$

Réponse

On crée $S_i = Educ_i + Exper_i$ et on régresse y sur une constante, $Educ$, S et $Immigrant$. Le coefficient de $Educ$ est $\theta = \beta_1 - \beta_2$; tester $H_0 : \beta_1 = \beta_2$ revient à tester que $Educ$ peut être exclue de ce modèle ($\theta = 0$). On lit directement dans le tableau :

$$t = \frac{\hat{\theta}}{\text{e.t.}(\hat{\theta})} \sim t(996) \text{ sous } H_0, \quad \text{rejet si } |t| > 1{,}962.$$

C'est le même modèle que (5), écrit autrement : même ajustement, même SCE, et t^2 est égal au F de la question (f). Équivalent sans reparamétrer : $t = (\hat{\beta}_1 - \hat{\beta}_2)/\sqrt{\widehat{\text{Var}}(\hat{\beta}_1) + \widehat{\text{Var}}(\hat{\beta}_2) - 2\widehat{\text{Cov}}(\hat{\beta}_1, \hat{\beta}_2)}$ (`lincom educ - exper`).

(h) Même effet de l'éducation pour immigrants et non-immigrants

Idée de la démarche

Permettre à la pente de l'éducation de différer selon le groupe, grâce à une interaction. L'hypothèse « même effet » devient alors « le coefficient de l'interaction est nul » : une contrainte d'exclusion.

Modèle.

$$y_i = \beta_0 + \beta_1 Educ_i + \beta_2 Exper_i + \beta_3 Immigrant_i + \beta_4 (Immigrant_i \times Educ_i) + \epsilon_i.$$

Effet d'une année d'éducation : β_1 pour les non-immigrants ($Immigrant_i = 0$), $\beta_1 + \beta_4$ pour les immigrants. Le coefficient β_4 est donc la *différence* de rendement de l'éducation entre les deux groupes. (β_3 doit rester dans le modèle, pour laisser la constante différer aussi entre groupes.)

Test. $H_0 : \beta_4 = 0$ (même rendement de l'éducation) contre $H_a : \beta_4 \neq 0$.

1. Créer la variable $Immigrant_i \times Educ_i$ et estimer le modèle par MCO ($K = 5$, $n - K = 995$).
2. Test t d'exclusion : $t = \hat{\beta}_4/\text{e.t.}(\hat{\beta}_4) \sim t(995)$ sous H_0 ; rejeter si $|t| > 1{,}962$ (ou $p < 0{,}05$).
3. De façon équivalente, test F avec $r = 1$: le modèle contraint est (5) et le non contraint est le modèle avec interaction : $F = \dfrac{(\text{SCE}_r - \text{SCE}_u)/1}{\text{SCE}_u/995} = t^2$.

Réponse

On ajoute l'interaction $Immigrant \times Educ$ et on teste l'exclusion de cette variable ($H_0 : \beta_4 = 0$) par un test t. Si l'on rejette, le rendement de l'éducation diffère entre immigrants et non-immigrants ; le rendement des immigrants est alors estimé par $\hat{\beta}_1 + \hat{\beta}_4$. Par exemple, $\hat{\beta}_4 < 0$ serait cohérent avec une moins bonne reconnaissance des diplômes obtenus à l'étranger.